Министерство науки и высшего образования РФ
Федеральное государственное автономное
образовательное учреждение высшего образования
«**СИБИРСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ**»

Институт космических и информационных технологий

Кафедра «Программная инженерия»

УТВЕРЖДАЮ

Заведующий кафедрой

_____ О. А. Антамошкин

подпись инициалы, фамилия

«___» _____ 20 __ г.

БАКАЛАВРСКАЯ РАБОТА

Программная система анализа данных ЭКГ на основе технологий искусственного интеллекта

09.03.04 «Программная инженерия»

Руководитель	_____ подпись, дата	_____ должность, ученая степень	А. С. Михалев инициалы, фамилия
Выпускник	_____ подпись, дата		Е. С. Сурнов инициалы, фамилия
Нормоконтролер	_____ подпись, дата		О. В. Киселева инициалы, фамилия

Красноярск 2026

РЕФЕРАТ

Выпускная квалификационная работа по теме «Программная система анализа данных ЭКГ на основе технологий искусственного интеллекта» содержит 137 страниц текстового документа, 27 использованных источников, 8 иллюстраций, 13 формул, 22 таблицы, 7 приложений.

ЭЛЕКТРОКАРДИОГРАММА, ЭКГ, ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ, ГЛУБОКОЕ ОБУЧЕНИЕ, КЛАССИФИКАЦИЯ ЭКГ, DENSENET121_1D, RESNET18_1D, СИСТЕМА ПОДДЕРЖКИ ПРИНЯТИЯ РЕШЕНИЙ.

Цель работы – создание программной системы, обеспечивающей загрузку цифровой ЭКГ – записи, ее предварительную обработку, классификацию, визуализацию ЭКГ – сигнала и отображение результатов анализа. Система должна функционировать локально на персональном компьютере пользователя без обязательной передачи медицинских данных во внешние облачные сервисы.

В соответствии с целью ставятся следующие задачи:

- проанализировать предметную область классификации ЭКГ – сигналов;
- рассмотреть существующие подходы к автоматическому анализу ЭКГ;
- выполнить обзор коммерческих и исследовательских систем анализа ЭКГ;
- проанализировать открытые наборы данных ЭКГ;
- сформировать требования к программной системе;
- подготовить и гармонизировать данные;
- спроектировать алгоритм классификации 12 – канальных ЭКГ;
- провести экспериментальную оценку нейросетевых архитектур;
- реализовать локальный программный прототип системы поддержки принятия решений.

В результате бакалаврской работы была разработана локальная программная система поддержки принятия решений для предварительного анализа 12 – канальных ЭКГ – сигналов.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 8
1 Анализ предметной области и существующих решений 9
1.1 Электрокардиограмма как источник диагностической информации 9
1.2 Процессы, происходящие при анализе ЭКГ – сигналов 10
1.3 Актуальность автоматической классификации ЭКГ – сигналов 10
1.4 Существующие подходы к автоматическому анализу ЭКГ 11
1.5 Обзор существующих систем анализа ЭКГ 12
1.5.1 Коммерческие системы анализа ЭКГ 12
1.5.2 Исследовательские системы на базе методов глубокого обучения 15
1.5.3 Преимущества и ограничения существующих решений 17
1.6 Обзор открытых наборов данных ЭКГ 19
1.6.1 Открытые наборы данных ЭКГ 19
1.6.2 Ограничения открытых наборов данных ЭКГ 21
1.7 Выявление проблем и ограничений существующих подходов 22
1.8 Постановка задачи 24
1.9 Вывод по главе 26
2 Требования к программной системе поддержки принятия решений на основе анализа ЭКГ – сигналов 27
2.1 Назначение и область применения программного продукта 27
2.2 Условия эксплуатации системы 28
2.3 Пользователи системы и сценарии взаимодействия 29
2.4 Функциональные требования 30
2.5 Нефункциональные требования 33
2.5.1 Требования к производительности 33
2.5.2 Требования к надежности и отказоустойчивости 33
2.5.3 Требования к точности классификации 34
2.5.4 Требования к безопасности 35
2.5.5 Требования к удобству использования 36

2.5.6 Требования к совместимости и переносимости 36
2.5.7 Требования к сопровождаемости и расширяемости 37
2.6 Требования к входным данным 37
2.7 Требования к результатам анализа ЭКГ – сигналов 38
2.8 Требования к пользовательскому интерфейсу 39
2.9 Требования к программным интерфейсам 39
2.10 Ограничения и допущения 40
2.11 Критерии качества и приемки программного продукта 41
2.12 Вывод по главе 43
3 Подготовка данных и проектирование алгоритма классификации ЭКГ – сигналов 44
3.1 Описание используемых наборов данных 44
3.1.1 PTB – XL 45
3.1.2 Ningbo 45
3.1.3 MIMIC – IV – ECG 46
3.1.4 Georgia 12 – lead ECG Challenge Database 46
3.2 Форматы хранения ЭКГ – сигналов: WFDB 47
3.3 Анализ структуры и семантики наборов данных 49
3.4 Гармонизация диагностических меток 51
3.5 Техническая стандартизация ЭКГ – сигналов 54
3.6 Предобработка ЭКГ – сигналов 56
3.7 Формирование целевой переменной и разделение данных 60
3.8 Формальная постановка задачи классификации 62
3.9 Выбор и обоснование архитектур нейронных сетей 63
3.9.1 Архитектура ResNet 65
3.9.2 Архитектура DenseNet 67
3.9.3 Ограничения и границы применимости моделей 69
3.10 Алгоритм применения модели классификации 71
3.11 Выводы по главе 73
4 Исследование эффективности моделей классификации ЭКГ – сигналов 75

4.1 Экспериментальная постановка исследования 75
4.2 Подготовка данных и протокол формирования выборок 75
4.2.1 Учет дисбаланса классов при оценке качества 76
4.2.2 Контроль утечки данных 76
4.2.3 Варианты входного сигнала 77
4.2.4 Нормализация данных 77
4.2.5 Расширение данных ЭКГ – сигналов 77
4.3 Роль SimpleCNN1D в исследовательском этапе 78
4.4 Метрики и методика оценки качества 78
4.4.1 Используемые метрики 78
4.4.2 Обоснование выбора F1 macro 79
4.5 Бинарные исследовательские эксперименты на SimpleCNN1D 79
4.5.1 Сравнение исходного и фильтрованного ЭКГ – сигнала 79
4.5.2 Исследование влияния случайных преобразований 80
4.5.3 Исследование влияния нормализации 81
4.5.4 Исследование влияния скорости обучения и размера пакета 82
4.6 Переход к финальной трехклассовой постановке 83
4.7 Методика обучения финальных моделей 83
4.7.1 Функция потерь, оптимизатор и планировщик скорости обучения 83
4.7.2 Настройка скорости обучения и размера пакета 83
4.7.3 Валидация, регуляризация и критерии остановки обучения 84
4.8 Финальное обучение и сравнение ResNet18_1D и DenseNet121_1D 84
4.9 Динамика обучения моделей 85
4.10 Анализ ошибок классификатора 86
4.10.1 Матрицы ошибок 86
4.10.2 Анализ типичных ошибок 87
4.11 Анализ сходимости и устойчивости финальных моделей 87
4.12 Вывод по главе 88
5 Апробация модели на реальных клинических данных 89
5.1 Цель, условия и критерии апробации 89

5.2 Описание клинических данных 90
5.3 Анализ результатов вывод моделиа 91
5.3.1 Сводные метрики качества 91
5.3.2 Матрица ошибок 92
5.3.3 Поклассовые метрики 92
5.4 Анализ ограничений 93
5.5 Выводы по главе 94
6 Проектирование и реализация программной системы поддержки принятия решений на основе анализа ЭКГ – сигналов 95
6.1 Общая архитектура программного комплекса 95
6.2 Состав системы и ключевые подсистемы 96
6.2.1 Подсистема ввода и первичной обработки данных 98
6.2.2 Подсистема предобработки ЭКГ – сигналов 99
6.2.3 Подсистема нейросетевого анализа 101
6.2.4 Подсистема анализа ритма и ЧСС 102
6.2.5 Подсистема представления результата и пороговой постобработки 103
6.2.6 Подсистема формирования PDF – отчетов 104
6.2.7 Подсистема автоматического импорта ЭКГ 105
6.2.8 Подсистема объяснимости решений модели 106
6.2.9 Подсистема пользовательского интерфейса и управления сессией 106
6.3 Информационное обеспечение системы 109
6.4 Потоки данных между компонентами системы 109
6.5 Модуль загрузки и обработки XML – файлов ЭКГ 110
6.6 Автоматический импорт ЭКГ – записей из папки кардиографа 111
6.7 Модуль предобработки сигналов 112
6.8 Модуль классификации ЭКГ 113
6.9 Модуль анализа ритма и дополнительных признаков 114
6.10 Модуль представления результатов 114
6.11 Модуль визуализации ЭКГ – сигнала и результатов 114
6.12 Формирование PDF – отчета 115

6.13 Реализация пользовательского интерфейса 116
6.14 Используемые технологии и библиотеки 117
6.15 Вывод по главе 118
ЗАКЛЮЧЕНИЕ 119
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 121
ПРИЛОЖЕНИЕ А 125
ПРИЛОЖЕНИЕ Б 126
ПРИЛОЖЕНИЕ В 127
ПРИЛОЖЕНИЕ Г 128
ПРИЛОЖЕНИЕ И 129
ПРИЛОЖЕНИЕ К 130
ПРИЛОЖЕНИЕ Л 131

ВВЕДЕНИЕ

Сердечно – сосудистые заболевания остаются одной из наиболее острых медико – социальных проблем современности и являются ведущей причиной глобальной смертности. По данным Всемирной организации здравоохранения, ежегодно от ССЗ умирает около 20 миллионов человек, что составляет порядка 32% всех случаев смерти в мире [1].

В клинической практике одним из основных и наиболее доступных методов первичной оценки функционального состояния сердца является электрокардиография. Однако традиционная визуальная интерпретация ЭКГ имеет существенные ограничения, связанные с зависимостью результата от квалификации специалиста, его опыта, текущей рабочей нагрузки и условий труда. Это может приводить к заметным различиям в качестве анализа у врачей разного профиля и уровня подготовки.

Согласно результатам масштабных медицинских исследований, средняя точность ручной интерпретации ЭКГ профильными кардиологами составляет около 75% [18]. Среди практикующих врачей других специальностей, например терапевтов и врачей скорой помощи, этот показатель снижается до 68%, у ординаторов в среднем не превышает 56%, а у студентов – медиков составляет примерно 42% [13]. Такая статистика демонстрирует потребность в автоматизированных интеллектуальных системах, которые при достаточной клинической и технической валидации могут снижать влияние человеческого фактора и способствовать повышению качества кардиологической диагностики на разных уровнях медицинской помощи.

В этих условиях особую актуальность приобретает автоматизация анализа 12 – канальных электрокардиограмм на основе методов машинного и глубокого обучения. Существенный интерес представляют модели, способные повышать воспроизводимость результатов анализа и создавать предпосылки для снижения зависимости диагностического заключения от человеческого фактора.

1 Анализ предметной области и существующих решений

1.1 Электрокардиограмма как источник диагностической информации

Электрокардиограмма является одним из ключевых источников диагностической информации о функциональном состоянии сердечно – сосудистой системы. ЭКГ отражает электрическую активность сердца и позволяет оценивать ритм, проводимость, морфологию отдельных зубцов и комплексов, интервалы, сегменты, электрическую ось сердца, а также признаки ишемических и структурных изменений миокарда. Благодаря этому электрокардиографическое исследование широко применяется как в плановой функциональной диагностике, так и в неотложной кардиологии.

В рамках настоящего исследования предметная область находится на стыке кардиологии, цифровой обработки биомедицинских сигналов и интеллектуальных систем поддержки принятия решений. Центральной задачей является автоматизированный анализ 12 – канальной электрокардиограммы. Объектом исследования выступают цифровые записи ЭКГ, экспортированные из электрокардиографа, а объектом разработки – программная система, обеспечивающая локальную обработку и классификацию.

Практический контекст применения такой системы связан с работой врача функциональной диагностики или кардиолога. Специалисту требуется быстрое, безопасное и удобное средство анализа ЭКГ, позволяющее получать предварительную классификацию записи и интерпретацию результата без передачи медицинских данных во внешние сервисы. В этом случае ЭКГ рассматривается не только как графическое представление электрической активности сердца, но и как цифровой биомедицинский сигнал, пригодный для алгоритмической обработки, машинного анализа и последующего использования в системах поддержки принятия врачебных решений.

1.2 Процессы, происходящие при анализе ЭКГ – сигналов

Процесс анализа ЭКГ – сигналов включает регистрацию сигнала, его сохранение, предварительную обработку, выделение диагностически значимых признаков и интерпретацию результата. В традиционной клинической практике анализ 12 – канальной ЭКГ преимущественно выполняется врачом вручную: медицинский персонал регистрирует сигнал с помощью электрокардиографа, запись экспортируется в цифровой формат и сохраняется в архиве медицинского учреждения, после чего врач просматривает электрокардиограмму и выполняет ее интерпретацию.

Ручная интерпретация основана на визуальном анализе морфологии волн, интервалов, осевых отклонений и других параметров. Врач сопоставляет обнаруженные изменения со стандартными диагностическими критериями и собственным клиническим опытом. В ряде учреждений дополнительно используется встроенная компьютерная интерпретация, предоставляемая самим кардиографом, ее результат, как правило, рассматривается только как вспомогательная информация и не заменяет экспертную оценку врача.

При внедрении автоматизированной системы процесс анализа сохраняет существующую клиническую логику, но дополняется машинной обработкой. Зарегистрированная и экспортированная из электрокардиографа ЭКГ – запись загружается в приложение, где выполняется анализ.

1.3 Актуальность автоматической классификации ЭКГ – сигналов

Актуальность автоматической классификации ЭКГ обусловлена несколькими факторами. Во – первых, электрокардиография остается одним из наиболее массовых методов функциональной диагностики, поэтому объем записей, требующих интерпретации, постоянно возрастает. При этом ручной анализ каждой записи требует времени и высокой квалификации специалиста. В условиях большой нагрузки на врачей возрастает потребность в инструментах, способных выполнять предварительную обработку и классификацию ЭКГ.

Во – вторых, автоматическая классификация может способствовать более быстрой предварительной идентификации потенциально опасных состояний, особенно в задачах сортировки исследований. Система может указывать врачу на записи с повышенной вероятностью патологии и тем самым создавать предпосылки для более оперативного принятия решения в ситуациях, где важна скорость экспертной оценки.

В – третьих, современные методы машинного и глубокого обучения способны выявлять сложные и слабо формализуемые особенности ЭКГ – сигнала. Такие признаки не всегда могут быть явно описаны через ограниченный набор традиционных амплитудно – временных параметров. [12].

1.4 Существующие подходы к автоматическому анализу ЭКГ

Современные подходы к автоматическому анализу ЭКГ можно условно разделить на классические методы, основанные на заранее заданных признаках и экспертных правилах, и методы глубокого обучения, способные извлекать информативные признаки непосредственно из цифрового сигнала.

Классический подход предполагает автоматическую сегментацию кардиоциклов: выделяются зубцы P, комплексы QRS, зубцы T, интервалы и сегменты. На следующем шаге рассчитываются амплитудно – временные и морфологические признаки: длительность RR – , PR – и QT – интервалов, ширина комплекса QRS, амплитуды отдельных зубцов, показатели вариабельности сердечного ритма и другие параметры.

На основе выделенных признаков могут применяться экспертные правила или алгоритмы классического машинного обучения. Преимуществом такого подхода является высокая интерпретируемость: врач может сопоставить результат алгоритма с привычными клиническими параметрами и нормативными значениями. [15].

Современный этап развития автоматического анализа ЭКГ связан с применением методов глубокого обучения. В этой группе подходов используются сверточные нейронные сети, рекуррентные архитектуры, гибридные модели

CNN – LSTM, механизмы внимания и трансформеры. Такие модели могут выполнять классификацию по исходному цифровому сигналу. Это позволяет сократить или полностью исключить этап ручного конструирования признаков, поскольку модель самостоятельно извлекает релевантные пространственно – временные закономерности [12].

1.5 Обзор существующих систем анализа ЭКГ

С практической точки зрения современные системы автоматического анализа ЭКГ можно разделить на два основных направления. Первое направление представлено коммерческими программно – аппаратными комплексами, встроенными в клиническую инфраструктуру и работающими преимущественно через измерения, правила и стандартизированные диагностические критерии. Второе направление включает исследовательские системы на базе машинного и глубокого обучения, обучаемые на крупных массивах ЭКГ – данных и ориентированные на повышение точности классификации, выявление скрытых закономерностей и расширение диагностических возможностей.

1.5.1 Коммерческие системы анализа ЭКГ

Мировой рынок систем компьютерной интерпретации электрокардиограмм исторически формируется решениями нескольких ведущих производителей. К ключевым представителям данного сегмента относятся GE Healthcare с алгоритмом Marquette 12SL и Philips с алгоритмом DXL. Методологическая база этих систем опирается на соблюдение международных кардиологических стандартов и использование обширных верифицированных массивов клинических данных для оценки диагностической точности [14].

Алгоритм Marquette 12SL, впервые внедренный в 1980 году, является одной из наиболее клинически апробированных систем компьютерного анализа ЭКГ. В его основе лежит комплекс технологий обработки биосигналов. Одной из

базовых концепций является технология медианного комплекса, предполагающая идентификацию и морфологическую кластеризацию QRS – комплексов с последующим формированием репрезентативного усредненного кардиоцикла для каждого из 12 синхронно регистрируемых отведений. Медианное усреднение позволяет эффективнее подавлять случайные артефакты и выбросы, обеспечивая более устойчивое определение опорных точек для измерения временных интервалов и амплитуд [1].

Для контроля качества исходных данных в решениях GE Healthcare применяется система Hookup Advisor, которая в реальном времени отслеживает импеданс и уровень шума на каждом электроде. Она позволяет выявлять нарушения контакта, мышечный тремор и сетевую интерференцию до начала записи, что снижает вероятность искажения морфологии сегмента ST. Кроме того, Marquette 12SL учитывает особенности различных клинических субпопуляций: в систему интегрированы критерии для 12 возрастных групп педиатрического профиля и гендерно – специфичные пороговые значения. Указанный подход способствует повышению точности выявления острого инфаркта миокарда у женщин младше 60 лет на 25% за счет модификации порогов смещения сегмента ST. При интеграции с госпитальной информационной сетью MUSE становится доступна функция серийного сравнения, которая автоматически сопоставляет текущую ЭКГ с историческими записями пациента [1].

Система DXL компании Philips ориентирована на расширение диагностических возможностей стандартной 12 – канальной электрокардиографии. Одной из ее особенностей является поддержка расширенного анализа до 16 отведений, включая дополнительные правые и задние электроды. Это повышает информативность исследования при выявлении зон ишемии, которые могут быть недостаточно представлены в стандартных отведениях. Для задач неотложной кардиологии в алгоритме реализована технология STEMI – CA, позволяющая не только выявлять инфаркт миокарда, но и выполнять топическую оценку пораженной коронарной артерии.

Дополнительно используется визуализация ST – карт, формирующая наглядное векторное представление смещений сегмента ST во фронтальной и горизонтальной плоскостях [14].

Отечественный сегмент систем автоматизированного анализа ЭКГ развивается в более широком контексте цифровой трансформации здравоохранения. Национальный проект «Здравоохранение» предусматривает формирование единого цифрового контура, внедрение телемедицинских сервисов и решений на базе искусственного интеллекта [27]. Поэтому российские разработки целесообразно рассматривать не только как аналоги зарубежных электрокардиографических комплексов, но и как элементы медицинских информационных систем и систем поддержки принятия врачебных решений.

Примером специализированного отечественного решения, ориентированного непосредственно на работу с ЭКГ, является проект CORINTEL.TECH, реализуемый на базе Сеченовского Университета. Он представляет собой веб – сервис для автоматизированной аннотации 12 – канальной ЭКГ, основанный на гибридной архитектуре, сочетающей сверточную нейронную сеть и большую языковую модель. Ядром комплекса является CNN, обученная на временных рядах ЭКГ и дополненная встроенным вейвлет – преобразованием, что повышает точность выделения переходных границ и локальных морфологических закономерностей. Для повышения интерпретируемости в архитектуру интегрирован механизм внимания, позволяющий модели фокусироваться на наиболее информативных участках кардиосигнала: зубцах P, комплексах QRS, зубцах T и зонах ишемических изменений. Выделенные признаки затем используются языковой моделью для формирования развернутого текстового заключения по стандартизированному клиническому шаблону [11].

Смежное направление представлено платформой Webiomed компании «К – СКАЙ», которая относится к системам поддержки принятия врачебных решений и работает преимущественно с обезличенными электронными медицинскими

картами, структурированными данными и текстовыми протоколами. В контексте кардиологической диагностики важную роль играет NLP – модуль, обученный на корпусе более 1,3 млн текстовых протоколов и способный извлекать до 492 диагностически значимых признаков из свободного текста, включая параметры ритма, проводимости, реполяризации и морфологические описания. Извлеченные сущности нормализуются и кодируются в соответствии с международной номенклатурой SNOMED CT и российскими клиническими рекомендациями. Валидация модуля на выборке более 2000 документов показала F1 – показатель порядка 0,96 и AUC около 0,97 [25].

На базе данных Webiomed также реализованы предиктивные модели, использующие логистическую регрессию, градиентный бустинг, ансамблевые методы и многослойные перцептроны. В исследовании по прогнозированию госпитализаций пациентов с артериальной гипертензией модель XGBoost, обученная на 151 492 пациентах и 1 165 770 записях, достигла AUROC 0,849 при внутреннем тестировании и 0,815 при внешней валидации [26]. Эти примеры отражают два направления отечественного применения искусственного интеллекта в кардиологической диагностике: специализированную обработку ЭКГ – сигнала и поддержку клинических решений на основе медицинских данных.

1.5.2 Исследовательские системы на базе методов глубокого обучения

В академической среде развитие автоматизированного анализа ЭКГ все больше смещается от классических экспертных систем к моделям глубокого обучения. Основным преимуществом этого подхода является сквозное обучение, при котором нейросетевая архитектура самостоятельно извлекает иерархические признаки непосредственно из цифрового сигнала. Это позволяет исключить трудоемкий этап ручного конструирования дескрипторов и повысить гибкость модели при решении разных диагностических задач [8].

В задачах анализа морфологии ЭКГ и мультиклассовой классификации высокую эффективность демонстрируют глубокие сверточные нейронные сети,

включая архитектуры семейств ResNet, DenseNet и аналогичных. Для моделирования временных зависимостей и анализа нарушений ритма применяются рекуррентные сети и гибридные архитектуры CNN – LSTM, объединяющие выделение локальных морфологических закономерностей с оценкой динамики сердечного цикла. Современные решения также используют механизмы внимания и трансформерные архитектуры, позволяющие модели избирательно фокусироваться на диагностически значимых участках сигнала и снижать влияние шума [5].

Важным достижением нейросетевых моделей стала способность выявлять скрытые признаки сердечно – сосудистых нарушений, которые не всегда обнаруживаются при визуальной оценке. Например, алгоритмы глубокого обучения применяются для прогнозирования риска фибрилляции предсердий по ЭКГ – записям, формально классифицируемым как нормальный синусовый ритм [8]. Также нейросети могут выступать в роли экстракторов цифровых биомаркеров, определяя пол пациента и биологический возраст сердечно – сосудистой системы по стандартной ЭКГ.

Подтвердить эффективность работы нейронных сетей могут многочисленные исследования, так, например A. Hannun и соавт., разработали модель, представляющая собой сквозную глубокую сверточную нейронную сеть для распознавания 12 классов нарушений ритма по одноканальной амбулаторной ЭКГ. Сеть обучалась на 91 232 записях от 53 549 пациентов и валидировалась на независимом тестовом наборе, аннотированном консилиумом кардиологов. На тестовой выборке средняя площадь под ROC – кривой составила около 0,97, а средневзвешенный F1 – показатель достиг 0,837 против 0,780 у среднего кардиолога; при фиксированной специфичности чувствительность нейросети была выше для всех 12 ритмов [2].

Другим примером является система CODE, предложенная A. Ribeiro и соавт. для автоматической интерпретации стандартной 12 – канальной ЭКГ. Авторы сформировали набор данных из 2 322 513 записей от 1 676 384 пациентов телемедицинской сети Минас – Жерайс в Бразилии и обучили остаточную

сверточную сеть распознавать шесть распространенных нарушений. На независимом тестовом наборе из 827 ЭКГ все F1 – показатели модели превысили 0,80, а специфичность по каждому из шести классов была выше 99% [16].

1.5.3 Преимущества и ограничения существующих решений

Коммерческие системы анализа ЭКГ обладают рядом значимых преимуществ. Главным из них является ориентация на клиническую верифицируемость, стандартизацию и интеграцию в медицинские информационные системы. Такие решения основаны на традиционной морфологической интерпретации ЭКГ: оценке интервалов, электрических осей, амплитудных значений и других параметров. Это обеспечивает понятность результатов для врача и возможность их проверки.

К преимуществам коммерческих систем также относятся стабильность и воспроизводимость диагностических измерений. Достоверность результатов поддерживается многолетней клинической валидацией, тестированием на эталонных массивах данных и независимой проверкой. Ведущие системы учитывают возрастные и гендерные особенности пациентов, что повышает чувствительность выявления патологий [22]. Кроме того, интеграция с госпитальными архивами позволяет выполнять серийное сопоставление текущей ЭКГ с предыдущими записями пациента, что важно для динамического наблюдения.

Однако коммерческие программно – аппаратные комплексы имеют и ограничения. Закрытость алгоритмов и использование проприетарных форматов данных создают зависимость медицинской организации от конкретного производителя. Это затрудняет перенос данных между платформами, ограничивает гибкость внедрения и повышает стоимость модернизации оборудования. Дополнительным ограничением является зависимость многих современных сервисов от облачной инфраструктуры. Передача биометрических медицинских данных на удаленные серверы создает риски информационной безопасности и требует строгого соблюдения требований законодательства о

персональных данных. Кроме того, диагностический процесс становится зависимым от стабильности телекоммуникационных каналов.

Академические и исследовательские решения на основе искусственного интеллекта, в свою очередь, демонстрируют высокую точность и способность выявлять скрытые закономерности патологий, которые трудно формализовать традиционными диагностическими критериями. Они хорошо масштабируются и подходят для потоковой обработки больших массивов данных, что особенно важно для телемедицины и холтеровского мониторирования. Методы переносного обучения позволяют адаптировать модели к локальным клиническим выборкам даже при ограниченном объеме данных [7].

В то же время исследовательские модели сталкиваются с рядом существенных проблем. Одной из ключевых является сдвиг области: снижение качества модели при переносе с «чистых» обучающих наборов данных на зашумленные данные реальной клинической практики. Отдельной проблемой остается недостаточная интерпретируемость нейросетевых решений. Методы визуализации, такие как карты активации, не всегда позволяют однозначно связать решение модели с конкретным морфологическим признаком ЭКГ. Наконец, большинство исследовательских прототипов не имеет статуса сертифицированного медицинского изделия, что ограничивает их применение в реальной клинической практике [8].

Рассмотренные свойства существующих систем задают направления последующей формализации требований: локальную обработку данных, наглядность представления результата, контроль качества входного сигнала, автономность работы и удобство пользовательского интерфейса.

1.6 Обзор открытых наборов данных ЭКГ

Качественные верифицированные наборы данных являются основой разработки современных систем автоматического анализа ЭКГ, особенно при использовании методов глубокого обучения. Точность, обобщающая способность и клиническая применимость нейросетевых моделей напрямую зависят от объема, качества и репрезентативности обучающей выборки. В настоящее время сформирован ряд открытых баз данных, используемых как международные бенчмарки для обучения и объективного сравнения алгоритмов автоматической интерпретации ЭКГ. К ним относятся PTB – XL, MIMIC, CPSC, INCART, LUDB и другие наборы [21].

1.6.1 Открытые наборы данных ЭКГ

В настоящее время в открытом доступе можно найти множество различных наборов данных на тематику ЭКГ исследований. Они могут использоваться для разных целей. Так например: Одним из наиболее масштабных клинических наборов данных является PTB – XL. Он включает 21 799 записей 10 – секундных 12 – канальных ЭКГ, полученных от 18 869 пациентов. Важным достоинством PTB – XL является детальная экспертная разметка: каждая запись проаннотирована одним или двумя кардиологами с использованием 71 диагностического утверждения в соответствии со стандартом SCP – ECG. Разметка имеет иерархическую и многометочную структуру, охватывая нарушения ритма, проводимости, ишемические изменения и гипертрофию [23].

Значимую роль в развитии решений на основе искусственного интеллекта для анализа ЭКГ сыграли открытые соревнования PhysioNet/Computing in Cardiology Challenge. В рамках соревнования 2020 года был собран крупномасштабный объединенный набор 12 – канальных ЭКГ, включающий базы из разных стран. Этот ресурс использовался для сопоставления алгоритмов автоматической интерпретации ЭКГ на разнородных клинических данных [10].

Для задач сегментации особое значение имеет российская база LUDB, созданная в Нижегородском государственном университете. В отличие от наборов данных, ориентированных преимущественно на итоговый диагноз, LUDB предназначена для валидации алгоритмов делинеации сигнала. В ней вручную проаннотированы начала, пики и окончания зубцов P, комплексов QRS и зубцов T, причем разметка выполнена независимо для каждого из 12 отведений [19].

В условиях дефицита качественных реальных данных, в силу разных юридических тонкостей, все большую актуальность приобретает использование синтетических ЭКГ. Такие данные могут создаваться с помощью математического моделирования или генеративных нейросетей, включая GAN и диффузионные модели. Синтетические записи позволяют обходить часть ограничений, связанных с конфиденциальностью, а также расширять обучающие выборки и компенсировать дисбаланс классов за счет генерации реалистичных примеров редких аритмий.

Комбинирование диагностических наборов данных, таких как PTB – XL, с базами детальной сегментации вроде LUDB и современными моделями делинеации позволяет создавать комплексные решения. Такие системы способны не только классифицировать ЭКГ, но и выделять морфологические элементы – P – волны, комплексы QRS, зубцы T и соответствующие участки сигнала, повышая интерпретируемость результатов [3].

Отдельного внимания заслуживает семейство баз данных MIMIC, в частности MIMIC – IV и связанный с ним модуль MIMIC – IV – ECG. MIMIC – IV представляет собой крупную клиническую базу данных, включающую не только электрокардиографические записи, но и широкий спектр сопутствующей медицинской информации: демографические данные пациентов, диагнозы, результаты лабораторных исследований, сведения о назначенных препаратах, госпитализациях и других клинических событиях.

Модуль MIMIC – IV – ECG содержит около 800 000 диагностических 10 – секундных 12 – канальных ЭКГ, полученных примерно от 160 000 пациентов;

записи представлены с частотой дискретизации 500 Гц и сопоставлены с клиническими данными MIMIC – IV. В данной работе основной интерес представляет именно ЭКГ – компонент этого ресурса, тогда как его мультимодальный потенциал рассматривается как характеристика набора данных и более широкий контекст его возможного применения.

Связность данных MIMIC показывает, что такие ресурсы могут использоваться не только для классификации ЭКГ – сигналов, но и для более широких задач прогнозирования, оценки рисков и построения систем поддержки принятия врачебных решений. При этом в рамках настоящей работы дальнейшее рассмотрение ограничивается задачей анализа ЭКГ – сигналов.

1.6.2 Ограничения открытых наборов данных ЭКГ

Несмотря на важность открытых ЭКГ – наборов данных, их применение связано с рядом методологических ограничений. Во – первых, многие наборы формируются в отдельных медицинских учреждениях или региональных когортах и преимущественно отражают взрослую госпитализированную популяцию. Это создает смещение выборки по демографическим и клиническим параметрам и снижает обобщающую способность моделей при переносе на другие центры, возрастные группы или этнические когорты [9].

Во – вторых, мультицентровые коллекции, включая объединенные наборы PhysioNet, могут содержать данные, зарегистрированные на разном оборудовании и по различным протоколам. Это повышает вариабельность сигнала и усложняет совместное обучение моделей, а также объективное сравнение результатов, полученных на разных источниках данных [17].

В – третьих, значимой проблемой остается согласованность аннотаций. Диагностические метки могут формироваться автоматическими алгоритмами, отдельными экспертами или консенсусом кардиологов. При этом используются разные номенклатуры и правила агрегации, что приводит к межэкспертной вариабельности, шуму в разметке и неоднородности систем кодирования [20].

В – четвертых, крупные открытые наборы данных ЭКГ часто характеризуются выраженным дисбалансом классов. Распространенные состояния представлены значительно лучше, чем редкие, но клинически важные патологии. В результате модели могут демонстрировать высокие метрики на частых диагнозах и нестабильное качество при распознавании редких аритмий и нарушений проводимости [24].

Отдельной методологической проблемой является утечка данных. Она возникает, когда записи одного пациента или перекрывающиеся фрагменты сигнала одновременно присутствуют в обучающей и тестовой выборках. В таких условиях модель фактически обучается и тестируется на статистически зависимых наблюдениях, что приводит к искусственному завышению метрик и снижению качества при переносе на новых пациентов.

Дополнительным источником скрытой утечки могут быть мультицентровые наборы данных. Если кросс – валидация проводится без контроля источников данных, модель может неявно обучаться на особенностях конкретной больницы, оборудования или локального протокола регистрации, а не на устойчивых диагностических признаках. Также следует учитывать, что ЭКГ как биометрический сигнал может быть уязвима к повторной идентификации и извлечению чувствительной клинической информации при объединении открытых коллекций с внешними источниками данных [4].

1.7 Выявление проблем и ограничений существующих подходов

Анализ существующих подходов к автоматизированной интерпретации ЭКГ позволяет выделить несколько групп проблем, актуальных как для коммерческих систем, так и для академических разработок.

Первая группа связана с технологическими и экономическими барьерами коммерческих решений. Закрытость алгоритмической базы и проприетарные форматы данных создают зависимость от поставщика (vendor lock – in), при которой медицинская организация оказывается привязанной к оборудованию и программному обеспечению конкретного производителя. Это затрудняет гибкую

миграцию на альтернативные платформы и увеличивает затраты на модернизацию диагностической инфраструктуры.

Вторая проблема коммерческих решений связана с зависимостью от облачной инфраструктуры. Многие современные сервисы реализуются по модели программного обеспечения как услуги (SaaS) и требуют передачи медицинских данных на удаленные серверы. Это создает дополнительные риски информационной безопасности, усложняет выполнение требований законодательства о персональных данных и делает диагностический процесс зависимым от качества телекоммуникационных каналов. В условиях экстренной медицины такая зависимость может быть критичной.

Третья группа проблем относится к академическим и исследовательским моделям глубокого обучения. Несмотря на высокие опубликованные метрики, такие модели не всегда сохраняют качество на данных реальной клинической практики. Причиной является сдвиг области: обучающие наборы данных часто содержат более «чистые» и стандартизированные сигналы, тогда как реальные записи могут включать миографические артефакты, сетевую интерференцию, дрейф изолинии и другие искажения [8].

Четвертая проблема связана с интерпретируемостью. Нейросетевые модели часто воспринимаются как «черный ящик», поскольку врач не всегда может понять, какие именно элементы ЭКГ стали основанием для классификации. Методы визуального объяснения, например карты активации, могут быть нестабильными и не всегда указывают на конкретный морфологический предиктор: изменение амплитуды, длительности или формы отдельного зубца либо сегмента.

Пятая проблема заключается в отсутствии готового пользовательского интерфейса у многих исследовательских решений. Значительная часть современных алгоритмов реализована в виде программных скриптов или экспериментальных ноутбуков, требующих навыков программирования. Это делает их непригодными для непосредственного применения врачебным персоналом.

Шестая группа ограничений связана с регуляторными и правовыми барьерами. Академические прототипы, как правило, не имеют статуса зарегистрированного медицинского изделия и не могут легитимно использоваться для клинической диагностики.

Наконец, общей проблемой для многих подходов является демографическая и популяционная предвзятость. Модели могут демонстрировать снижение точности на группах пациентов, недостаточно представленных в обучающих данных. Это связано с дисбалансом выборок по возрасту, полу, этническим и клиническим признакам.

1.8 Постановка задачи

С учетом выявленных ограничений актуальной является разработка локальной автономной программной системы для автоматической классификации ЭКГ – сигналов. Такая система должна объединять преимущества современных нейросетевых методов с инструментами визуализации ЭКГ и наглядного представления результата анализа и быть пригодной для использования врачом в рамках существующего клинического процесса.

Целью разработки является создание программной системы, обеспечивающего загрузку цифровой ЭКГ – записи, ее предварительную обработку, классификацию, визуализацию ЭКГ и отображение результатов анализа. Система должна функционировать локально на персональном компьютере врача, без обязательной передачи медицинских данных во внешние облачные сервисы. В рамках данной работы локальная автономность понимается как выполнение анализа на рабочей станции пользователя без обращения к внешним API.

Для достижения указанной цели необходимо решить следующие задачи:

1 Проанализировать предметную область классификации ЭКГ – сигналов и определить основные этапы обработки электрокардиографических данных.

2 Рассмотреть существующие подходы к автоматическому анализу ЭКГ, включая классические методы, алгоритмы машинного обучения и нейросетевые архитектуры.

3 Выполнить обзор коммерческих и исследовательских систем анализа ЭКГ, выявить их преимущества и ограничения.

4 Проанализировать открытые наборы данных ЭКГ, используемые для обучения и валидации моделей, а также определить их методологические ограничения.

5 Обосновать необходимость локальной системы классификации ЭКГ, ориентированной на безопасность данных, удобство использования и наглядность представления результата.

6 Сформировать требования к программной системе поддержки принятия решений на основе анализа ЭКГ – сигналов.

7 Подготовить и гармонизировать данные, используемые для построения алгоритма классификации ЭКГ – сигналов.

8 Спроектировать алгоритм классификации и определить архитектурные решения, применяемые для анализа 12 – канальных ЭКГ.

9 Провести экспериментальную оценку нескольких архитектур классификации ЭКГ – сигналов, включая базовую, компактную и более емкие нейросетевые модели, и проанализировать качество полученных результатов.

Предполагается, что разрабатываемая система будет использоваться как вспомогательный инструмент поддержки принятия решений. Она рассматривается как исследовательский программный прототип и не предназначена для самостоятельной постановки окончательного клинического диагноза. Окончательное клиническое заключение при этом остается за врачом, а результат работы программы должен рассматриваться как дополнительная аналитическая информация.

1.9 Вывод по главе

В данной главе была рассмотрена предметная область классификации ЭКГ – сигналов и показано, что электрокардиограмма является важным источником диагностической информации о состоянии сердечно – сосудистой системы. Анализ клинического контекста подтвердил актуальность средств предварительной автоматизированной обработки ЭКГ, которые могут использоваться врачом как вспомогательный источник аналитической информации.

Рассмотрение традиционного и автоматизированного анализа ЭКГ позволило выделить основные этапы машинной обработки сигнала: предобработку, выделение морфологических элементов, извлечение признаков, классификацию и наглядное представление результата анализа. Эти этапы задают общую логику дальнейшего проектирования программной системы и алгоритма классификации.

Сравнение классических методов и подходов глубокого обучения показало, что первые отличаются высокой интерпретируемостью, но зависят от качества сегментации и заранее заданных признаков, тогда как нейросетевые модели способны извлекать сложные пространственно – временные закономерности непосредственно из сигнала и требуют отдельной проверки устойчивости на целевых данных.

Обзор предметной области, существующих подходов, программных систем и открытых наборов данных служит основой для формулирования требований к локальной системе поддержки принятия решений на основе анализа ЭКГ – сигналов.

Анализ открытых наборов данных ЭКГ, включая PTB – XL, PhysioNet/CinC Challenge, MIMIC и LUDB, показал их значимость для обучения и сравнения алгоритмов, а также выявил ограничения, связанные с репрезентативностью, неоднородностью оборудования, шумом аннотаций, дисбалансом классов, риском утечки данных и вопросами конфиденциальности.

Выявленные ограничения существующих подходов служат основанием для дальнейшей формализации требований к локальной автономной системе поддержки принятия решений. В последующих главах эти требования переходят в описание подготовки данных, проектирование алгоритма классификации и экспериментальную проверку моделей на задаче анализа ЭКГ – сигналов.

2 Требования к программной системе поддержки принятия решений на основе анализа ЭКГ – сигналов

2.1 Назначение и область применения программного продукта

Назначение программной системы заключается в автоматизации предварительного анализа 12 – канальных электрокардиограмм с применением методов цифровой обработки биомедицинских сигналов и нейросетевой классификации. Система предназначена для поддержки врача при первичной оценке ЭКГ – записей, ускорения обработки потока исследований и выделения записей, требующих первоочередного экспертного просмотра.

Основной прикладной задачей системы является трехклассовая классификация ЭКГ – записей по категориям «норма», «синусовые отклонения без явных патологических меток» и «патология». Модель возвращает вероятности трех целевых классов, а вероятность класса «патология» используется для приоритизации записей. Полученный результат предназначен для предварительного скрининга, сортировки записей и последующей экспертной интерпретации.

Область применения программной системы включает медицинские учреждения, кабинеты функциональной диагностики, кардиологические подразделения и иные организации, где выполняется регистрация и последующая интерпретация 12 – канальных ЭКГ. Система ориентирована на локальную эксплуатацию внутри медицинской организации и не требует передачи данных во внешние сервисы.

2.2 Условия эксплуатации системы

Программная система реализуется как автономное локальное приложение с веб – интерфейсом для персональных компьютеров под управлением 64 – битных операционных систем Windows 10 и Windows 11. Серверная часть запускается на рабочей станции пользователя, а взаимодействие с интерфейсом осуществляется через локальный браузер или настольную оболочку. Работа выполняется в локальном режиме: загрузка данных, предобработка сигнала, выполнение нейросетевой модели, визуализация результатов и формирование отчета осуществляются на ресурсах рабочей станции.

Для эксплуатации системы не требуется постоянное подключение к сети Интернет, внешним API, облачным сервисам или удаленным вычислительным ресурсам. Ввод данных осуществляется через файловую систему Windows: пользователь может вручную загружать ЭКГ – записи с локального диска, USB – накопителя или сетевой папки медицинской организации. Кроме того, система может работать в режиме автоматического мониторинга заданной директории, в которую кардиограф или связанное с ним программное обеспечение экспортирует ЭКГ – записи после регистрации и первичной обработки. В этом режиме приложение отслеживает появление новых файлов, выполняет их валидацию и добавляет корректные записи в очередь анализа, что позволяет сократить количество ручных действий пользователя и встроить систему в существующий рабочий процесс без прямой интеграции с медицинским оборудованием.

Вывод результатов выполняется в виде сохранения PDF – отчета в выбранную пользователем директорию. Целевая аппаратная конфигурация включает процессор уровня Intel Core i3 / i5 или выше, не менее 4 ГБ оперативной памяти и стандартное графическое окружение Windows. Наличие дискретной видеокарты не является обязательным, поскольку система должна обеспечивать выполнение основных функций на центральном процессоре; пиковое потребление памяти самим приложением ограничивается отдельно.

2.3 Пользователи системы и сценарии взаимодействия

Система ориентирована на две основные категории пользователей: средний медицинский персонал и врачей функциональной диагностики или кардиологов. Такое разделение обусловлено особенностями реального клинического процесса: запись ЭКГ часто выполняется медицинской сестрой или другим сотрудником среднего медицинского персонала, тогда как последующая интерпретация результатов и постановка клинического заключения относятся к зоне ответственности врача. В текущей версии ролевое разграничение прав доступа не предусматривается: указанные роли описывают сценарии использования системы, а не разные уровни функциональных полномочий в интерфейсе.

Средний медицинский персонал выполняет первичные операции с данными: проводит регистрацию ЭКГ на кардиографе, обеспечивает экспорт записи в цифровой формат, загружает ЭКГ – файлы в программную систему или контролирует их поступление в автоматически отслеживаемую папку. Также к его задачам относятся запуск автоматизированного анализа, контроль успешности обработки и проверка наличия сообщений об ошибках при некорректном формате или низком качестве записи.

Врач функциональной диагностики или кардиолог использует результаты работы системы на этапе экспертной интерпретации ЭКГ. Для него основное значение имеют итоговая классификация записи, вероятность патологического класса для приоритизации просмотра, интерактивный просмотр ЭКГ – сигнала и сформированный отчет.

Типовой сценарий работы начинается с регистрации ЭКГ средним медицинским персоналом и экспорта записи из кардиографа. Далее файл загружается в приложение вручную либо автоматически поступает в очередь анализа из заранее заданной директории. После загрузки система проверяет корректность входных данных: число отведений, частоту дискретизации, длительность записи и отсутствие недопустимых значений. Если файл

соответствует установленным требованиям, приложение выполняет предобработку сигнала и нейросетевую классификацию.

По завершении анализа врач получает итоговую метку «норма», «синусовые отклонения без явных патологических меток» или «патология», вероятность класса «патология». При необходимости формируется PDF – отчет, содержащий предварительный результат автоматизированного анализа.

2.4 Функциональные требования

Программная система должна обеспечивать полный цикл автоматизированной обработки ЭКГ – записи: от загрузки исходного файла до формирования результата и отчета. Основные функциональные требования включают импорт и техническую валидацию данных, автоматический мониторинг директории с ЭКГ – файлами, предобработку сигнала, нейросетевую классификацию, визуальную интерпретацию результатов, пакетную обработку, приоритизацию записей, интерактивный просмотр ЭКГ и генерацию отчетов.

Функция импорта и первичной валидации должна обеспечивать загрузку 12 – канальных ЭКГ – записей в формате XML с автоматической проверкой числа каналов, читаемости структуры файла, длительности записи и отсутствия недопустимых числовых значений. Поскольку целевой кардиограф может экспортировать сигнал с частотой 2000 Гц, система должна выполнять передискретизацию до 500 Гц и формировать входное окно 12 × 5000, соответствующее формату обученной модели. Отклоняются только записи, которые невозможно корректно прочитать или привести к указанному представлению без потери пригодности для анализа.

Функция автоматического мониторинга директории должна обеспечивать отслеживание заданной пользователем папки, в которую кардиограф или связанное с ним программное обеспечение автоматически экспортирует ЭКГ – записи после регистрации. При появлении нового XML – файла система должна выполнять его первичную проверку, исключать повторную обработку уже проанализированных записей и добавлять корректные файлы в очередь анализа.

Данная функция позволяет организовать полуавтоматический поток обработки ЭКГ без прямой интеграции с кардиографом или медицинской информационной системой.

Функция предобработки должна выполнять подготовку сигнала к подаче на вход модели классификации. Она включает проверку структуры и длительности записи, контроль недопустимых значений, передискретизацию до 500 Гц, формирование модельного окна 12 × 5000 и расчет показателей качества сигнала. Дополнительная фильтрация может использоваться для вспомогательной визуализации или оценки качества, но не является основным входом финальной модели.

Функция нейросетевой классификации должна автоматически формировать трехклассовый вердикт по 12 – канальной записи ЭКГ. На выходе формируются вероятности по целевым классам и итоговый вердикт. Вероятность класса «патология» используется для приоритизации записей. В системе предусматривается пороговая постобработка по схеме argmax + настраиваемый порог патологического класса: если максимальная вероятность относится к непатологическому классу, но вероятность класса «патология» превышает заданный пользователем или конфигурацией порог, запись может быть дополнительно помечена как требующая приоритетного внимания. Такой механизм служит эксплуатационной настройкой чувствительности и не изменяет обученные вероятности модели.

Функция интерпретации решений модели в текущей версии должна предоставлять итоговый вердикт, вероятности классов и сведения, необходимые для экспертной оценки результата. Построение тепловых карт значимости и определение наиболее значимых отведений рассматриваются как перспективное направление развития, поскольку требуют отдельной методики, проверки устойчивости и экспертной клинической оценки.

Функция интерактивной визуализации должна предоставлять пользователю возможность просматривать графики всех 12 отведений, изменять масштаб по временной и амплитудной осям, перемещаться по записи и включать

или отключать отображение отдельных отведений. Отображение тепловых карт значимости не входит в завершенный объем текущей реализации и относится к дальнейшему развитию интерфейса.

Функция пакетной обработки должна обеспечивать последовательный анализ нескольких файлов из выбранной директории без необходимости ручного запуска каждого исследования. В интерфейсе должны отображаться общий ход обработки, состояние каждой записи и количество обработанных, ожидающих и ошибочных файлов. Механизмы сохранения очереди после перезапуска, отмены обработки и расширенного управления ошибками очереди рассматриваются как элементы, требующие дальнейшей проработки.

Функция приоритизации должна автоматически маркировать записи с высокой вероятностью патологии и располагать их в начале очереди просмотра. Для каждой записи должны отображаться вероятность патологического класса и уровень уверенности модели. Приоритизация не должна скрывать остальные записи и не отменяет необходимость просмотра всех исследований.

Функция формирования отчетов должна обеспечивать создание PDF – документа на русском языке. Отчет должен содержать дату и время анализа, имя исходного файла, версию модели, вариант обработки, использованный порог классификации, статус качества сигнала, предварительный вердикт системы, вероятность патологии, графики 12 отведений и краткое техническое резюме обработки. Добавление карт значимости в отчет рассматривается как перспективное расширение после отдельной валидации методов объяснимости.

Система должна поддерживать различные виды сортировки обработанных файлов по классам, убыванию или возрастанию вероятность патологии, по названию файла, а также иметь фильтр по принципу «просмотрено» и «не просмотрено».

2.5 Нефункциональные требования

Нефункциональные требования определяют качественные характеристики программной системы, включая производительность, надежность, точность классификации, безопасность, удобство использования, совместимость, переносимость, сопровождаемость и возможность дальнейшего расширения.

2.5.1 Требования к производительности

Все временные показатели задаются для целевой конфигурации оборудования: процессор уровня Intel Core i3 / i5, 4 ГБ оперативной памяти, отсутствие GPU, операционная система Windows 10 или Windows 11 в 64 – битной редакции. Для первичной обработки одной 10 – секундной ЭКГ – записи, включая загрузку, валидацию, передискретизацию, формирование модельного окна и подготовку визуализации, целевым проектным ориентиром является выполнение этапа в пределах 2 секунд.

Для выполнения нейросетевой модели на CPU целевым ориентиром также является время до 2 секунд. Генерация PDF – отчета с графиками ЭКГ и текстовым резюме рассматривается как отдельный этап с ориентиром до 2 секунд. Полный цикл с формированием отчета должен стремиться укладываться в 6 секунд для одной записи. Эти значения используются как проектные критерии интерактивности исследовательского прототипа, а не как внешняя медицинская норма.

2.5.2 Требования к надежности и отказоустойчивости

Система должна устойчиво работать как при обработке единичных записей, так и при пакетном анализе очереди файлов. При обнаружении некорректного формата, недостаточной длительности записи, критически низкого качества сигнала или недопустимых значений анализ соответствующего файла должен прерываться без аварийного завершения приложения.

Пользователь должен получать диагностическое сообщение на русском языке с указанием причины отклонения файла. При пакетной обработке ошибка в одном файле не должна останавливать анализ остальных записей. Все предупреждения, ошибки и ключевые события должны фиксироваться в журнале приложения; причина отклонения файла должна сохраняться в журнале, а отклоненная запись не должна включаться в отчет как успешно обработанная.

При возникновении внутренней ошибки или нехватки ресурсов система должна завершать текущую операцию в штатном режиме и сохранять техническую информацию о сбое в журнале событий приложения без записи персональных данных пациента.

2.5.3 Требования к точности классификации

Качество классификации определяется с учетом клинического приоритета минимизации риска пропуска патологических изменений. На независимых валидационных данных, соответствующих предполагаемым условиям эксплуатации, модель должна демонстрировать для класса «патология» полноту (recall) не ниже 0,80 и точность положительных предсказаний (precision) не ниже 0,75. Значение recall 0,80 рассматривается как минимально приемлемый уровень полноты: при более низком результате риск пропуска патологических записей становится слишком высоким для вспомогательного скринингового инструмента. При этом выбранный порог считается реалистичным с учетом разнородности источников данных, различий в разметке, дисбаланса классов и ограничений открытых наборов ЭКГ, описанных в главе о подготовке данных. Для трехклассовой оценки дополнительно рассчитываются macro – F1 и balanced accuracy; с учетом сложности задачи для прототипа реалистичным целевым диапазоном этих метрик считается 0,75 – 0,85.

Пороговое значение для показателя вероятности патологических изменений должно быть доступно для настройки. Это позволяет изменять соотношение между полнотой и точностью положительных предсказаний в

зависимости от сценария применения системы: скрининга, приоритизации очереди исследований или вспомогательного анализа спорных записей.

2.5.4 Требования к безопасности

Система должна функционировать в автономном локальном режиме без обращения к внешним API, облачным платформам, интернет – ресурсам и удаленным сервисам. ЭКГ – записи, результаты анализа и сформированные отчеты не должны передаваться за пределы рабочей станции. Такой подход снижает риски несанкционированной передачи медицинских данных и упрощает эксплуатацию системы в изолированном контуре медицинской организации.

Обеспечение полного соответствия требованиям законодательства о персональных данных, включая Федеральный закон № 152 – ФЗ «О персональных данных», относится к зоне ответственности медицинской организации, эксплуатирующей программную систему. К таким мерам относятся настройка прав доступа к рабочей станции, защита локальной сети, регламенты хранения и передачи файлов, резервное копирование, антивирусная защита и контроль доступа пользователей.

Система не должна требовать наличия персональных идентификаторов пациента в загружаемых ЭКГ – файлах, формируемых отчетах или журнале событий приложения. К таким идентификаторам относятся ФИО, дата рождения, номер медицинской карты и иные данные, позволяющие напрямую установить личность пациента. Если исходный файл ЭКГ содержит подобные сведения, система не должна использовать их как обязательное условие для выполнения анализа.

Временные файлы, создаваемые в процессе анализа, должны автоматически удаляться после завершения обработки или при штатном закрытии приложения. При аварийном завершении работы очистка временных данных должна выполняться при следующем запуске системы.

2.5.5 Требования к удобству использования

Пользовательский интерфейс должен быть полностью русскоязычным, не содержать неоднозначной терминологии и быть понятным для медицинского персонала без специальных навыков программирования. Пользователь должен иметь возможность запустить анализ и получить основной результат не более чем за 3 – 4 действия интерфейса, включая выбор файла, запуск обработки и просмотр итогового вердикта.

Все сообщения об ошибках, предупреждения, элементы управления и отчеты должны формулироваться в медицински понятном виде, без избыточных технических подробностей. Во время анализа система должна отображать ход выполнения и текущую стадию обработки: загрузку данных, предобработку, выполнение модели, построение визуализации или формирование отчета.

Врач должен иметь возможность быстро оценить исходную форму ЭКГ, итоговый вердикт, вероятности классов, показатели ритма и признаки качества сигнала.

2.5.6 Требования к совместимости и переносимости

Система должна работать в типовой клинической ИТ – среде без сложной настройки окружения. Поддерживаются 64 – битные версии Windows 10 и Windows 11 на процессорах архитектуры x86 – 64 уровня Intel Core i3 и выше. Наличие дискретной видеокарты не требуется.

Дистрибутив должен поставляться в виде автономной сборки, не требующей от пользователя ручной установки Python, сторонних библиотек или специальных прав администратора, если это не предусмотрено политиками конкретной организации. Конкретный размер дистрибутива определяется выбранным способом упаковки и составом включенных библиотек.

2.5.7 Требования к сопровождаемости и расширяемости

Архитектура приложения должна иметь модульную структуру с четким разделением ответственности между компонентами загрузки и валидации данных, предобработки сигнала, нейросетевой классификации, визуализации, интерпретации и формирования отчетов. Замена или обновление одного модуля не должны требовать существенной переработки остальных компонентов.

Исходный код должен соответствовать принятым правилам оформления и документирования. Публичные функции и классы должны сопровождаться строками документации, а значимые действия пользователя, системные события, предупреждения и ошибки должны фиксироваться в журнале событий приложения.

Система должна быть подготовлена к дальнейшему развитию, например к расширению набора диагностических категорий, обновлению весов модели и состава отчета без изменения базовых принципов работы приложения.

2.6 Требования к входным данным

Основным типом входных данных являются 12 – канальные ЭКГ – записи в формате XML, экспортированные из программного обеспечения целевого электрокардиографа. В экспериментальном контуре модель обучалась на фрагментах 12 × 5000 при частоте 500 Гц; поэтому эксплуатационный контур должен приводить входную запись к этому представлению перед нейросетевой классификацией.

Целевой кардиограф может экспортировать записи с частотой дискретизации 2000 Гц, поэтому система должна выполнять передискретизацию до 500 Гц и выделять 10 – секундное окно 12 × 5000, соответствующее входу обученной модели. Запись отклоняется только в случаях, когда невозможно корректно прочитать XML, обнаружено неверное число отведений, недостаточная длительность после приведения частоты, пустые массивы, NaN,

Inf или поврежденные участки структуры файла, препятствующие обработке сигнала.

При валидации система должна проверять число отведений, исходную частоту дискретизации, длительность записи, целостность данных и базовые показатели качества сигнала. Файлы, не соответствующие установленным требованиям, не должны передаваться на этап нейросетевой классификации; причина отказа должна сохраняться в журнале приложения.

Статическими системными данными являются предобученные веса нейронной сети и конфигурационные параметры приложения. Пользователь не должен выполнять отдельную загрузку этих данных при стандартной эксплуатации системы.

2.7 Требования к результатам анализа ЭКГ – сигналов

Результатом классификации должна быть структурированная информация, пригодная для последующего анализа врачом: итоговый вердикт, вероятности целевых классов, вероятность класса «патология» для приоритизации и уровень уверенности модели.

Кроме численного результата, перспективным направлением развития системы является визуальное объяснение решения модели, например с использованием тепловых карт значимости или других методов. Такая функция необходима для повышения интерпретируемости, однако ее полноценная реализация требует отдельной методики построения карт, проверки устойчивости результатов и экспертной клинической оценки.

Результаты классификации должны отображаться в пользовательском интерфейсе и включаться в PDF – отчет. Формулировки результата должны подчеркивать вспомогательный характер автоматического анализа и необходимость экспертной интерпретации врачом.

2.8 Требования к пользовательскому интерфейсу

Пользовательский интерфейс должен быть доступен в локальном браузере или настольной оболочке и работать в составе автономного приложения на русском языке. Главное окно должно содержать панель управления, область визуализации ЭКГ, строку состояния и элементы отображения хода обработки.

Панель управления должна предоставлять функции выбора и загрузки файлов, запуска анализа, настройки порога классификации, просмотра результатов и сохранения отчета. Желательна поддержка механизма перетаскивания файлов для быстрого добавления файлов в рабочую область приложения.

Область визуализации должна отображать все 12 отведений ЭКГ с возможностью масштабирования по временной и амплитудной осям, а также перемещения по записи.

Интерфейс должен обеспечивать адаптивное масштабирование при различных разрешениях экрана и оставаться читаемым на стандартных мониторах, используемых в медицинских учреждениях. Все сообщения, уведомления и подписи элементов должны быть единообразными и стилистически согласованными.

2.9 Требования к программным интерфейсам

В текущей версии система проектируется как полностью автономное приложение и не предоставляет внешних программных интерфейсов для интеграции с медицинскими информационными системами, ЕГИСЗ, облачными платформами или сторонними сервисами. Такое ограничение снижает риски несанкционированной передачи данных за пределы рабочей станции.

Взаимодействие между внутренними модулями должно осуществляться через унифицированные внутренние форматы данных приложения: числовые массивы ЭКГ – сигналов, структуры с метаданными записи и словари с результатами анализа. Модуль предобработки принимает исходный массив ЭКГ

– сигнала и возвращает представления, приведенные к эксплуатационному формату модели: сигнал после передискретизации до 500 Гц, модельное окно 12 × 5000 и показатели качества. Модуль классификации принимает подготовленные данные и возвращает вероятности по трем классам, итоговую метку класса, показатель вероятности патологических изменений и дополнительные показатели уверенности модели. Модуль отчетности получает итоговые результаты анализа, графические материалы и путь сохранения файла.

Взаимодействие с внешними устройствами ограничивается файловым обменом. Прямое программное подключение к кардиографам и иному медицинскому оборудованию в текущей версии не предусматривается: данные поступают в систему только в виде файлов, предварительно экспортированных устройством или его программным обеспечением.

2.10 Ограничения и допущения

Программная система предназначена для работы только в 64 – битных версиях Windows 10 и Windows 11 на компьютерах с процессорами архитектуры x86 – 64 и объемом оперативной памяти не менее 4 ГБ. Использование GPU не является обязательным. Поддержка других операционных систем, многопользовательского режима и сетевого развертывания в текущей версии не предусматривается.

Формат входных данных ограничен 12 – канальными ЭКГ – записями в формате XML, экспортированными из программного обеспечения целевого электрокардиографа. Допускается исходная частота дискретизации, отличающаяся от входного формата модели, поскольку эксплуатационный контур выполняет передискретизацию до 500 Гц и формирует окно 12 × 5000. Записи с поврежденной структурой, некорректным числом каналов, недостаточной длительностью после приведения частоты или недопустимыми значениями не подлежат анализу.

Система является вспомогательным инструментом предварительного скрининга и не имеет статуса медицинского изделия. Она не предназначена для

самостоятельной постановки окончательного клинического диагноза. Окончательная интерпретация ЭКГ и принятие медицинских решений остаются ответственностью врача.

В рамках текущей версии не реализуются автоматическая интеграция с медицинскими информационными системами, обновление модели через сеть, централизованное хранение результатов и одновременная работа нескольких пользователей.

При формировании требований принимается допущение, что заказчик или медицинская организация предоставит обезличенные клинические ЭКГ – записи для приемочной валидации системы. Также предполагается, что открытые обучающие наборы данных, использованные при подготовке модели, в достаточной степени отражают спектр патологий целевой клинической популяции.

Предполагается, что ЭКГ – запись после приведения к частоте 500 Гц имеет достаточную длительность и качество для выполнения классификации. Основной эксплуатационный вход модели формируется из исходного сигнала в сохраненных амплитудах после технического приведения к формату 12 × 5000; дополнительные процедуры оценки качества и опциональная фильтрация используются как вспомогательные механизмы и не подменяют основной вход финальной модели.

2.11 Критерии качества и приемки программного продукта

Качество программного продукта оценивается по совокупности функциональных, диагностических, эксплуатационных и пользовательских критериев. Система считается соответствующей требованиям только при одновременном выполнении основных условий приемки.

Функциональная корректность подтверждается успешным выполнением полного цикла обработки: загрузки и валидации входных файлов, предобработки ЭКГ – сигнала, нейросетевой классификации, пакетной обработки,

протоколирования событий, визуализации исходной ЭКГ и формирования PDF – отчета.

Диагностические характеристики модели должны быть подтверждены на независимой тестовой или валидационной выборке, соответствующей предполагаемым условиям эксплуатации системы. При приемке проверяется, что полученные значения recall, precision, macro – F1 и balanced accuracy соответствуют порогам, установленным в требованиях к точности классификации.

Производительность подтверждается тем, что первичная обработка одной 10 – секундной ЭКГ – записи, нейросетевой вывод модели и генерация итогового PDF – отчета соответствуют проектным ориентирам интерактивности: до 2 секунд на каждый из трех этапов и до 6 секунд на полный цикл с формированием отчета для одной записи.

Надежность подтверждается отсутствием критических сбоев при непрерывной пакетной обработке не менее 100 записей подряд, а также корректной отбраковкой некорректных и зашумленных файлов без остановки всего процесса анализа. Объем 100 записей выбран как демонстрационный стресс – тест для проверки устойчивости очереди обработки, журналирования ошибок и отсутствия аварийного завершения приложения при типовой пакетной нагрузке. Интерпретируемость на основе Grad – CAM и других методов объяснимого ИИ рассматривается как перспективное направление и не используется как критерий приемки завершенной реализации.

Полная автономность подтверждается проверкой работы приложения на изолированной от сети рабочей станции. Приложение должно запускаться и выполнять все функции без обращения к интернет – ресурсам, внешним API, удаленным сервисам и облачным платформам.

PDF – отчеты должны соответствовать утвержденному шаблону, корректно отображать кириллицу, содержать читаемые графики с достаточным разрешением и без ошибок заполнять обязательные поля, определенные функциональными требованиями.

Дистрибутив должен поставляться в виде автономного .exe – файла, успешно запускающегося на чистой системе Windows 10 или Windows 11 без установленного Python и сторонних библиотек. При приемке также проверяется наличие руководства пользователя и технической документации с описанием архитектуры и основных модулей системы.

Готовность прототипа к демонстрационной или предварительной апробации может дополнительно подтверждаться проверкой в условиях медицинского учреждения на перспективном объеме не менее 500 ЭКГ – записей; этот показатель рассматривается как критерий дальнейшей апробации, а не как обязательное условие завершения работы.

2.12 Вывод по главе

Во второй главе сформулированы требования к программной системе классификации ЭКГ, предназначенной для локального автоматизированного анализа 12 – канальных электрокардиограмм. Определены назначение и область применения программного продукта, условия его эксплуатации, категории пользователей и основные сценарии взаимодействия.

Сформирован перечень функциональных требований, включающий импорт и валидацию ЭКГ – записей, предобработку сигнала, нейросетевую классификацию, пакетную обработку, приоритизацию исследований, интерактивную визуализацию ЭКГ и генерацию PDF – отчетов. Также определены нефункциональные требования к производительности, надежности, точности, безопасности, удобству использования, совместимости, переносимости, сопровождаемости и расширяемости системы. Методы объяснимого ИИ и тепловые карты значимости выделены как направление дальнейшего развития.

3 Подготовка данных и проектирование алгоритма классификации ЭКГ – сигналов

3.1 Описание используемых наборов данных

Для подготовки обучающей выборки в работе использованы четыре открытых набора данных 12 – канальных электрокардиограмм: PTB – XL, A large scale 12 – lead electrocardiogram database for arrhythmia study, в дальнейшем обозначаемый как Ningbo, MIMIC – IV – ECG и Georgia 12 – lead ECG Challenge Database. Они были выбраны не как изолированные источники, а как взаимодополняющие части единой экспериментальной базы: каждый набор содержит стандартные отведения ЭКГ, но отличается объемом, происхождением, принципами аннотирования и клиническим контекстом.

Общей особенностью выбранных наборов является ориентация на задачу автоматической интерпретации 12 – канальных ЭКГ. Большинство записей имеют длительность 10 секунд и частоту дискретизации 500 Гц, что соответствует распространенному формату диагностической ЭКГ. Данные представлены в формате WFDB или в совместимой с ним структуре, где сигнал сопровождается заголовочным файлом с техническими параметрами записи, демографическими сведениями и диагностической информацией. Это позволяет использовать единый конвейер загрузки, предварительной обработки и формирования признакового пространства.

При этом наборы данных не являются полностью однородными. Они были собраны в разных странах, медицинских учреждениях и клинических условиях, что отражается в составе пациентов, распределении диагнозов и особенностях зарегистрированных ЭКГ – сигналов. Дополнительно наборы различаются по схемам аннотирования: например, в PTB – XL используется стандарт SCP – ECG, тогда как в Ningbo и Georgia диагнозы представлены с использованием кодов SNOMED CT. Эти различия необходимо учитывать при подготовке данных, поскольку перед обучением модели требуется привести диагностические метки к единому представлению. Каждый набор данных вносит вклад не только в

увеличение объема выборки, но и в расширение ее клинического и популяционного разнообразия.

3.1.1 PTB – XL

PTB – XL выступает в работе как основной эталонный клинический набор с хорошо структурированной экспертной разметкой. Он включает 21 799 записей от 18 869 пациентов. Важным преимуществом PTB – XL является наличие не только самих ЭКГ – сигналов, но и подробных метаданных: возраста, пола, параметров записи, сведений о качестве сигнала и рекомендованных разбиений на обучающую, валидационную и тестовую части.

Разметка PTB – XL выполнена по стандарту SCP – ECG и охватывает диагностические, ритмологические и морфологические утверждения. Для данной работы это делает набор удобным источником для обучения модели на клинически интерпретируемых классах и для проверки корректности этапов предобработки, поскольку структура данных и схема аннотаций хорошо документированы.

3.1.2 Ningbo

Набор Ningbo используется как крупный источник данных, ориентированный преимущественно на изучение аритмий и сопутствующих сердечно – сосудистых состояний. Он содержит 45 152 записи пациентов, собранные при участии Chapman University, Shaoxing People’s Hospital и Ningbo First Hospital. В отличие от PTB – XL, данный набор сильнее сфокусирован на ритмах и нарушениях проводимости.

Диагностическая разметка включает основной ритм и дополнительные состояния, например преждевременные желудочковые сокращения, блокаду правой или левой ножки пучка Гиса и предсердные экстрасистолы. Разметка выполнялась врачами с последующей проверкой, а диагностические обозначения

приведены к кодам SNOMED CT. В общей выборке Ningbo повышает представленность аритмий и расширяет спектр патологических классов.

3.1.3 MIMIC – IV – ECG

MIMIC – IV – ECG является самым крупным из используемых источников: он содержит приблизительно 800 000 диагностических ЭКГ почти от 160 000 уникальных пациентов. Записи были получены в Beth Israel Deaconess Medical Center в рамках рутинной клинической практики и связаны с базой MIMIC – IV.

Главная ценность этого набора заключается в его масштабе и клиническом контексте. Помимо данных временных рядов, для записей доступны машинные измерения, идентификаторы исследований и информация для связи с кардиологическими отчетами. Поэтому MIMIC – IV – ECG используется как источник, позволяющий повысить объем обучающих данных и приблизить экспериментальную постановку к условиям реальной больничной среды.

3.1.4 Georgia 12 – lead ECG Challenge Database

Georgia 12 – lead ECG Challenge Database используется в работе как часть набора «Classification of 12 – lead ECGs: The PhysioNet/Computing in Cardiology Challenge 2020».

Обучающая часть Georgia содержит 10 344 записи: 5 551 запись относится к пациентам мужского пола и 4 793 – к пациентам женского пола. Все записи имеют длительность 10 секунд и частоту дискретизации 500 Гц. Диагнозы представлены кодами SNOMED CT.

Для данной работы Georgia важен как независимый источник, представляющий популяцию пациентов юго – восточной части США. Он дополняет PTB – XL, собранный в Германии, Ningbo, сформированный на базе китайских медицинских учреждений, и MIMIC – IV – ECG, полученный в американском госпитальном центре. Благодаря этому включение Georgia повышает географическое и демографическое разнообразие данных и позволяет

уменьшить зависимость модели от особенностей одного медицинского учреждения. Используемые наборы данных перечислены в таблице 1.

Таблица 1 – Характеристика используемых наборов данных

Набор данных	**Объем и происхождение**	**Особенности разметки**
PTB – XL	21 799 записей от 18 869 пациентов; клинические ЭКГ, Германия.	SCP – ECG; диагностические, ритмологические и морфологические утверждения; метаданные качества сигнала.
Ningbo	45 152 записи; данные Shaoxing People's Hospital и Ningbo First Hospital, Китай, опубликованы при участии Chapman University.	Ритмы и дополнительные сердечно – сосудистые состояния; привязка к SNOMED CT; врачебная проверка разметки.
MIMIC – IV – ECG	Около 800 000 записей почти от 160 000 пациентов; Beth Israel Deaconess Medical Center, США, связь с MIMIC – IV.	Машинные измерения, идентификаторы исследований и ссылки на кардиологические отчеты при их наличии.
Georgia	10 344 записи; региональная выборка юго – восточной части США; часть PhysioNet/CinC Challenge 2020.	Коды SNOMED CT

3.2 Форматы хранения ЭКГ – сигналов: WFDB

В используемых наборах данных исходные ЭКГ – сигналы поставляются в формате WFDB – WaveForm DataBase. Данный формат является распространенным стандартом хранения физиологических сигналов и широко используется в наборах данных, размещенных на платформе PhysioNet.

Название WFDB используется как для формата хранения сигналов, так и для программной библиотеки, предназначенной для работы с такими файлами. В

данном подразделе WFDB рассматривается прежде всего как формат исходных записей, общий для используемых PhysioNet – наборов данных.

Одна запись в формате WFDB обычно представлена набором связанных файлов с одинаковым именем, но разными расширениями. Обязательным элементом является заголовочный файл с расширением .hea. Он содержит описание записи: идентификатор, число каналов, частоту дискретизации, количество отсчетов, названия отведений и параметры масштабирования сигнала. Сами значения ЭКГ хранятся в отдельном файле данных. В зависимости от конкретного набора данных это может быть бинарный файл .dat или файл MATLAB – формата .mat.

Пример структуры одной записи:

record_name.hea – заголовочный файл с описанием записи;

record_name.dat – файл с отсчетами ЭКГ – сигнала.

Или:

record_name.hea – заголовочный файл с описанием записи;

record_name.mat – файл с массивом ЭКГ – сигнала.

Первая строка .hea – файла содержит общую информацию о записи: имя, количество сигналов, частоту дискретизации и общее число отсчетов. Далее обычно перечисляются строки отдельных каналов ЭКГ, включая стандартные отведения I, II, III, aVR, aVL, aVF и V1 – V6. В конце файла, в зависимости от набора данных, могут находиться комментарии, начинающиеся с символа #; в них часто указываются возраст пациента, пол, диагнозы, клинические коды и другие дополнительные сведения. Содержание заголовочных файлов всех четырех датасетов представлены на рисунке 1.

12 lead

```
JS00105 12 500 5000
JS00105.mat 16+24 1000/mV 16 0 98 -17508 0 I
JS00105.mat 16+24 1000/mV 16 0 283 22311 0 II
JS00105.mat 16+24 1000/mV 16 0 185 -25808 0 III
JS00105.mat 16+24 1000/mV 16 0 -190 -29417 0 aVR
JS00105.mat 16+24 1000/mV 16 0 -44 -1761 0 aVL
JS00105.mat 16+24 1000/mV 16 0 234 25389 0 aVF
JS00105.mat 16+24 1000/mV 16 0 -761 30169 0 V1
JS00105.mat 16+24 1000/mV 16 0 -1337 25240 0 V2
JS00105.mat 16+24 1000/mV 16 0 -1396 15552 0 V3
JS00105.mat 16+24 1000/mV 16 0 -859 4972 0 V4
JS00105.mat 16+24 1000/mV 16 0 -273 -13683 0 V5
JS00105.mat 16+24 1000/mV 16 0 -127 -24494 0 V6
#Age: 58
#Sex: Male
#Dx: 164889003
#Rx: Unknown
#Hx: Unknown
#Sx: Unknown
```

Georgia

```
E00001.mat 12 500 5000 05-May-2020 14:50:55
E00001.mat 16+24 4880/mV 16 0 136 -28477 0 I
E00001.mat 16+24 4880/mV 16 0 87 545 0 II
E00001.mat 16+24 4880/mV 16 0 -48 29413 0 III
E00001.mat 16+24 4880/mV 16 0 -112 -18879 0 aVR
E00001.mat 16+24 4880/mV 16 0 92 -29015 0 aVL
E00001.mat 16+24 4880/mV 16 0 19 -17384 0 aVF
E00001.mat 16+24 4880/mV 16 0 -39 10780 0 V1
E00001.mat 16+24 4880/mV 16 0 58 -22686 0 V2
E00001.mat 16+24 4880/mV 16 0 87 -24025 0 V3
E00001.mat 16+24 4880/mV 16 0 97 -26617 0 V4
E00001.mat 16+24 4880/mV 16 0 87 21518 0 V5
E00001.mat 16+24 4880/mV 16 0 78 25805 0 V6
#Age: NaN
#Sex: Female
#Dx: 426783006
#Rx: Unknown
#Hx: Unknown
#Sx: Unknown
```

PTB-XL

```
03001_hr 12 500 5000
03001_hr.dat 16 1000.0(0)/mV 16 0 5 17899 0 I
03001_hr.dat 16 1000.0(0)/mV 16 0 175 61932 0 II
03001_hr.dat 16 1000.0(0)/mV 16 0 170 44009 0 III
03001_hr.dat 16 1000.0(0)/mV 16 0 -90 57632 0 AVR
03001_hr.dat 16 1000.0(0)/mV 16 0 -83 19214 0 AVL
03001_hr.dat 16 1000.0(0)/mV 16 0 172 52348 0 AVF
03001_hr.dat 16 1000.0(0)/mV 16 0 215 11532 0 V1
03001_hr.dat 16 1000.0(0)/mV 16 0 -175 60753 0 V2
03001_hr.dat 16 1000.0(0)/mV 16 0 -1595 30371 0 V3
03001_hr.dat 16 1000.0(0)/mV 16 0 -265 9583 0 V4
03001_hr.dat 16 1000.0(0)/mV 16 0 -245 14631 0 V5
03001_hr.dat 16 1000.0(0)/mV 16 0 -485 46866 0 V6
```

MIMIC

```
40689238 12 500 5000 08:44:00 23/07/2180
40689238.dat 16 200.0(0)/mV 16 0 -31 9616 0 I
40689238.dat 16 200.0(0)/mV 16 0 2 35318 0 II
40689238.dat 16 200.0(0)/mV 16 0 30 10704 0 III
40689238.dat 16 200.0(0)/mV 16 0 14 40438 0 aVR
40689238.dat 16 200.0(0)/mV 16 0 15 17944 0 aVF
40689238.dat 16 200.0(0)/mV 16 0 -28 7176 0 aVL
40689238.dat 16 200.0(0)/mV 16 0 8 34084 0 V1
40689238.dat 16 200.0(0)/mV 16 0 8 8828 0 V2
40689238.dat 16 200.0(0)/mV 16 0 2 30926 0 V3
40689238.dat 16 200.0(0)/mV 16 0 8 42230 0 V4
40689238.dat 16 200.0(0)/mV 16 0 16 46797 0 V5
40689238.dat 16 200.0(0)/mV 16 0 4 31544 0 V6
# <subject_id>: 10000032
```

Рисунок 1 – Структура заголовочного файла WFDB – записи

В данной работе WFDB выступает как базовый формат исходных ЭКГ – записей: он хранит многоканальный временной ряд вместе с техническими и, в части наборов, клиническими метаданными. Практическое чтение этих записей и преобразование их в рабочий числовой формат описаны далее в подразделе технической стандартизации.

3.3 Анализ структуры и семантики наборов данных

Перед предварительной обработкой ЭКГ – сигналов был выполнен анализ того, как в каждом наборе данных организованы записи и диагностические аннотации. Несмотря на то, что все используемые источники содержат 12 – канальные ЭКГ, их нельзя напрямую объединить в одну обучающую выборку без дополнительного анализа. Различия касаются не только объема данных, но и способа хранения метаданных, принципов именования записей и представления диагнозов.

В данной работе под структурой набора данных понимается организация его файлов и связей между ними: где хранится сигнал, где находится заголовочный файл, какие поля описывают запись и каким образом можно связать ЭКГ с пациентом или исследованием. Под семантикой понимается смысл диагностических и служебных полей: какие значения являются диагнозами, какие используются как идентификаторы, какие поля относятся к демографическим данным, а какие не участвуют в формировании целевой переменной.

Первичный анализ выполнялся на уровне заголовочных файлов WFDB и связанных с ними таблиц метаданных. Для каждой записи определялись технические характеристики, доступные источники демографической информации и способ получения диагностических обозначений. Поэтому .hea – файл рассматривался не только как техническое описание сигнала, но и как возможный источник части метаданных.

Однако диагностическая информация в разных наборах данных хранится неодинаково. В Georgia и Ningbo диагнозы представлены непосредственно в заголовочных файлах в поле Dx и записаны в виде кодов SNOMED CT. Для PTB – XL основная разметка находится не в .hea – файлах, а в отдельной таблице метаданных, где каждому идентификатору ЭКГ соответствует набор диагностических утверждений SCP – ECG. Для MIMIC – IV – ECG диагностические метки также не извлекаются напрямую из заголовочного файла: в .hea – файле содержится служебная информация о записи, включая идентификатор пациента, например строка # <subject_id>: 10000635. Этот идентификатор используется вместе с идентификатором исследования study_id для сопоставления ЭКГ – записи с внешним файлом диагностических аннотаций. Единый формат хранения сигналов не означает единого способа получения диагнозов: сами ЭКГ – записи могут быть считаны по общей схеме, однако целевые метки формируются из разных источников. Именно это различие определяет необходимость отдельного этапа гармонизации диагностических меток.

Также на данном этапе учитывалась многометочная природа задачи. В ЭКГ – записи может быть указан не один диагноз, а несколько состояний одновременно. Например, нарушение ритма может сочетаться с нарушением проводимости или другими изменениями. Поэтому исходные диагностические поля рассматривались как наборы меток, а не как единственный класс записи.

В результате анализа для каждой ЭКГ – записи определялись три группы данных: сигнал, метаданные и исходные диагностические аннотации. Сигнал используется как вход модели, метаданные позволяют контролировать источник и технические параметры записи, а исходные аннотации служат основой для формирования целевых классов.

Такой анализ необходим для корректной гармонизации диагностических меток и технической стандартизации сигналов, поскольку эти процедуры должны учитывать особенности каждого набора данных.

3.4 Гармонизация диагностических меток

Гармонизация диагностических меток направлена на приведение разнородных диагностических аннотаций к единому представлению. Необходимость такой процедуры связана с тем, что используемые наборы данных имеют разные системы представления диагнозов. В PTB – XL диагностические утверждения представлены в виде акронимов SCP – ECG и связанных с ними кодов, в Ningbo и Georgia – в виде кодов SNOMED CT, а в MIMIC – IV – ECG аннотации представлены преимущественно в текстовом формате на основе машинных диагностических меток. Поэтому прямое объединение таких данных без предварительного преобразования привело бы к неоднозначной интерпретации классов.

В качестве единого формата представления диагностических меток в данной работе был выбран текстовый формат. Такое решение связано с тем, что MIMIC – IV – ECG является самым крупным из используемых наборов данных и составляет значительную часть общей выборки. Поскольку диагностические аннотации MIMIC – IV – ECG представлены в текстовом виде, приведение

остальных наборов данных к аналогичному формату позволило сформировать единое пространство меток и упростить последующее объединение записей.

Гармонизация выполнялась поэтапно. Для PTB – XL исходные диагностические обозначения сначала рассматривались на уровне акронимов SCP – ECG, содержащихся в поле scp_codes. Далее эти акронимы сопоставлялись с соответствующими SCP – ECG – описаниями и диагностическими категориями. После этого, при наличии соответствия, SCP – ECG – утверждения приводились к кодам SNOMED CT, что позволяло использовать общую медицинскую терминологию для сопоставления с другими источниками данных.

Для Ningbo и Georgia исходные диагнозы уже были представлены кодами SNOMED CT в поле Dx, поэтому для этих наборов данных дополнительный переход от локальных акронимов к медицинской терминологии не требовался. Основная задача заключалась в преобразовании SNOMED CT – кодов в человекочитаемые текстовые диагностические названия. Если одна ЭКГ – запись содержала несколько кодов, каждый код преобразовывался в отдельную текстовую метку.

Для MIMIC – IV – ECG диагностические аннотации были получены из внешнего файла в текстовом формате и сопоставлены с конкретными ЭКГ – записями по паре идентификаторов subject_id и study_id. После сопоставления эти текстовые метки использовались как часть общего словаря диагностических обозначений. В рамках подготовки данных MIMIC – IV – ECG задавал целевой формат представления меток, к которому приводились аннотации остальных наборов данных.

Для преобразования кодированных диагнозов в текстовые обозначения использовался файл соответствий, сформированный на основе ресурса ATHENA проекта OHDSI. ATHENA представляет собой инструмент для поиска медицинских терминов и работы со стандартизированными словарями OMOP, включая SNOMED CT; такие словари используются для сопоставления медицинских понятий между различными терминологическими системами. В

рамках данной работы этот файл соответствий использовался для перехода от кодов SNOMED CT к текстовым названиям диагностических состояний.

После первичного преобразования был сформирован файл соответствий для всех уникальных текстовых названий диагностических состояний. Наличие синонимов и дублей не мешало дальнейшей разметке, поскольку итоговые классы задавались через этот файл соответствий: названия из основного файла меток сопоставлялись с категориями классификационной схемы на основе подготовленного файла разметки.

Общая схема гармонизации меток может быть представлена следующим образом (рисунок 2).

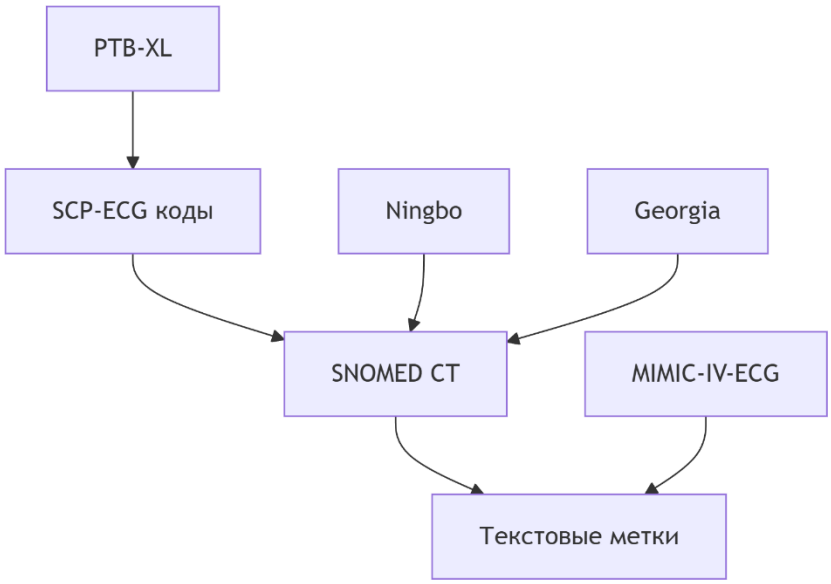


Рисунок 2 – Схема гармонизации диагностических меток

В результате преобразования все диагностические обозначения были приведены к единому текстовому виду. Это позволило сравнивать и объединять записи из разных источников независимо от того, в какой системе кодирования они были представлены изначально. При этом сохранялась многометочная природа задачи: если одной ЭКГ – записи соответствовало несколько исходных диагнозов, после гармонизации ей сопоставлялось несколько текстовых меток.

Гармонизация диагностических меток обеспечила переход от разнородных исходных аннотаций к единой системе текстовых диагностических обозначений. Это позволило сопоставлять записи из PTB – XL, Ningbo, Georgia и MIMIC – IV – ECG независимо от исходной системы кодирования и подготовило основу для последующего формирования целевой переменной.

3.5 Техническая стандартизация ЭКГ – сигналов

Техническая стандартизация ЭКГ – сигналов обеспечивает приведение записей из разных наборов данных к единому числовому и файловому представлению, пригодному для дальнейшей предобработки, нормализации и обучения моделей классификации.

В исходных файлах сигналов значения ЭКГ могут быть представлены в виде цифровых отсчетов, полученных после аналого – цифрового преобразования. Такие отсчеты зависят от параметров конкретной записи: коэффициента усиления, базового значения, единиц измерения, частоты дискретизации и других характеристик, указанных в .hea – файле. Поэтому прямое объединение сигналов в виде исходных цифровых значений нежелательно: одинаковые по физическому смыслу амплитуды могут иметь разные числовые значения в зависимости от параметров оцифровки.

Для устранения различий в представлении амплитуды при чтении записей использовалась библиотека wfdb. При загрузке сигнала применялся параметр physical=True: в этом режиме цифровые отсчеты преобразуются в физические величины на основе коэффициентов из заголовочного файла. В результате каждая запись представлялась как массив амплитуд ЭКГ в милливольтах.

Сигналы, преобразованные в физические величины, сохранялись в формате HDF5. HDF5 (Hierarchical Data Format version 5) – это формат хранения больших объемов числовых данных, организованных в виде иерархической структуры. Он позволяет размещать внутри одного файла массивы данных, метаданные и служебные атрибуты. В отличие от исходного WFDB – представления, где каждая ЭКГ – запись хранится отдельным набором файлов,

HDF5 позволяет объединить большое количество записей в один контейнер и обращаться к ним по индексам.

Использование HDF5 удобно для последующего обучения нейронных сетей. При работе с исходными WFDB – файлами необходимо многократно открывать отдельные .hea, .dat или .mat файлы, что усложняет загрузку данных и увеличивает накладные расходы. В HDF5 все стандартизированные сигналы хранятся в едином массиве, поэтому их можно считывать последовательно или пакетами при формировании пакетов для обучения модели. В данной работе HDF5 используется как промежуточный рабочий формат между исходными WFDB – записями и этапом машинного обучения.

В рамках технической стандартизации также фиксировались единые параметры представления ЭКГ – сигналов. Все записи приводились к стандартному набору из 12 отведений: I, II, III, aVR, aVL, aVF, V1, V2, V3, V4, V5, V6.

Сохранение единого порядка отведений необходимо, поскольку нейронная сеть воспринимает каждый канал входного массива как фиксированный источник информации. Если порядок каналов меняется между записями, модель может некорректно интерпретировать входные данные.

После чтения WFDB – записи сигнал имел форму 5000 × 12, где первая размерность соответствовала временным отсчетам, а вторая – отведениям. Для подачи в используемые одномерные сверточные модели массив приводился к форме 12 × 5000 путем транспонирования, где канальная размерность соответствовала отведениям ЭКГ. В результате каждая ЭКГ – запись сохранялась как числовой массив фиксированной формы: 12 × 5000, где 12 – количество стандартных ЭКГ – отведений, а 5000 – число временных отсчетов для 10 – секундной записи при частоте дискретизации 500 Гц. Данные сохранялись в формате float32, что уменьшало объем файла по сравнению с float64 при сохранении достаточной точности для последующей обработки сигналов.

Записи, не соответствующие заданным требованиям по числу отведений, длительности или частоте дискретизации, исключались из основного набора

данных. В рамках данного конвейера нестандартные записи не приводились к требуемой частоте дискретизации или длительности искусственно, чтобы не вносить дополнительные искажения в исходный сигнал.

Дополнительно при формировании HDF5 – файла сохранялись служебные атрибуты и внешний индекс записей в виде таблицы метаданных. В атрибутах HDF5 фиксировались общие параметры сформированного массива: количество отведений, количество отсчетов, частота дискретизации, единицы измерения, использованный метод фильтрации и общее число сохраненных записей.

Для связи каждой конкретной записи с исходными файлами параллельно формировалась таблица метаданных в формате Excel. В ней каждая строка соответствовала одной обработанной ЭКГ – записи и содержала ее индекс в HDF5, путь к исходному .hea – файлу, имя записи, идентификатор пациента при его наличии, исходную частоту дискретизации, длительность сигнала, список отведений, форму сохраненного массива, диагностические поля, признаки качества и статус обработки. HDF5 использовался для хранения числовых массивов ЭКГ, а Excel – таблица выполняла роль навигационного слоя между исходными данными, индексами HDF5, диагностическими метками и результатами контроля качества.

3.6 Предобработка ЭКГ – сигналов

Предобработка ЭКГ – сигналов выполнялась после технической стандартизации. На этом этапе сигналы уже были представлены в едином рабочем формате: 12 отведений, 5000 отсчетов, значения амплитуды в милливольтах и хранение в HDF5.

ЭКГ – сигналы могут содержать различные виды помех: дрейф изолинии, высокочастотный шум, сетевую наводку, артефакты движения пациента, плохой контакт электродов, насыщение амплитуды, выпадение отдельных участков сигнала или некорректные значения в отдельных отведениях. Наличие таких искажений может привести к тому, что модель будет обучаться не на морфологических особенностях ЭКГ, а на технических артефактах. Поэтому

предобработка рассматривалась не только как этап фильтрации, но и как этап контроля пригодности записи для дальнейшего анализа.

В работе было сформировано два основных варианта подготовленных данных. Первый вариант сохранял исходную форму ЭКГ после технической стандартизации и использовался как базовый для сравнения. Второй вариант формировался с применением библиотеки neurokit2 и метода neurokit, реализованного в функции ecg_clean: он включает высокочастотную фильтрацию с частотой среза 0,5 Гц на основе фильтра Баттерворта пятого порядка, а также подавление сетевой наводки. Другие методы очистки, поддерживаемые neurokit2, в данной работе рассматривались как дополнительные возможности библиотеки, но не как основные экспериментальные варианты.

Фильтрация применялась ко всей ЭКГ – записи, однако выполнялась независимо для каждого из 12 отведений.

Отдельным направлением предобработки было выявление записей низкого качества. Для этого использовались как простые эвристические признаки, так и отдельный контур обнаружения артефактов. На уровне базовой проверки качества оценивались плоские или почти плоские каналы, постоянные значения, насыщение амплитуды, высокочастотный шум, наличие пропусков и другие признаки технических дефектов. Для каждой записи фиксировался общий флаг качества и список отведений, в которых были обнаружены проблемы.

Помимо основной модели классификации ЭКГ был разработан вспомогательный модуль для выявления записей низкого качества. Его задача отличалась от медицинской классификации: модель должна была определять не диагноз, а пригодность сигнала для дальнейшего анализа. Если запись содержит выраженные технические или физиологические искажения, результат основного классификатора может отражать не морфологию ЭКГ, а артефакт регистрации. Поэтому такие записи необходимо выявлять до подачи в основную модель.

Для обучения модели поиска помех использовались синтетические и реальные данные. Синтетические 12 – канальные ЭКГ формировались с использованием neurokit2: задавались длительность, частота дискретизации,

уровень шума, вариабельность ритма и тип состояния, например нормальный ритм, тахикардия, брадикардия, расширенный QRS, элевация или депрессия ST и другие. Дополнительно к отдельным отведениям добавлялись изменения масштаба, дрейф изолинии, сетевая наводка и помехи движения пациента. Также использовался набор синтетических 12 – канальных ЭКГ – записей deepsynthbody/deepfake_ecg.

Для имитации записей с артефактами был подготовлен генератор искажений. Он накладывал случайный набор изменений на выбранные отведения: дрейф изолинии, мышечный шум, пульсовые артефакты, артефакты движения электрода, сетевые помехи частотой 50/60 Гц, плоский сигнал, импульсные выбросы, шум, зануление участка сигнала, насыщение амплитуды, инверсию отведений, смещение постоянной составляющей, случайные ступенчатые сдвиги, дрожание сигнала и квантование. Искажения применялись не ко всей записи сразу, а к случайным каналам, что приближало синтетические примеры к реальным ситуациям, когда проблема часто затрагивает только часть электродов.

На основе этих данных обучалась бинарная CNN – модель для задачи классификации «чистый сигнал» / «сигнал с артефактом». После синтетического этапа выборка была дополнена реальными данными: вручную были аннотированы 1500 ЭКГ – записей, из которых 370 были отмечены как содержащие помехи. Это позволило добавить реальные примеры плохого контакта, шума и других дефектов записи, которые не всегда полностью воспроизводятся искусственным генератором.

Кроме обучаемой модели был реализован отдельный эвристический фильтр морфологии ЭКГ. Он работает без обучения и используется как дополнительный инструмент контроля качества. Фильтр оценивает каждый файл двумя независимыми блоками. Первый блок основан на шаблонной корреляции QRS – комплексов: R – пики детектируются один раз на наиболее регулярном отведении, после чего для каждого из 12 каналов вычисляется согласованность соседних QRS – комплексов. Канал с низкой согласованностью помечается как

плохой; для анатомически более слабых отведений aVR, III и V1 применяется пониженный порог.

Второй блок эвристического фильтра включает быстрые проверки: обнаружение плоского сигнала, насыщения амплитуды, импульсных выбросов, нестабильного знака R – пика, нестабильного амплитудного отношения между каналами и нарушения закона Эйнтховена для отведений от конечностей. Итоговое решение принимается по числу каналов, не прошедших хотя бы одну из проверок: если таких каналов не менее заданного порога, запись получает статус FAIL. Такой фильтр дополняет CNN – модель поиска артефактов и обеспечивает независимый быстрый контроль качества без дополнительного обучения.

При использовании эвристического фильтра учитывалось, что снижение регулярности комплексов не всегда связано с техническими дефектами. Некоторые патологические состояния могут сами по себе нарушать повторяемость формы и временного положения QRS – комплексов. Например, при экстрасистолии отдельные комплексы отличаются от соседних по морфологии и интервалам появления, поэтому низкая шаблонная корреляция в такой записи может быть следствием патологии, а не плохого качества сигнала. По этой причине фильтр, основанный на шаблонной корреляции, не применялся к записям с патологиями, для которых характерна выраженная нерегулярность или морфологическая неоднородность комплексов. Это позволило избежать ошибочной отбраковки диагностически значимых ЭКГ – записей.

Предобработка ЭКГ – сигналов включала формирование двух вариантов данных, фильтрацию, проверку корректности числовых значений и выявление записей низкого качества. Сформированные механизмы контроля качества позволяют обнаруживать выраженные технические артефакты до использования записи в основной задаче классификации.

3.7 Формирование целевой переменной и разделение данных

Итоговые данные были представлены в двух вариантах: без дополнительной фильтрации и после обработки методом neurokit. Такое разделение создает основу для последующей экспериментальной проверки влияния фильтрации на качество обучения моделей и устойчивость классификации.

Целевая переменная формировалась на основе гармонизированных диагностических меток. В рамках данной работы задача была сведена к классификации ЭКГ – записей на три укрупненных класса: «норма», «синусовые отклонения без явных патологических меток» и «патология». Такой подход был выбран из – за разнородности исходных диагностических аннотаций и необходимости привести их к единой интерпретируемой схеме.

К классу «норма» относились записи с чистым нормальным синусовым ритмом без дополнительных патологических указаний.

К классу «синусовые отклонения без явных патологических меток» относились состояния, сохраняющие синусовое происхождение ритма, но отличающиеся от чистого нормального синусового ритма частотой или регулярностью сердечных сокращений. К ним относились, например, синусовая тахикардия, синусовая брадикардия и синусовая аритмия. В данной классификационной схеме этот класс используется как промежуточная укрупненная категория и не является самостоятельным клиническим заключением, поскольку интерпретация таких состояний зависит от возраста пациента, контекста регистрации и сопутствующих признаков.

К классу «патология» относились записи, содержащие диагностические метки, не входящие в первые две группы. В эту категорию включались нарушения ритма, проводимости, морфологические изменения и другие патологические или потенциально клинически значимые состояния.

Поскольку исходные данные имеют многометочную структуру, одна ЭКГ – запись могла содержать несколько диагностических обозначений одновременно.

При формировании целевой переменной использовалось правило приоритета патологической метки: если среди меток присутствовало состояние, не относящееся к нормальному синусовому ритму или выбранным синусовым отклонениям без явных патологических меток, запись относилась к классу патологии. После применения этого правила каждая запись получала один итоговый класс из трех.

Сформированные данные разделялись на обучающую, валидационную и тестовую выборки. Обучающая выборка использовалась для подбора весов нейронной сети, валидационная – для контроля качества модели в процессе обучения и выбора наилучшего состояния модели, а тестовая – для итоговой независимой оценки качества классификации.

Разделение выполнялось со стратификацией по целевым классам. Это необходимо для того, чтобы в каждой из подвыборок были представлены как нормальные, так и патологические записи. Без стратификации возможно смещение распределения классов, при котором один из классов будет недостаточно представлен в валидационной или тестовой части, что сделает оценку качества модели менее надежной.

Дополнительно учитывалась необходимость предотвращения утечки данных между выборками. Для наборов данных, в которых доступен идентификатор пациента, разбиение выполнялось с учетом этого уникального идентификатора: записи одного и того же пациента не должны попадать одновременно в обучающую, валидационную и тестовую выборки. Подробная проверка этого принципа и ограничения, связанные с особенностями отдельных наборов данных, рассматриваются в следующей главе.

При формировании разбиения учитывались два требования: сохранение представительности классов в каждой подвыборке и исключение пересечения идентификаторов пациентов между ними. Поэтому разбиение подбиралось так, чтобы максимально сохранить стратификацию по классам и не допустить попадания одного и того же пациента в разные части выборки.

На данном этапе были отобраны записи, прошедшие подготовку и контроль качества, сформирована трехклассовая целевая переменная и выполнено стратифицированное разделение данных с учетом предотвращения утечки между выборками.

3.8 Формальная постановка задачи классификации

Пусть исходная выборка после этапов чтения, стандартизации, предобработки и контроля качества содержит N ЭКГ – записей. Каждая запись представляется в виде многоканального временного ряда $X_i \in \mathbb{R}^{12 \times 5000}$, где 12 соответствует числу стандартных отведений, а 5000 – числу временных отсчетов 10 – секундного сигнала при частоте дискретизации 500 Гц.

Для каждой записи задана целевая метка $y_i \in Y,$ где множество классов имеет вид $\mathrm{Y} = \{0, 1, 2\}$. В рамках данной работы класс 0 соответствует нормальной ЭКГ – записи, класс 1 – синусовым отклонениям без явных патологических меток, класс 2 – патологической ЭКГ – записи. Таким образом, обучающая выборка задается множеством $D = \{(X_i, y_i)\}_{i=1}^{N}$.

Требуется построить параметризованную модель классификации $\mathrm{f_\theta}$, которая для входной ЭКГ – записи $\mathrm{X_i}$ формирует вектор оценок принадлежности к классам: $\mathrm{f_{\theta(X_i)}} = \mathrm{p_i} = (\mathrm{p_{i,0}}, \mathrm{p_{i,1}}, \mathrm{p_{i,2}})$, где $\mathrm{p_{i,k}} \in [0,1]$, а сумма вероятностей по всем классам равна единице: $\sum_{\mathrm{k=0}}^{2} \mathrm{p_{i,k}} = 1$. Значение $\mathrm{p_{i,k}}$ интерпретируется как оценка вероятности принадлежности записи $\mathrm{X_i}$ к классу k.

Итоговая предсказанная метка может определяться по правилу максимальной вероятности: $\hat{\mathrm{y}}_\mathrm{i} = \arg\max_{\mathrm{k} \in \mathrm{Y}} \mathrm{p_{i,k}}$.

При практическом использовании системы для класса 2 может дополнительно задаваться порог принятия решения, поскольку пропуск патологической записи является более критичной ошибкой, чем ложноположительное направление записи на дополнительную экспертную проверку.

Следовательно, решаемая задача относится к задаче многоклассовой классификации многоканальных временных рядов фиксированной длины. Модель не выполняет детальную диагностику отдельных нозологических форм, а относит ЭКГ – запись к одной из трех укрупненных категорий состояния. С учетом временной структуры сигнала и наличия 12 отведений далее рассматриваются одномерные сверточные архитектуры как основа классификатора.

3.9 Выбор и обоснование архитектур нейронных сетей

При решении задач анализа временных рядов электрокардиографических сигналов могут применяться различные архитектуры нейронных сетей. ЭКГ – сигнал представляет собой последовательность измерений во времени, поэтому для его обработки подходят модели, способные учитывать как локальные изменения формы сигнала, так и более протяженные временные зависимости.

К числу архитектур, применяемых для анализа ЭКГ – сигналов, относятся рекуррентные нейронные сети, сверточные нейронные сети, трансформерные модели, а также гибридные архитектуры, объединяющие несколько подходов. Рекуррентные нейронные сети и их модификации, например LSTM и GRU, ориентированы на обработку последовательностей и позволяют учитывать зависимость текущего состояния временного ряда от предыдущих значений. Такие модели могут применяться для анализа ЭКГ, поскольку электрокардиографический сигнал имеет выраженную временную структуру. Однако при работе с длинными многоканальными записями ЭКГ рекуррентные архитектуры не всегда являются наиболее удобным выбором, так как обработка последовательности в них во многом носит пошаговый характер. Это может ограничивать возможности параллельной обработки и увеличивать время обучения или вывод моделиа по сравнению с архитектурами, основанными на свертках.

Также для анализа ЭКГ могут использоваться трансформерные архитектуры. Их преимуществом является способность учитывать дальние

зависимости внутри последовательности и анализировать взаимосвязи между удаленными фрагментами сигнала. Вместе с тем применение таких моделей обычно связано с более сложной архитектурной настройкой, необходимостью подбора механизма позиционного кодирования, а также повышенными требованиями к вычислительным ресурсам. Поэтому в рамках данной работы трансформерные модели не рассматривались в качестве основного решения.

В рамках данной работы в качестве основной архитектуры были выбраны сверточные нейронные сети. Данный выбор обусловлен особенностями электрокардиографического сигнала и характером диагностически значимых признаков. ЭКГ содержит локальные морфологические элементы – зубцы, интервалы, сегменты и комплексы, форма и взаимное расположение которых могут указывать на наличие нормы или патологических изменений. Сверточные фильтры хорошо подходят для выделения таких локальных закономерностей, поскольку последовательно анализируют небольшие фрагменты сигнала и формируют на их основе более обобщенное представление.

Для анализа ЭКГ целесообразно использовать одномерные сверточные нейронные сети, поскольку входные данные представляют собой временной ряд. В этом случае сверточные фильтры перемещаются вдоль временной оси и выделяют характерные фрагменты сигнала. Такой подход позволяет учитывать локальную структуру ЭКГ, повторяемость кардиокомплексов и изменения формы сигнала на разных участках записи.

Отдельным аргументом в пользу сверточных нейронных сетей является возможность обработки многоканальных данных. В случае стандартной ЭКГ каждый канал соответствует отдельному отведению, отражающему электрическую активность сердца с определенного направления. Поэтому диагностически значимые изменения могут проявляться по – разному в разных отведениях. Представление нескольких отведений как входных каналов позволяет модели анализировать запись целиком, учитывая не только временную динамику сигнала, но и различия между отведениями.

Одномерные сверточные архитектуры являются обоснованным выбором для решения задачи анализа ЭКГ – сигналов в рамках данной работы. Они соответствуют структуре исходных данных, позволяют обрабатывать многоканальные временные ряды, автоматически выделяют локальные морфологические признаки и обеспечивают достаточно эффективную обработку записей. Указанные свойства делают одномерные сверточные архитектуры подходящей основой для построения модели классификации ЭКГ – сигналов.

3.9.1 Архитектура ResNet

ResNet (Residual Network) представляет собой разновидность глубокой сверточной нейронной сети, в которой используются остаточные соединения между слоями. Основная идея архитектуры заключается в том, что блок сети обучается не полному преобразованию входа, а остаточной функции. Если вход блока обозначить как x, а результат последовательности сверточных преобразований как F(x), то выход остаточного блока можно представить как F(x) + x. Такое остаточное соединение облегчает распространение градиента через глубокую сеть и снижает риск деградации качества при увеличении числа слоев.

В задаче классификации ЭКГ – сигналов ResNet обычно адаптируется к одномерным временным рядам. Вместо двумерных сверток, применяемых в задачах обработки изображений, используются одномерные свертки вдоль временной оси. На вход модели подается многоканальный массив ЭКГ, где отдельные каналы соответствуют отведениям, а временная размерность отражает последовательность отсчетов. Первые сверточные слои выделяют локальные морфологические элементы сигнала, такие как зубцы, сегменты и комплексы QRS, а более глубокие блоки формируют обобщенные признаки, связанные с ритмом, проводимостью и изменениями формы сигнала.

Типовой остаточный блок для одномерной ЭКГ – модели включает одну или несколько сверток Conv1D, нормализацию, нелинейную активацию и остаточное сложение входа с результатом преобразования. Если число каналов или временное разрешение меняется, в обходной ветви может использоваться

дополнительная свертка с ядром 1, чтобы согласовать размерности. После последовательности таких блоков обычно применяется глобальное усреднение по времени или другой агрегирующий слой, а затем полносвязный классификатор, формирующий вероятности целевых классов.

На рисунке 3 показан остаточный блок ResNet: основная ветвь выполняет последовательность сверточных преобразований, а дополнительный обходной путь (shortcut) передает вход блока к его выходу и тем самым облегчает обучение глубокой сети.

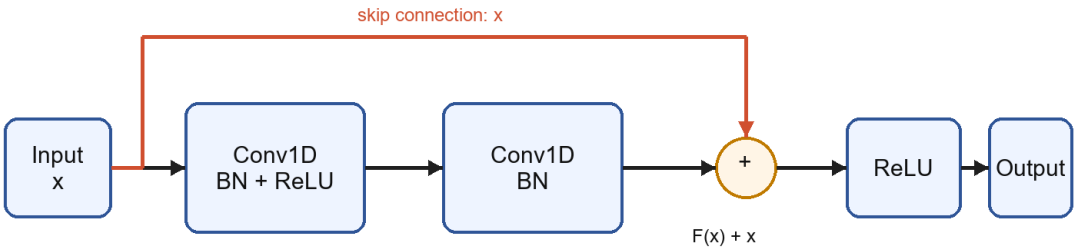


Рисунок 3 – Схема остаточного блока ResNet

На рисунке 4 представлена общая организация модели ResNet, где несколько остаточных блоков последовательно формируют признаки ЭКГ – сигнала от локальных морфологических элементов к более обобщенным представлениям.

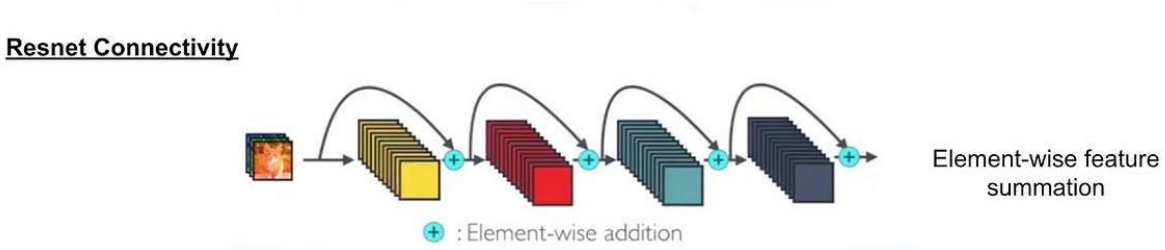


Рисунок 4 – Иллюстрация модели ResNet

Практическая значимость ResNet – подходов подтверждается результатами соревнований PhysioNet/Computing in Cardiology Challenge, посвященных автоматической классификации ЭКГ. На странице Computing in Cardiology с перечнем победителей указано, что среди призовых решений Challenge 2020

присутствовали модели на основе ResNet: команда «between a ROC and a heart place» заняла 2 место из 41 с решением «Adaptive lead weighted ResNet trained with different duration signals for classifying 12 – lead ECGs», а команда HeartBeats заняла третье место с решением «Classification of Cardiac Abnormalities from ECG Signals Using SE – ResNet». В списке победителей Challenge 2021 также приведены решения на основе residual CNN и attention – механизмов, что показывает устойчивое использование остаточных сверточных архитектур в задачах классификации многоканальных ЭКГ.

Указанные примеры важны для данной работы, поскольку они демонстрируют, что ResNet используется не только как теоретически удобная архитектура, но и как практическая основа конкурентоспособных решений в открытых международных соревнованиях по анализу ЭКГ.

Приведенные примеры показывают, что остаточные архитектуры успешно применялись в открытых соревнованиях по автоматическому анализу ЭКГ и могут рассматриваться как обоснованный вариант для экспериментального сравнения.

3.9.2 Архитектура DenseNet

DenseNet (Densely Connected Convolutional Network) представляет собой глубокую сверточную архитектуру, в которой каждый слой внутри плотного блока получает на вход признаки всех предшествующих слоев. Если в обычной сверточной сети слой использует только результат предыдущего слоя, то в DenseNet входом для очередного слоя является конкатенация всех ранее сформированных карт признаков. Такой принцип получил название плотных соединений и был предложен в работе G. Huang, Z. Liu, L. van der Maaten и K. Q. Weinberger «Densely Connected Convolutional Networks».

Ключевое отличие DenseNet от ResNet заключается в способе передачи информации между слоями. В ResNet используется остаточное сложение, при котором результат преобразования складывается с входом блока. В DenseNet признаки не складываются, а объединяются по канальной размерности.

Благодаря этому последующие слои получают доступ как к низкоуровневым локальным признакам, выделенным в начале сети, так и к более абстрактным представлениям, сформированным глубокими слоями.

Архитектура DenseNet строится из плотных блоков и переходных слоев. Внутри плотного блока каждый слой обычно включает нормализацию, нелинейную активацию и сверточную операцию, после чего его выход передается всем последующим слоям блока. Между плотными блоками располагаются переходные слои, которые уменьшают размерность признакового пространства, например с помощью свертки 1x1 и операции объединения. Важным параметром архитектуры является темп прироста признаков, то есть число новых карт признаков, которые добавляет каждый слой к общему набору признаков.

Для классификации ЭКГ – сигналов DenseNet может быть адаптирована к одномерным многоканальным временным рядам. В этом случае двумерные сверточные операции заменяются одномерными Conv1D – слоями, работающими вдоль временной оси. Входной массив содержит несколько каналов, соответствующих отведениям ЭКГ, а плотные связи позволяют модели сохранять и переиспользовать признаки, связанные с локальными морфологическими элементами сигнала: зубцами, сегментами, интервалами и комплексами QRS.

Преимущество DenseNet для анализа ЭКГ состоит в эффективном переиспользовании признаков. Диагностически значимые изменения могут проявляться как в коротких локальных фрагментах, так и в более протяженных временных закономерностях. Плотные соединения позволяют передавать ранние морфологические признаки к последующим слоям без необходимости заново формировать их на каждом уровне сети. Это улучшает распространение градиента, снижает риск его затухания и делает обучение глубокой модели более устойчивым.

DenseNet является обоснованной архитектурой для задачи классификации ЭКГ – сигналов. Она сочетает возможности глубоких сверточных моделей с

механизмом плотного переиспользования признаков, что полезно при обработке 12 – канальных записей, где важны как локальные изменения формы сигнала, так и совместный анализ информации из разных отведений.

Конкретные экспериментальные конфигурации одномерных реализаций ResNet и DenseNet, а также параметры обучения, приведены в следующей главе.

На рисунке 5 показан принцип DenseNet: признаки, полученные на ранних слоях, передаются последующим слоям через плотные связи и повторно используются при классификации.

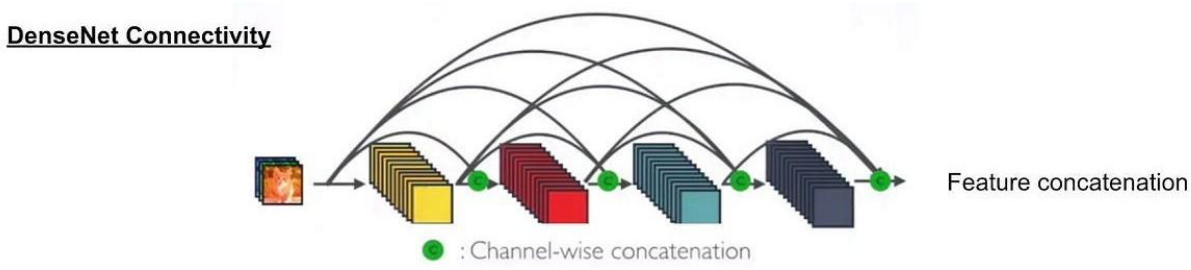


Рисунок 5 – Иллюстрация модели DenseNet

Для данной работы DenseNet представляет интерес как архитектура, сочетающая компактность параметров и эффективное переиспользование признаков, что важно при последующем применении модели в локальной программной системе.

3.9.3 Ограничения и границы применимости моделей

Несмотря на преимущества сверточных архитектур ResNet и DenseNet, их применение в задаче классификации ЭКГ – сигналов имеет ряд ограничений. Прежде всего, корректность работы модели зависит от соответствия входных данных формату, использованному при подготовке и обучении. В рамках данной работы модель ориентирована на анализ 12 – канальных ЭКГ – записей фиксированной длительности и частоты дискретизации. Изменение числа отведений, порядка каналов, частоты дискретизации или длительности записи может привести к некорректной интерпретации входного сигнала.

Важным ограничением является зависимость качества классификации от качества исходной ЭКГ – записи. Выраженные технические артефакты и некорректные значения в отдельных отведениях могут существенно повлиять на результат работы модели. Поэтому перед классификацией необходимы техническая валидация, предобработка и контроль качества сигнала, описанные в предыдущих подразделах.

Модель также ограничена системой целевых классов, использованной при обучении. Поскольку задача формулируется как классификация записей на категории «норма», «синусовые отклонения без явных патологических меток» и «патология», результат модели не следует интерпретировать как постановку конкретного клинического диагноза. Классификатор определяет укрупненную категорию состояния ЭКГ, но не выполняет полноценную дифференциальную диагностику отдельных аритмий, нарушений проводимости, ишемических изменений или других патологий.

Дополнительным ограничением является зависимость модели от распределения обучающих данных. Даже при использовании нескольких открытых наборов данных качество может снижаться на ЭКГ – записях, полученных на другом оборудовании, в другой клинической среде или у групп пациентов, недостаточно представленных в обучающей выборке. Это связано с возможным сдвигом области между обучающими данными и реальными условиями эксплуатации.

Следует учитывать возможность ложноположительных и ложноотрицательных решений. Ложноположительный результат приводит к необходимости дополнительной экспертной проверки, тогда как ложноотрицательный результат является более критичным, поскольку патологическая запись может быть ошибочно отнесена к норме или варианту нормы. Поэтому при настройке порога классификации необходимо учитывать клинический приоритет высокой чувствительности.

Методы визуальной интерпретации, например карты, созданные алгоритмом Grad – CAM, или карты значимости, могут повысить прозрачность

работы модели, однако не устраняют полностью проблему интерпретируемости. Такие карты показывают участки сигнала, оказавшие влияние на решение модели, но не являются самостоятельным медицинским объяснением и должны рассматриваться только как вспомогательная информация для врача.

3.10 Алгоритм применения модели классификации

Алгоритм применения модели классификации описывает последовательность действий, связывающую подготовленные данные с получением итогового результата. На вход алгоритма поступает ЭКГ – запись, приведенная к единому формату хранения и снабженная метаданными, необходимыми для контроля источника, порядка отведений и статуса обработки.

На первом шаге выполняется проверка пригодности записи к анализу. Контролируются соответствие формату входных данных и результаты контроля качества, установленные в требованиях к системе. Записи, не соответствующие этим условиям, не должны передаваться в нейросетевой классификатор, поскольку это может привести к недостоверному результату.

На втором шаге сигнал приводится к входному представлению модели. Для каждой записи формируется массив фиксированной формы 12 × 5000 с единым порядком отведений. В зависимости от выбранного экспериментального варианта может использоваться сигнал без дополнительной фильтрации либо сигнал, обработанный методом neurokit. Нормализация рассматривается как отдельный экспериментальный фактор; конкретные варианты нормализации и результаты их сравнения приведены в следующей главе.

На третьем шаге подготовленный массив передается в модель классификации. Сверточные слои выделяют локальные морфологические признаки ЭКГ, более глубокие блоки формируют обобщенное представление записи, после чего классификационный слой рассчитывает вероятности принадлежности к целевым классам «норма», «синусовые отклонения без явных патологических меток» и «патология».

На четвертом шаге выполняется интерпретация выхода модели. Полученный вектор вероятностей преобразуется в итоговую метку класса. Базовым правилом является выбор класса с максимальной вероятностью, однако для практического применения может использоваться дополнительный порог для класса «патология», позволяющий повысить чувствительность системы к потенциально опасным записям.

На пятом шаге результат классификации связывается с исходной записью и ее метаданными. Для каждой ЭКГ – записи сохраняются итоговая метка, вероятности классов, сведения о варианте предобработки и статус качества сигнала. Эти данные могут использоваться при последующем анализе результатов обучения, сравнении архитектур и формировании отчета в программной системе.

Обобщенно алгоритм применения классификатора можно представить как последовательность: чтение ЭКГ – записи, проверка формата и качества, приведение к стандартному набору отведений, выбор варианта предобработки, формирование входного массива, нейросетевая классификация, получение вероятностей классов и формирование итоговой метки. Такая последовательность обеспечивает единообразное использование модели как на этапе экспериментов, так и при последующей интеграции в программную систему поддержки принятия решений.

3.11 Выводы по главе

В данной главе была рассмотрена подготовка данных и проектирование алгоритма классификации ЭКГ – сигналов. В качестве исходной экспериментальной базы были выбраны открытые наборы 12 – канальных электрокардиограмм PTB – XL, Ningbo, MIMIC – IV – ECG и Georgia 12 – lead ECG Challenge Database. Их совместное использование расширяет исходную базу исследования и создает предпосылки для последующей экспериментальной проверки устойчивости модели к данным из разных источников.

Показано, что несмотря на общий формат хранения ЭКГ – сигналов, используемые наборы данных различаются структурой файлов, составом метаданных и схемами диагностической разметки. Поэтому перед объединением данных был выполнен анализ структуры и семантики наборов, а диагностические обозначения были приведены к единому текстовому представлению. Это обеспечило возможность сопоставлять записи из разных источников и формировать общую целевую переменную.

На этапе технической стандартизации ЭКГ – записи были приведены к единому числовому и файловому представлению. Сигналы считывались из WFDB – формата с преобразованием цифровых отсчетов в физические величины, приводились к стандартному набору и порядку 12 отведений и сохранялись в формате HDF5. Дополнительно формировалась таблица метаданных, связывающая сохраненные массивы с исходными файлами, диагностическими метками и результатами контроля качества.

В рамках предобработки были подготовлены варианты данных без дополнительной фильтрации и с фильтрацией методом neurokit. Также были описаны механизмы выявления записей низкого качества, включающие эвристические проверки, вспомогательную CNN – модель для обнаружения артефактов и морфологический фильтр на основе анализа согласованности QRS – комплексов. Эти механизмы формируют основу для последующей

экспериментальной проверки влияния качества сигнала на обучение классификатора.

Целевая переменная была сформирована на основе гармонизированных меток и правила приоритета патологической метки. Затем данные были разделены на обучающую, валидационную и тестовую выборки со стратификацией по классам и с учетом предотвращения утечки между выборками.

Формальная постановка задачи классификации определила вход модели как стандартизированный многоканальный временной ряд формы 12 × 5000, а выход – как вероятностную оценку принадлежности ЭКГ – записи к одному из трех целевых классов. Такая постановка соответствует назначению системы поддержки принятия решений, поскольку модель выполняет предварительную укрупненную классификацию, а не постановку конкретного клинического диагноза.

В качестве базовых архитектур для дальнейшего исследования были обоснованы одномерные сверточные нейронные сети ResNet и DenseNet. ResNet выбрана благодаря использованию остаточных соединений, облегчающих обучение глубоких моделей, а DenseNet – благодаря механизму плотного переиспользования признаков. Обе архитектуры могут быть адаптированы к анализу 12 – канальных ЭКГ как многоканальных временных рядов и способны выделять локальные морфологические признаки сигнала.

Также были определены ограничения применимости моделей и общий алгоритм использования классификатора. Показано, что корректность результата зависит от формата входной записи, качества сигнала, соответствия данных обучающему распределению и правильной интерпретации выходных вероятностей. Итогом главы стал подготовленный набор данных, формальная постановка задачи и алгоритмическая основа для последующего обучения, сравнения и оценки моделей классификации ЭКГ – сигналов.

4 Исследование эффективности моделей классификации ЭКГ – сигналов

4.1 Экспериментальная постановка исследования

Экспериментальное исследование организовано в два связанных этапа. На первом этапе выполнялись бинарные серии для задачи различения синусового ритма и патологии; эти опыты использовались для выбора устойчивых решений по типу входного сигнала, нормализации, расширение данныхм и параметрам обучения. На втором этапе найденные решения проверялись в итоговой трехклассовой постановке «норма / синусовые отклонения без явных патологий / патология» на более сложных архитектурах.

Все эксперименты выполнены по единому контролируемому протоколу: начальное значение генератора псевдослучайных чисел фиксировало разбиение данных на обучающую, валидационную и тестовую выборки, порядок мини – батчей при обучении и порядок случайных преобразований в экспериментах с расширение данныхми. Сравнение вариантов входного сигнала, нормализации, случайных преобразований, скорости обучения и размера пакета проводилось при изменении одного фактора и сохранении остальных условий, что обеспечивало сопоставимость результатов внутри постановки задачи.

4.2 Подготовка данных и протокол формирования выборок

Для экспериментов из общего массива выделялись псевдослучайные подвыборки с сохранением пропорций целевых классов. В бинарных сериях записи приводились к постановке «синусовый ритм / патология», в финальном этапе использовалась трехклассовая постановка. В таблице 2 представлено распределение меток в исходном корпусе.

Таблица 2 – Распределение меток в исходном корпусе

Класс	Количество записей	Доля, %
Норма (NORM)	117 295	14,24
Патология (PATHOLOG)	650 929	79,00
Синусовые отклонения (SR)	55 801	6,77
Итого	824 025	100,00

4.2.1 Учет дисбаланса классов при оценке качества

Распределение классов имеет выраженный перекос в сторону класса «патология», поэтому основное внимание в работе уделялось метрикам, устойчивым к дисбалансу: F1 macro и balanced accuracy, уравновешивающим вклад классов.

4.2.2 Контроль утечки данных

Ключевой риск при работе с ЭКГ состоит в попадании записей одного пациента или одной клинической группы в разные подвыборки. Для снижения этого риска применялось групповое стратифицированное разбиение: записи с одним идентификатором пациента или группы не могли одновременно оказаться в обучающей, валидационной и тестовой выборках. При отсутствии идентификатора запись рассматривалась как отдельная уникальная группа. Состав полученных подвыборок приведен в таблице 3.

Таблица 3 – Размеры и состав подвыборок

Подвыборка	Записей	Групп	NORM	PATHOLOG	SR
Train	659 146	108 010	93 835	520 681	44 630
Validation	82 393	60 864	11 729	65 085	5 579
Test	82 394	60 824	11 730	65 085	5 579

Тестовая выборка содержит 82 394 записи, что обеспечивает достаточный объем данных для статистически устойчивой итоговой оценки моделей.

4.2.3 Варианты входного сигнала

В экспериментальных сериях сопоставлялись два варианта входного сигнала. Первый вариант использовал исходную ЭКГ в сохраненных амплитудах после технической стандартизации. Второй вариант использовал сигнал после фильтрации NeuroKit2, направленной на подавление шума и дрейфа изолинии. Фильтрация рассматривалась как самостоятельный фактор, поскольку не является однозначно полезной операцией: она способна повысить устойчивость к артефактам, но одновременно может ослабить слабые диагностически значимые компоненты сигнала.

4.2.4 Нормализация данных

Для оценки роли амплитудного масштаба рассматривались три режима: сохранение исходного масштаба, стандартизация каждого отведения по среднему и стандартному отклонению, а также приведение значений каждого отведения к фиксированному диапазону [– 1, 1]. Указанный дизайн обусловлен тем, что для ЭКГ абсолютные и межканальные амплитудные соотношения могут нести диагностическую информацию. Нормализация рассматривалась как самостоятельный фактор предобработки и не смешивалась с фильтрацией сигнала.

4.2.5 Расширение данных ЭКГ – сигналов

Расширение данных применялась только к обучающей выборке и не затрагивала валидационную и тестовую, что исключало искусственное изменение контрольных наборов. Использовались два типа преобразований: изменение амплитуды и сдвиг сигнала по времени. Преобразования имитируют естественные вариации регистрации и не должны менять клиническую

семантику записи. На данном этапе расширение данных рассматривалась исключительно как экспериментальный фактор.

4.3 Роль SimpleCNN1D в исследовательском этапе

На исследовательском этапе основной рабочей моделью для абляционных экспериментов служила модель SimpleCNN1D. Она использовалась в бинарной задаче «синусовый ритм / патология» для повторяемых сравнений, в которых изменялся один фактор: тип входного сигнала, режим нормализации, набор случайных преобразований или режим обучения. Архитектура модели представлена на рисунке 6.

SimpleCNN1D не рассматривалась как итоговая модель системы. Ее задача состояла в экономичном выявлении устойчивых закономерностей в бинарной задаче, которые далее использовались как методические ориентиры и требовали проверки в финальной трехклассовой постановке.

4.4 Метрики и методика оценки качества

4.4.1 Используемые метрики

Состав применяемых метрик приведен в таблице 4.

Таблица 4 – Используемые метрики качества

Метрика	Назначение
Accuracy	Общая доля правильных ответов; вспомогательная метрика при дисбалансе
Balanced accuracy	Средняя полнота по классам
Precision	Доля верных предсказаний среди объектов, отнесенных к классу
Recall	Доля найденных объектов класса среди всех истинных объектов класса

Окончание таблицы 4

Метрика	Назначение
F1 macro	Среднее F1 по классам без учета их численности
ROC – AUC macro OVR	Агрегированная способность отделять каждый класс от остальных

4.4.2 Обоснование выбора F1 macro

F1 macro выбран в качестве основной метрики вследствие неравномерного представления классов. В бинарных сериях он обеспечивал сопоставление качества распознавания синусового ритма и патологии без доминирования более многочисленного класса. В финальной трехклассовой постановке macro – усреднение особенно важно из – за малого класса SR: ошибка на нем сохраняет заметный вес в итоговой оценке и не маскируется большим числом патологических записей.

4.5 Бинарные исследовательские эксперименты на SimpleCNN1D

4.5.1 Сравнение исходного и фильтрованного ЭКГ – сигнала

В первой исследовательской серии проверялось, какой вход предпочтительнее в бинарной задаче: исходный сигнал или сигнал после фильтрации NeuroKit2. В серии фиксировались размер пакета 256, начальная скорость обучения 0,001, отсутствие случайных преобразований и отсутствие дополнительной нормализации, что позволяло изолировать влияние фильтрации. Результаты сопоставления представлены в таблице 5.

Таблица 5 – Сравнение исходного и фильтрованного сигнала в бинарных сериях

Входной сигнал	**Кол – во сравнений**	**Средний F1 macro**	**Balanced accuracy**	**AUC ROC**
Исходная ЭКГ	30	0,8411	0,8552	0,9486
Фильтрованная ЭКГ NeuroKit2	30	0,8287	0,8449	0,9413

Сравнение показало, что в бинарной задаче дополнительная фильтрация не дала устойчивого выигрыша. В 28 из 30 парных запусков средняя парная разница была положительной в пользу исходного сигнала; среднее улучшение F1 macro составило около 0,0123. На этом основании RAW – сигнал принят как методический ориентир для дальнейших проверок с уточнением в финальном трехклассовом контуре.

4.5.2 Исследование влияния случайных преобразований

Следующая бинарная серия проверяла влияние случайных преобразований. Режимы преобразований сопоставлялись по единому протоколу, что позволяло оценивать вклад амплитудных изменений и временного сдвига отдельно от состава выборок. Результаты приведены в таблице 6.

Таблица 6 – Сравнение режимов случайные преобразования в бинарных сериях

Режим	**n**	**Изменение амплитуды**	**Сдвиг во времени**	**Средний F1 macro**	**Balanced accuracy**	**AUC ROC**
Strong	20	до 15 %	до 500 отсчетов	0,8509	0,8654	0,9547
Medium	20	до 10 %	до 250 отсчетов	0,8505	0,8658	0,9545
Weak	20	до 5 %	до 100 отсчетов	0,8496	0,8622	0,9541

Окончание таблицы 6

Режим	n	Изменение амплитуды	Сдвиг во времени	Средний F1 macro	Balanced accuracy	AUC ROC
Только сдвиг	20	не применялось	до 500 отсчетов	0,8485	0,8606	0,9538
Без случайные преобразования	20	не применялось	не применялось	0,8424	0,8578	0,9493

Случайные преобразования улучшали качество относительно режима без преобразований, однако различия между режимами weak, medium и strong оказались умеренными. Умеренный режим случайные преобразования выбран как кандидат для финального цепочки обработки: он повышает устойчивость обучения, не приводя к избыточной деформации сигнала.

4.5.3 Исследование влияния нормализации

В отдельной бинарной серии проверялась необходимость дополнительного изменения амплитудного масштаба ЭКГ перед подачей в модель. Изменяемым фактором являлся режим нормализации. Результаты представлены в таблице 7.

Таблица 7 – Влияние нормализации на качество бинарной классификации

Режим	n	Средний F1 macro	SD	Balanced accuracy	AUC ROC	Δ к лидеру
Исходный масштаб	30	0,8411	0,0056	0,8571	0,9486	0,0000
Стандартизация по отведению	30	0,8251	0,0055	0,8423	0,9393	– 0,0159
Приведение к [– 1, 1] по отведению	30	0,8153	0,0051	0,8339	0,9329	– 0,0258

Дополнительное изменение масштаба не улучшило качество: стандартизация и приведение к фиксированному диапазону снижали средний F1 macro относительно исходного масштаба. Возможное объяснение состоит в том, что амплитудные соотношения между отведениями и абсолютный масштаб комплекса могут участвовать в различении классов. Отсутствие дополнительной поканальной нормализации принято, как методический ориентир для финальной проверки.

4.5.4 Исследование влияния скорости обучения и размера пакета

Завершающая бинарная серия оценивала чувствительность обучения к размеру батча и начальной скорости обучения. Внутри каждой конфигурации выполнялись парные сравнения с базовым режимом, что позволяло оценивать направленность изменения F1 macro при смене гиперпараметров. Результаты приведены в таблице 8.

Таблица 8 – Сравнение гиперпараметров в бинарных сериях

Размер батча / скорость обучения	**n**	**Средний F1 macro**	**SD**	**Balanced accuracy**	**AUC ROC**
128 / 0,001	20	0,8431	0,0053	0,8561	0,9495
128 / 0,0015	30	0,8431	0,0051	0,8574	0,9493
256 / 0,003	20	0,8427	0,0047	0,8593	0,9496
192 / 0,002	30	0,8423	0,0046	0,8568	0,9493
256 / 0,001	10	0,8389	0,0065	0,8545	0,9476

Проверка показала, что близкие конфигурации дают небольшие различия. Лучшие средние значения концентрировались в области размера батча 128 и начальной скорости обучения 0,001 – 0,0015. Для финального обучения выбрана

устойчивая область гиперпараметров, а не единичное значение, случайно удачное для одного запуска.

4.6 Переход к финальной трехклассовой постановке

Методические выводы бинарных серий проверены на модели ResNet18_1D и подтвердились. Это дало основание перенести найденные решения в финальное обучение. Обе финальные модели (ResNet18_1D и DenseNet121_1D) обучались на исходном сигнале в сохраненных амплитудах, без дополнительной поканальной нормализации, с умеренными расширение данныхми и с гиперпараметрами, выбранными по результатам предварительных экспериментов.

4.7 Методика обучения финальных моделей

4.7.1 Функция потерь, оптимизатор и планировщик скорости обучения

В финальных экспериментах использовалась функция потерь Focal Loss с $\gamma = 2{,}0$. Оптимизация выполнялась оптимизатором AdamW с weight decay = 0,0001. Скорость обучения управлялась планировщиком ReduceLROnPlateau, уменьшавшим скорость обучения при отсутствии улучшения валидационной F1 macro.

4.7.2 Настройка скорости обучения и размера пакета

Для финальной серии зафиксированы размер пакета 128 и начальная скорость обучения 0,001. Указанные значения соответствуют области устойчивых результатов, выявленной в бинарных сериях и перенесенной в трехклассовый контур.

4.7.3 Валидация, регуляризация и критерии остановки обучения

Валидационная выборка использовалась для выбора лучшего состояния модели. Критерием ранней остановки служила F1 macro с min_delta = 0,0001 и patience = 15. ResNet18_1D достигла лучшего значения на 28 – й эпохе, после чего обучение продолжалось до 31 – й эпохи без устойчивого улучшения. DenseNet121_1D улучшалась до 30 – й эпохи, где была сохранена лучшая контрольная точка модели.

4.8 Финальное обучение и сравнение ResNet18_1D и DenseNet121_1D

На финальном этапе выполнено сравнение двух архитектур на независимой тестовой выборке. Интегральные результаты представлены в таблице 9.

Таблица 9 – Итоговое сравнение моделей на независимой тестовой выборке

Модель	**Balanced accuracy**	**F1 macro**	**F1 weighted**	**ROC – AUC**
ResNet18_1D	0,846849	0,825655	0,911418	0,974334
DenseNet121_1D	0,875775	0,837339	0,917690	0,978376

DenseNet121_1D превосходит ResNet18_1D по всем интегральным метрикам. Для более детального анализа дополнительно рассмотрена поклассовая точность классификации (таблица 10), позволяющая определить, за счет каких классов формируется итоговое качество моделей.

Таблица 10 – Поклассовое качество на независимой тестовой выборке

Модель	**Класс**	**Precision**	**Recall**	**F1**	**Support**
ResNet18_1D	NORM	0,810123	0,839130	0,824372	11730
ResNet18_1D	PATHOLOG	0,954488	0,934793	0,944538	65085

Окончание таблицы 10

Модель	Класс	Precision	Recall	F1	Support
ResNet18_1D	SR	0,657798	0,766625	0,708054	5579
DenseNet121_1D	NORM	0,815034	0,879028	0,845823	11730
DenseNet121_1D	PATHOLOG	0,966458	0,929692	0,947719	65085
DenseNet121_1D	SR	0,640174	0,818605	0,718477	5579

Обе модели наиболее уверенно распознают класс «патология» (PATHOLOG). Наиболее сложным остается класс «синусовые отклонения без явных патологических меток» (SR): несмотря на рост recall у DenseNet до 0,818605, precision этого класса ниже, чем у классов «норма» и «патология».

4.9 Динамика обучения моделей

Динамика валидационного качества финальных моделей по ключевым эпохам приведена в таблице 11.

Таблица 11 – Динамика валидационного качества по ключевым эпохам

Модель	Эпоха	LR	Val loss	Val F1 macro	Val balanced accuracy	Val AUC
ResNet18_1D	1	0,001	0,118673	0,713771	0,698884	0,930158
ResNet18_1D	14	0,001	0,074448	0,803113	0,837814	0,967924
ResNet18_1D	28	0,001	0,064449	0,824102	0,846167	0,973803
DenseNet121_1D	1	0,001	0,123369	0,668558	0,645217	0,922781
DenseNet121_1D	14	0,001	0,079101	0,832479	0,862773	0,977609
DenseNet121_1D	30	0,001	0,064238	0,835949	0,873812	0,977965

4.10 Анализ ошибок классификатора

4.10.1 Матрицы ошибок

Матрицы ошибок моделей ResNet18_1D и DenseNet121_1D на тестовой выборке приведены в таблицах 12 и 13. Строки соответствуют истинным классам, столбцы – предсказанным.

Таблица 12 – Матрица ошибок ResNet18_1D

Истинный класс	**Прогноз NORM**	**Прогноз PATHOLOG**	**Прогноз SR**
NORM	9843	1710	177
PATHOLOG	2196	60841	2048
SR	111	1191	4277

Таблица 13 – Матрица ошибок DenseNet121_1D

Истинный класс	**Прогноз NORM**	**Прогноз PATHOLOG**	**Прогноз SR**
NORM	10311	1206	213
PATHOLOG	2222	60509	2354
SR	118	894	4567

Для наглядного сравнения дополнительно построены нормированные матрицы ошибок (рисунок 6), в которых значения представлены в относительном виде по каждому истинному классу. Это позволяет сопоставить модели независимо от различий в численности классов и оценить долю ошибок внутри каждой категории.

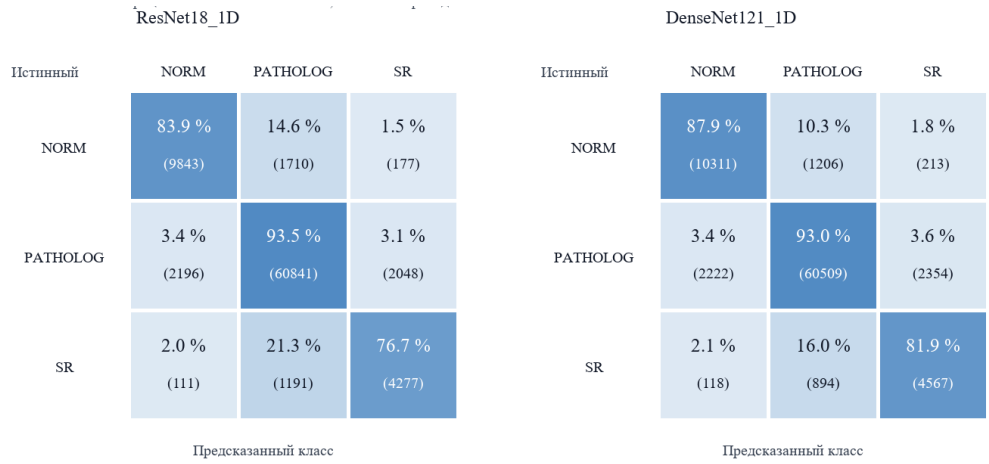


Рисунок 6 – Матрицы ошибок

4.10.2 Анализ типичных ошибок

Основные ошибки обеих моделей связаны с границей между классами «норма» (NORM) и «синусовые отклонения» (SR), а также с переносом части патологических записей в эти классы. У ResNet из 5579 истинных записей SR корректно распознаны 4277, а 1191 запись отнесена к классу «патология». У DenseNet корректных SR стало 4567, а ошибок SR в PATHOLOG уменьшилось до 894, что объясняет рост recall класса SR.

Для класса «патология» обе модели сохраняют высокую полноту, однако DenseNet немного чаще относит патологические записи к SR. Это снижает precision класса SR, но с прикладной точки зрения менее критично, чем систематический пропуск патологии как нормы. Число ошибок PATHOLOG в NORM остается сопоставимым: 2196 у ResNet и 2222 у DenseNet.

4.11 Анализ сходимости и устойчивости финальных моделей

Сходимость обеих финальных моделей можно считать удовлетворительной: валидационная F1 macro возрастала от начальных эпох к лучшим контрольным точкам. ResNet18_1D быстрее выходила на плато, однако ее итоговая тестовая метрика оказалась ниже. DenseNet121_1D обучалась дольше по числу эпох, но дала более высокий результат на независимой тестовой выборке. Сводные показатели обучения приведены в таблице 14.

Таблица 14 – Сводные показатели обучения финальных моделей

Модель	Число эпох	Время обучения	Best val F1	Test F1 macro
ResNet18_1D	28	4:23:19	0,824102	0,825655
DenseNet121_1D	35	5:50:04	0,835949	0,837339

4.12 Вывод по главе

В главе проведено экспериментальное исследование моделей классификации 12 – канальных ЭКГ – сигналов. На первом этапе на модели SimpleCNN1D в бинарной задаче «синусовый ритм / патология» выявлены закономерности предобработки и обучения. На втором этапе эти выводы использованы как ориентиры при переходе к финальной трехклассовой постановке и сравнению ResNet18_1D и DenseNet121_1D.

Методический вывод бинарных серий состоит в том, что предпочтительным оказался исходный сигнал в сохраненных амплитудах без дополнительной поканальной нормализации. Фильтрация NeuroKit2 не дала устойчивого улучшения и увеличивала вычислительную стоительность, тогда как умеренные случайные преобразования повышали качество относительно контроля без преобразований. Указанные решения подтверждены в финальном трехклассовом протоколе.

Финальная проверка на независимой тестовой выборке показала преимущество DenseNet121_1D над ResNet18_1D по основным интегральным метрикам: balanced accuracy 0,875775 против 0,846849, F1 macro 0,837339 против 0,825655, ROC – AUC 0,978376 против 0,974334. Результат согласуется с задачей выбора модели для дальнейшей реализации в программной системе.

На основании полученных результатов DenseNet121_1D выбрана в качестве итоговой рабочей модели для реализации программной системы поддержки принятия решений. Ее применение должно сопровождаться отображением вероятностей классов и учетом ограничений модели, особенно

при смешении нормы с синусовыми отклонениями без явных патологических меток и при неоднозначных патологических записях.

5 Апробация модели на реальных клинических данных

5.1 Цель, условия и критерии апробации

Апробация выполнялась для финальной модели DenseNet121_1D, выбранной ранее по результатам экспериментального сравнения архитектур. Целью проверки являлась оценка работы обученной модели не только на подготовленных открытых наборах данных, но и на реальных обезличенных клинических ЭКГ – записях, экспортированных из целевого кардиографа в формате XML.

Вывод модели проводился локально, без передачи медицинских данных во внешние сервисы. Для запуска использовался скрипт inference_densenet121_multiclass_xml_h5_npy.py в режиме data_mode=xml с указанием колонки xml_path и лучшей контрольной точки обучения epoch_0030_f1_0.8359.pt (DenseNet121_1D, 30 – я эпоха).

В команде вывод моделиа были заданы дополнительные правила постобработки результатов: если модель первоначально относила запись к одному из непатологических классов – «норма» (NORM) или «синусовые отклонения без явных патологических меток» (SR), – но при этом вероятность класса «патология» (PATHOLOG) была не ниже 0,30, итоговое решение автоматически изменялось на «патология». Порог 0,30 использовался как защитное правило: при наличии достаточно выраженных признаков патологического класса система отдавала приоритет более осторожному решению и не оставляла запись в непатологической категории. Значение 0,30 расположено между серверным порогом правил 0,10 и значением слайдера пользовательского интерфейса по умолчанию 0,35 и выбрано как компромисс для клинической апробации.

В качестве целевых показателей апробации использовались:

- precision класса PATHOLOG ≥ 0,75 – обеспечение приемлемой точности положительных предсказаний патологического класса;

- recall класса PATHOLOG ≥ 0,80 – обеспечение полноты выявления патологий, критичной с точки зрения клинической безопасности.

5.2 Описание клинических данных

Проверочная выборка включала реальные обезличенные ЭКГ – записи, полученные из целевого кардиографа. Файлы представлены в формате XML и содержат 12 классических отведений. Исходная частота дискретизации записей составляла 2000 Гц; на этапе вывод моделиа сигнал приводился к частоте 500 Гц, после чего формировалось 10 – секундное модельное окно размерности 12 × 5000. Персональные данные пациента при анализе не использовались.

Распределение записей по истинным классам, полученное по итогам разметки, приведено в таблице 15.

Таблица 15 – Распределение клинических записей по классам

Класс	**Число записей**	**Доля, %**
NORM	396	42,17
PATHOLOG	418	44,52
SR	125	13,31
Итого	939	100,00

В отличие от обучающей выборки, где доля патологических записей составляла 79,00 %, в клинической выборке распределение более сбалансировано: на класс PATHOLOG приходится 44,52 %, на класс NORM – 42,17 %, на класс SR – 13,31 %.

5.3 Анализ результатов вывод моделиа

5.3.1 Сводные метрики качества

Сводная оценка качества вывод моделиа на реальных XML – записях представлена в таблице 16. Accuracy приведена как справочная общая доля правильных ответов; основной вывод формируется по balanced accuracy, F1 macro, F1 weighted и MCC, устойчивым к дисбалансу классов.

Таблица 16 – Сводные метрики апробации вывод моделиа

Метрика	Значение	Назначение
Accuracy	0,7391	Справочная общая доля правильных ответов
Balanced accuracy	0,7544	Средняя полнота по классам
F1 macro	0,7427	Среднее F1 без учета численности классов
F1 weighted	0,7377	F1 с учетом поддержки классов
MCC	0,6042	Корреляционная интегральная оценка

Модель сохраняет работоспособный уровень качества на реальных данных: balanced accuracy составила 0,7544, F1 macro – 0,7427, F1 weighted – 0,7377. Однако по сравнению с результатами на независимой тестовой выборке открытых наборов (F1 macro 0,8373) зафиксировано снижение F1 macro на 0,0946, что указывает на наличие сдвига области между обучающими и реальными эксплуатационными данными.

5.3.2 Матрица ошибок

Распределение верных и ошибочных решений модели представлено в таблице 17. Строки соответствуют истинным классам, столбцы – предсказанным.

Таблица 17 – Матрица ошибок вывод моделиа

Истинный класс	Прогноз NORM	Прогноз PATHOLOG	Прогноз SR	Итого
NORM	317	68	11	396
PATHOLOG	113	277	28	418
SR	12	13	100	125
Итого	442	358	139	939

Наиболее значимым ограничением является то, что 113 записей с истинным классом PATHOLOG были отнесены к NORM. Такой тип ошибки снижает полноту выявления патологий и требует отдельного анализа. Дополнительно 28 записей PATHOLOG были отнесены к SR.

5.3.3 Поклассовые метрики

Для уточнения выводов по матрице ошибок были рассчитаны поклассовые precision, recall и F1 (таблица 18). Эти показатели позволяют оценить не только количество ошибок, но и их влияние на качество распознавания каждого класса.

Таблица 18 – Поклассовые метрики вывод моделиа

Класс	Support	Predicted	Precision	Recall	F1
NORM	396	442	0,7172	0,8005	0,7566
PATHOLOG	418	358	0,7737	0,6627	0,7139
SR	125	139	0,7194	0,8000	0,7576

Поклассовые метрики подтверждают, что модель лучше удерживает качество для классов NORM и SR по показателю recall: 0,8005 и 0,8000 соответственно. Для класса PATHOLOG precision составляет 0,7737, что превышает установленное целевое значение 0,75. Однако recall равен 0,6627, что ниже требуемого уровня 0,80. Таким образом, основное ограничение апробации связано с пропуском части патологических записей, отнесенных моделью к классу NORM.

5.4 Анализ ограничений

Снижение полноты патологического класса связано с ограничениями, обозначенными ранее при работе с открытыми наборами данных ЭКГ. Модель обучалась и выбиралась на данных, отличающихся от реального эксплуатационного контура: возможен сдвиг области между открытыми базами и записями целевого кардиографа, различаются оборудование и протоколы регистрации, а реальные сигналы могут содержать миографические помехи, сетевые наводки, дрейф изолинии и другие артефакты.

При интерпретации результатов необходимо учитывать возрастную структуру обучающих и целевых данных. В обучающей выборке преобладали записи пациентов среднего и старшего возраста, тогда как в целевых клинических данных значимую долю составляют дети и молодые пациенты. Возраст влияет на морфологию ЭКГ, частотные характеристики ритма и распространенность отдельных состояний, поэтому недостаточная представленность младших возрастных групп в обучающей выборке может усиливать сдвиг области между обучающими и эксплуатационными данными.

Дополнительными факторами снижения качества являются неоднородность диагностических аннотаций, шум разметки и дисбаланс классов в обучающих данных. В открытых наборах частые состояния представлены лучше редких и пограничных, поэтому высокие метрики на подготовленных тестовых выборках могут снижаться при переносе на новых пациентов и в другую клиническую среду.

5.5 Выводы по главе

Апробация подтвердила, что реализованный конвейер способен выполнять локальный вывод модели финальной модели DenseNet121_1D на реальных обезличенных XML – записях целевого кардиографа с автоматической передискретизацией и формированием входного окна, соответствующего обученной модели.

Вместе с тем проверка показала, что требование к точности положительных предсказаний патологического класса выполнено (precision 0,7737 при целевом значении ≥ 0,75), тогда как требование к полноте выявления патологий на реальных данных не достигнуто (recall 0,6627 при целевом значении ≥ 0,80). По сравнению с результатами на независимой тестовой выборке открытых наборов зафиксировано снижение F1 macro на 0,0946, что объясняется сдвигом области, различиями в возрастной структуре данных и условий регистрации.

Для дальнейшего повышения соответствия целевым показателям необходимо:

- продолжить работу с реальными клиническими данными: уточнять разметку и анализировать ошибки класса PATHOLOG;

- выполнить настройку пороговых правил с учетом эксплуатационных требований к балансу precision/recall;

- провести дообучение модели с использованием записей целевого кардиографа, в том числе с увеличением представленности младших возрастных групп. На текущий момент аннотировано около 1000 записей целевого кардиографа, что недостаточно для формирования сбалансированных обучающей, валидационной и тестовой подвыборок при дообучении, поэтому в настоящее время ведется сбор и разметка дополнительных записей.

6 Проектирование и реализация программной системы поддержки принятия решений на основе анализа ЭКГ – сигналов

6.1 Общая архитектура программного комплекса

Разработанный программный комплекс представляет собой локальное приложение с веб – интерфейсом, предназначенное для загрузки, обработки, нейросетевого анализа, визуализации и документирования 12 – канальных ЭКГ – записей в формате XML Poly – Spectrum.NET. Серверная часть реализована на языке Python с использованием микрофреймворка Flask; пользовательский интерфейс доступен через локальный браузер или через настольную оболочку. Такое решение позволяет совместить браузерный пользовательский интерфейс с серверной обработкой ЭКГ – сигналов, нейросетевым вывод моделиом и формированием PDF – отчетов, не превращая систему в облачный сервис и не предполагая передачу медицинских данных во внешние API.

Архитектура системы построена по трехуровневой схеме. Уровень представления включает HTML – шаблоны, CSS – оформление и клиентские JavaScript – модули, отвечающие за загрузку файлов, отображение списка записей, запуск анализа, визуализацию ЭКГ и экспорт отчетов. Прикладной уровень содержит Flask – маршруты и сервисные модули, реализующие парсинг XML, предобработку сигнала, классификацию, расчет ритма, управление сессией, автоматический импорт и генерацию PDF. Уровень данных представлен локальной файловой системой, временными и служебными JSON – файлами, а также файлом обученной модели.

Локальный характер архитектуры принципиален для выбранной области применения. XML – файлы, модель, служебные JSON – файлы и формируемые отчеты находятся на рабочей станции пользователя. Оперативное состояние записей и результаты анализа хранятся в памяти Flask – процесса в течение текущего запуска приложения, а между запусками сохраняется только часть служебной информации (флаги просмотра/архивирования, конфигурация и журнал watcher). Для выполнения классификации не требуется обращение к

внешним API или облачным сервисам, что снижает зависимость от сетевой инфраструктуры и согласуется с ограничениями обработки медицинских данных.

Приложение поддерживает два режима запуска. В веб – режиме запускается Flask – сервер на локальном адресе с открытием интерфейса в системном браузере. В desktop – режиме сервер Flask работает в фоновом потоке, а интерфейс отображается в нативном окне pywebview.

Основной сценарий работы включает загрузку или автоматический импорт XML – файла, первичную проверку структуры, передискретизацию сигнала, подготовку входного массива для модели, классификацию, расчет ЧСС и ритма, отображение результата в интерфейсе и, при необходимости, формирование PDF – отчета. Схема модульной архитектуры локального программного комплекса представлена на рисунке А.1 (приложение А).

6.2 Состав системы и ключевые подсистемы

Программный комплекс разделен на функциональные подсистемы, каждая из которых выполняет отдельную роль в общем процессе обработки записи. Такая декомпозиция повышает сопровождаемость приложения и позволяет рассматривать пользовательский сценарий как последовательность независимых, но согласованных этапов. Схема состава и связей функциональных подсистем представлена на рисунке Б.1 (приложение Б)

Взаимодействие подсистем (рисунок Б.1) материализуется в виде последовательности шагов обработки записи, изображенной на рисунке 7

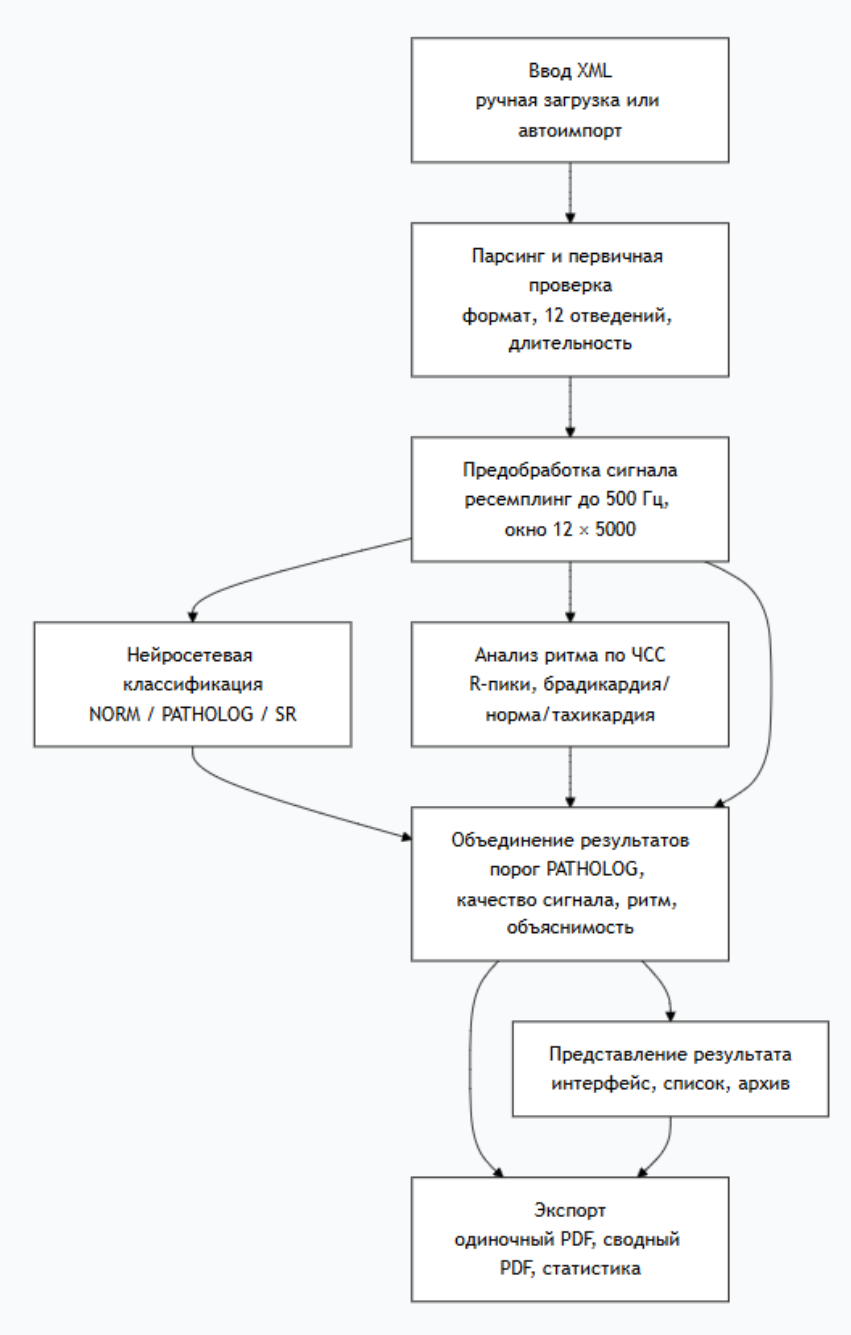


Рисунок 7 – Последовательность обработки ЭКГ – записи

Отдельно выделяется механизм автоматического импорта XML – файлов из папки кардиографа. Он не заменяет подсистему ввода, а расширяет ее за счет альтернативного канала поступления данных.

6.2.1 Подсистема ввода и первичной обработки данных

Подсистема ввода реализована маршрутами app/routes/upload.py и сервисом app/services/xml_parser.py. Ее назначение – принять XML – файл, разобрать его структуру, проверить корректность данных и зарегистрировать запись во внутреннем хранилище сессии.

Основным эксплуатационным форматом является XML Poly – Spectrum.NET. Файл содержит набор кривых ЭКГ, где каждая кривая соответствует одному из стандартных отведений. В типовом случае внутри XML присутствует элемент CurveSet Count="12", а каждое отведение задано элементом Curve с атрибутом SubType (например, ecgI, ecgII, ecgAVR или ecgV1). Внутри кривой указываются частота дискретизации Frequency, число отсчетов Samples и блок Data Units="Volt", содержащий значения сигнала. Дополнительно XML может содержать точки QRS, заданные как Point Type="pointECGQRS" с временем появления комплекса. Парсер извлекает эти сведения как метаданные и отражает наличие QRS – точек в информации о файле, однако основной расчет ритма в системе выполняется собственной детекцией R – пиков после предобработки сигнала.

Стандартный порядок отведений задается единым списком CHANNEL_NAMES: I, II, III, aVR, aVL, aVF, V1, V2, V3, V4, V5, V6.

При поступлении файла создается уникальный идентификатор записи, выполняется временное сохранение XML, затем вызывается парсер Poly – Spectrum.NET. После разбора временная копия удаляется, а сигнал и метаданные остаются в оперативном представлении – это уменьшает накопление временных данных и не оставляет XML – копий на диске после успешной обработки.

Парсер parsepolyspectrumxml() проверяет существование файла, расширение .xml, наличие набора из 12 отведений, единую частоту дискретизации и одинаковую длину всех каналов. После успешного разбора формируется массив сигнала формы [12, T], где 12 соответствует числу отведений, а T – числу отсчетов исходной записи. Дополнительно сохраняются

частота дискретизации, список названий отведений, фактическое число отсчетов и QRS – точки, если они присутствуют в XML.

На этапе валидации проверяются минимальная длительность записи, отсутствие полностью нулевых каналов, NaN и Inf, а также плоские (постоянные) отведения. Если запись не удовлетворяет условиям, она остается видимой в интерфейсе со статусом ошибки и не передается в основной классификатор – это позволяет не прерывать работу приложения и обрабатывать пакет файлов, не блокируя очередь из – за одной некорректной записи.

Запись в filestorage создается через общий механизм makestorageentry(). Это позволяет одинаково обрабатывать файлы, загруженные вручную, и файлы, поступившие через подсистему автоматического импорта. Для каждой записи сохраняются имя файла, идентификатор, статус разбора и валидации, источник поступления, время создания, признаки просмотра и архивирования. Флаги viewed и archived дополнительно сохраняются в файле uploads/.ecg_metadata.json, что позволяет восстановить пользовательское состояние после перезапуска приложения.

6.2.2 Подсистема предобработки ЭКГ – сигналов

Подсистема предобработки реализована сервисом app/services/preprocessor.py и утилитами utils/signal_processing.py. Она подготавливает сигнал к нейросетевому вывод моделиу, визуализации, расчету ЧСС и оценке качества. Параметры предобработки перечислены в таблице 19.

Таблица 19 – Ключевые параметры предобработки

Параметр	Значение	Назначение
TARGET_FS	500 Гц	Целевая частота дискретизации
MODELINPUTSAMPLES	5000	Вход модели, 10 с при 500 Гц

Окончание таблицы 19

Параметр	Значение	Назначение
RHYTHMINPUTSAMPLES	10000	Окно анализа ритма, до 20 с при 500 Гц
MINSAMPLESAFTER_RESAMPLE	5000	Минимальная длина после передискретизацияа
MINDURATIONSEC	10 с	Минимальная длительность записи
DEFAULT_THRESHOLD	0.35	Значение порога в интерфейсе и серверном fallback по умолчанию

На вход поступает массив [12, T] в микровольтах и исходная частота дискретизации. Если данные расположены в форме [T, 12], они приводятся к виду [12, T]. Первым этапом является проверка корректности сигнала: контролируются двумерность массива, длительность, наличие нулевых каналов, NaN, Inf и плоских отведений.

Далее весь сигнал передискретизируется к целевой частоте 500 Гц. Для XML с частотой 2000 Гц это соответствует переходу 2000 в 500 Гц. В реализации используется полифазная передискретизация resample_poly из scipy.signal, что позволяет привести сигнал к единой частоте без ручного удаления отдельных отсчетов.

После передискретизацияа формируются три представления. leadsfull содержит всю запись на частоте 500 Гц – это основа для ритма, визуализации и выделения модельного окна. leadsraw содержит первые 5000 отсчетов (10 секунд) без дополнительной фильтрации – это сырое окно для модели и предпросмотра. leads хранится в поле результата предобработки и используется для отображения и оценки качества. Если после передискретизацияа запись содержит менее 5000 отсчетов, она помечается как слишком короткая и не передается в классификатор.

Результат предобработки содержит:

- leads_raw – первые 5000 отсчетов передискретизированного сигнала для визуализации и вывод моделиа;

- leads_full – полный передискретизированный сигнал;

- fs – целевая частота дискретизации 500 Гц;

- sqiperlead и sqi_overall – показатели качества сигнала;

- morphology_passed – результат морфологической проверки;

- bad_channels – список проблемных отведений;

- morphology_details – дополнительные сведения о Template Correlation, выбранном отведении и вариабельности RR – интервалов.

Перед передачей в DenseNet значения масштабируются из микровольт в милливольты (умножением на 0.001), чтобы эксплуатационный вход соответствовал масштабу, использованному при подготовке модели.

6.2.3 Подсистема нейросетевого анализа

Подсистема нейросетевого анализа реализована в модуле app/services/densenetmulticlassclassifier.py. Для классификации используется локальная модель DenseNet121_1D, загружаемая из файла: models/densenet121_multiclass.pt. Модель решает трехклассовую задачу (таблица 20).

Таблица 20 – Целевые классы

Метка	Смысловой класс
NORM	Норма
PATHOLOG	Патология
SR	Синусовые отклонения без явных патологических меток

Классификатор выполняет ленивую загрузку checkpoint при первом обращении, проверяет совместимость архитектуры, число классов, карту классов и наличие modelstatedict. На вход подаются первые 5000 отсчетов 12 – канальной ЭКГ после передискретизацияа до 500 Гц и масштабирования в милливольты. После прямого прохода вычисляются вероятности классов с помощью softmax, argmax – класс и итоговый класс после пороговой постобработки.

Результат классификации содержит вероятности трех классов, исходный argmax – класс, итоговый класс после постобработки, уверенность, вероятность патологического класса, сведения о примененном пороговом правиле и служебные параметры режима нормализации.

Экземпляры классификатора кэшируются по округленному значению рабочего порога. Это уменьшает накладные расходы при повторных запусках анализа с тем же порогом.

6.2.4 Подсистема анализа ритма и ЧСС

Анализ ритма реализован в модуле app/services/rhythm_classifier.py. Отдельная нейросетевая модель ритма в системе не используется – расчет выполняется детерминированно на основе R – пиков.

Алгоритм работает с окном до 10000 отсчетов после передискретизацияа (до 20 секунд при 500 Гц). Сначала выбирается наиболее информативное отведение с учетом предпочтительного порядка II, I, aVF, V1 – V6, III, aVL, aVR. Далее на модуле сигнала выполняется поиск R – пиков через scipy.signal.find_peaks, после чего рассчитываются RR – интервалы и частота сердечных сокращений. Для фильтрации используется допустимый диапазон RR 0.3 – 2.5 с, ЧСС рассчитывается как 60 / mean(RR).

Классификация по ЧСС выполняется по простому правилу, представленному в таблице 21.

Таблица 21 – Правила классификации ЧСС

Условие	Класс ритма
ЧСС < 60 уд/мин	брадикардия
60 – 100 уд/мин	нормальный ритм
ЧСС > 100 уд/мин	тахикардия

Полученный результат используется как дополнительный признак, помогающий пользователю интерпретировать итоговый вердикт. Он не заменяет нейросетевую классификацию и не претендует на детальную ритмологическую диагностику.

6.2.5 Подсистема представления результата и пороговой постобработки

Представление результата объединяет вероятности нейросетевой модели, итоговый класс, сведения о примененном пороговом правиле, ЧСС, укрупненную оценку ритма и показатели качества сигнала. Такая подача позволяет пользователю видеть не только итоговую метку, но и контекст, в котором она была получена.

Пороговые правила задаются в app/config.py:

Если первичный класс относится к SR или NORM, но вероятность класса PATHOLOG достигает заданного порога, итоговая метка переводится в PATHOLOG. В серверной конфигурации fallback – порог правил равен 0.35, что совпадает со значением слайдера #globalThreshold в интерфейсе (сохраняется в localStorage под ключом ecgThreshold). Единый порог используется и для ручного анализа, и для автоанализа watcher. Механизм повышает чувствительность

системы к патологическому классу, но не отменяет необходимости врачебной оценки результата.

При открытии подробной страницы анализа вызывается POST /api/v1/analysis/run/<fileid>, поэтому подробный просмотр может заново выполнить анализ, а не только прочитать уже сохраненный результат. Значение порога передается в backend при запуске анализа или пересчете результата.

6.2.6 Подсистема формирования PDF – отчетов

Формирование отчетов реализовано сервисом PDFReportGenerator в модуле app/services/report_generator.py и маршрутами app/routes/export.py. Система поддерживает три сценария экспорта:

- одиночный отчет по одной записи – включает имя исходного файла, идентификатор записи, итоговый вердикт, вероятность патологического класса, сведения о чсс и ритме, показатели качества сигнала, графики 12 отведений, использованный порог, текстовое резюме обработки, таблицу ведущих отведений по вкладу в классификацию;

- сводный pdf по всем проанализированным файлам текущей сессии – объединяет результаты нескольких записей;

- статистический pdf – сортирует записи по вероятности патологического класса для приоритизации просмотра и последующего документирования.

Для генерации PDF используется ReportLab, для построения графиков ЭКГ – matplotlib с backend Agg. При первом создании генератора регистрируется TrueType – шрифт с поддержкой кириллицы; поиск шрифта выполняется среди стандартных шрифтов Windows: Arial, Calibri, Times, DejaVu Sans и Consolas.

В текущей версии PDF – отчет не содержит полноценные клинически валидированные тепловые карты значимости. В одиночном отчете явно выводится вероятность патологического класса. Добавление клинически валидированных карт значимости относится к дальнейшему развитию отчетной подсистемы.

6.2.7 Подсистема автоматического импорта ЭКГ

Для работы с потоком файлов из кардиографа реализована подсистема автоматического импорта ECGFolderWatcher. Она наблюдает за выбранной папкой экспорта и регистрирует новые XML – файлы без ручной загрузки через интерфейс. Подсистема является опциональной: она активируется через переменную окружения ECGWATCHFOLDER или через интерфейс в модальном окне настройки папки кардиографа. Если библиотека watchdog отсутствует, приложение продолжает работу в ручном режиме, а пользователь получает сообщение об отключенном наблюдателе. Схема архитектуры подсистемы автоматического импорта представлена на рисунке В.1 (приложение В)

При обнаружении XML – файла система не начинает чтение немедленно. Сначала выполняется ожидание стабильности файла: размер должен оставаться неизменным в течение заданного интервала (по умолчанию 2 секунды, максимальное ожидание – 300 секунд). Это защищает от попытки разобрать файл, который еще записывается программой кардиографа.

После стабилизации watcher проверяет .watchedstate.json. Если файл с тем же абсолютным путем, временем изменения и размером уже был импортирован и отмечен как проанализированный, повторная обработка не выполняется. Если файл новый, измененный или ранее был только импортирован без анализа, создается временная копия, над которой выполняются стандартный XML – парсинг и валидация. Затем запись добавляется в общее хранилище file_storage с признаком source="watcher", а служебный журнал обновляется.

Настройки watcher сохраняются в .watcherconfig.json: выбранная папка, режим автоанализа, признак удаления исходного файла, время ожидания стабильности. Журнал импортированных файлов – в .watchedstate.json (путь, размер, время изменения, идентификатор записи, статус анализа). По умолчанию исходные XML – файлы не удаляются из папки кардиографа, что сохраняет независимый журнал экспорта медицинского оборудования; удаление после импорта может быть включено отдельным параметром deleteafterimport.

При включенном автоанализе watcher вызывает тот же общий конвейер runanalysisforfile(), что и ручной сценарий.

6.2.8 Подсистема объяснимости решений модели

В системе предусмотрен технический задел для объяснимости решений модели. Он реализован в модуле app/services/explainer.py и включает два метода: Saliency (градиентная карта значимости) и Integrated Gradients. Также поддерживаются ранжирование отведений по суммарной атрибуции и временной анализ участков наибольшей значимости. Однако в текущей версии системы этот функционал представлен как вариант развития проекта на будущее.

6.2.9 Подсистема пользовательского интерфейса и управления сессией

Пользовательский интерфейс включает главную страницу index.html, страницу анализа analysis.html, модальные окна, карточки файлов, элементы управления порогом, архив записей и карточку watcher. Главная страница предназначена для загрузки и отбора записей, страница анализа – для просмотра результата классификации и формы ЭКГ.

Серверная часть управления сессией реализована в app/routes/session.py. Она предоставляет следующие маршруты:

- GET /api/v1/session/files – список файлов с пагинацией (page, perpage), скрывает архивные, возвращает archivecount;

- POST /api/v1/session/clear – полная очистка сессии с удалением временных файлов и метаданных;

- GET/POST /api/v1/session/threshold – чтение и установка рабочего порога классификации;

- GET /api/v1/session/archive – список архивных записей;

- POST /api/v1/session/archive/<file_id> – перемещение в архив;

- DELETE /api/v1/session/archive/<file_id> – окончательное удаление из архива;

- POST /api/v1/session/archive/bulk – массовое архивирование;

- DELETE /api/v1/session/archive/bulk – массовое удаление из архива;

- POST /api/v1/session/restore/<file_id> – восстановление из архива;

- POST /api/v1/session/restore/bulk – массовое восстановление;

- POST /api/v1/session/viewed/<file_id> – отметка записи как просмотренной;

- GET /api/v1/session/file/<file_id> – детальная информация о файле.

Записи, которые уже проанализированы и просмотрены, могут скрываться из активного списка и оставаться доступными через архив. Это снижает визуальную перегрузку при поточной работе и позволяет пользователю сосредоточиться на новых или непроверенных записях.

В интерфейс также включена карточка watcher и модальное окно настройки папки кардиографа. Пользователь может выбрать директорию экспорта, включить автоанализ, запустить повторное сканирование, приостановить наблюдение или восстановить его. Это связывает ручной и автоматический способы поступления данных в единый пользовательский сценарий (рисунок 8).

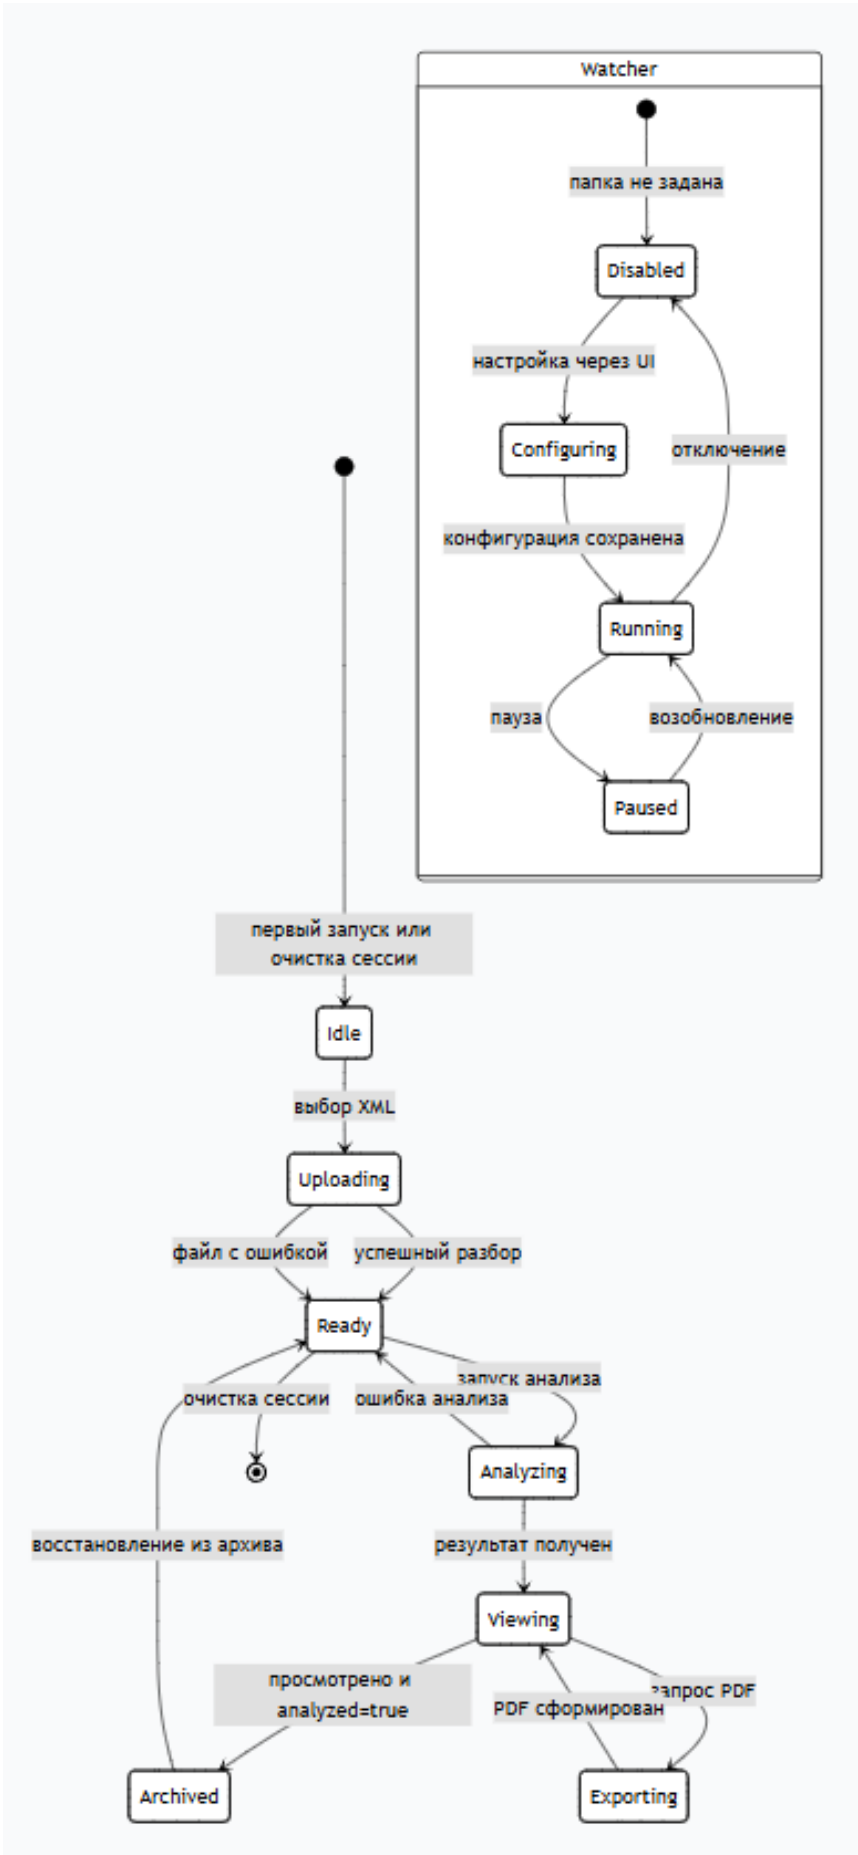


Рисунок 8 – Состояния пользовательского интерфейса и наблюдателя

6.3 Информационное обеспечение системы

Информационное обеспечение комплекса включает входные XML – файлы, оперативное состояние сессии, конфигурационные параметры, модельные ресурсы, служебные JSON – файлы и выходные PDF – отчеты.

Входной файл Poly – Spectrum.NET содержит блок кривых ЭКГ, в котором для каждого отведения указываются частота дискретизации, число отсчетов и значения сигнала:

Между запусками приложения сохраняется только часть служебного состояния. Служебные файлы в каталоге uploads представлен в таблице 22.

Таблица 22 – Служебные файлы системы

Файл	Назначение
.ecg_metadata.json	Хранение флагов просмотра и архивирования (viewed, archived)
.watcher_config.json	Настройки автоматического импорта
.watched_state.json	Журнал импортированных файлов и защита от дублей

6.4 Потоки данных между компонентами системы

Основной поток обработки начинается с ручной загрузки XML – файла или автоматического поступления записи из папки кардиографа. После парсинга система получает массив формы [12, T] в микровольтах и исходную частоту дискретизации. Далее сигнал приводится к 500 Гц, проверяется на минимальную длительность, преобразуется в окно [12, 5000] для модели, оценивается по показателям качества и масштабируется в милливольты. Нейросетевая модель возвращает вероятности классов NORM, PATHOLOG и SR. После этого применяется пороговая постобработка, рассчитываются R – пики, ЧСС и укрупненный класс ритма. Итог сохраняется в analysis_result и используется интерфейсом и генератором PDF без повторного вывод моделиа. Схема

основного потока обработки ЭКГ – записи представлена на рисунке Г.1 (приложение Г)

6.5 Модуль загрузки и обработки XML – файлов ЭКГ

Модуль загрузки обеспечивает переход от внешнего XML – файла к внутренней записи системы. При ручной загрузке файл временно сохраняется в каталоге uploads/, после чего передается в парсер. Если разбор завершен успешно, во внутреннем хранилище формируется запись с результатом парсинга, статусом валидности, временем создания, источником поступления и начальными признаками просмотра и архивирования.

После успешного разбора временная копия XML удаляется, поскольку значения сигнала и метаданные уже находятся в оперативном представлении. Для ошибочных файлов также удаляется временная копия, а в filestorage сохраняются статус ошибки и текст диагностического сообщения. Это уменьшает накопление временных данных и оставляет пользователю информацию, достаточную для понимания причины отказа.

Парсер parsepolyspectrumxml извлекает 12 отведений, частоту дискретизации, массив отсчетов и, при наличии, точки QRS. Валидатор проверяет минимальную длительность, отсутствие полностью нулевых каналов, NaN и Inf, а также плоские отведения. Если запись непригодна для анализа, она остается видимой в интерфейсе, но не передается в классификатор. Такой подход позволяет не накапливать временные XML – копии на диске и одновременно сохранять пользователю информацию о причине отказа обработки.

6.6 Автоматический импорт ЭКГ – записей из папки кардиографа

Автоматический импорт предназначен для сценария, при котором кардиограф или связанное с ним программное обеспечение сохраняет новые XML-файлы в заранее выбранную директорию. Реализованная подсистема ECGFolderWatcher в реальном времени наблюдает за этой папкой и автоматически передает новые записи в общий конвейер обработки. Настройка параметров мониторинга, включая выбор директории экспорта и режима немедленного автоанализа, осуществляется в специализированном интерфейсном модуле, представленном в приложении Л (рисунок Л.4).

Перед разбором нового файла watcher ожидает стабилизации его размера: по умолчанию файл должен оставаться неизменным в течение 2 секунд, максимальное ожидание – 300 секунд. Это защищает систему от чтения неполностью записанного XML.

После стабилизации размера файла выполняется проверка внутреннего журнала .watched_state.json. Если запись с идентичным абсолютным путем, временем изменения и размером уже была обработана системой, повторный импорт не производится для исключения дублирования данных. Для новых или измененных файлов создается временная копия, над которой запускаются стандартные процедуры парсинга, технической валидации и регистрации в хранилище file_storage с признаком источника source="watcher". Для оперативного контроля за процессом импорта и отслеживания статусов обработки файлов врачу доступен журнал истории автоанализа, приведенный в приложении Л (рисунок Л.7). Общая схема потока автоматического импорта представлена на рисунке И.1 приложения И.

По умолчанию исходные XML – файлы не удаляются из папки кардиографа. Удаление после импорта может быть включено отдельным параметром deleteafterimport, но базовый сценарий предполагает сохранение оригиналов как независимого журнала экспорта медицинского оборудования.

6.7 Модуль предобработки сигналов

Модуль предобработки получает массив [12, T] в микровольтах и исходную частоту дискретизации. Если данные представлены в форме [T, 12], они приводятся к стандартному виду [12, T].

Сначала выполняется проверка корректности сигнала: контролируются размерность массива, длительность записи, наличие нулевых или плоских отведений, а также значения NaN и Inf. Затем весь сигнал передискретизируется к частоте 500 Гц с помощью resample_poly.

После передискретизацияа формируются три представления:

- leads_full – весь сигнал на частоте 500 Гц;

- leads_raw – первые 5000 отсчетов для модели и визуализации;

- leads – рабочее окно для оценки качества и передачи в последующие модули.

Качество сигнала оценивается через SQI и морфологическую проверку. SQI строится как сочетание kurtosis – based SQI и spectral SQI: первый показатель отражает выраженность пикообразных QRS – комплексов, второй – долю энергии в диапазоне 5 – 25 Гц. Дополнительно применяется Template Correlation: вокруг R – пиков вырезаются фрагменты, нормируются и сравниваются между собой по форме с учетом допустимого временного сдвига. Запись считается морфологически пригодной, если число проблемных каналов не достигает критического уровня; отведения с низкой согласованностью могут быть отмечены как проблемные. Схема конвейера подготовки сигнала и нейросетевой классификации представлена на рисунке К.1 (приложение К)

6.8 Модуль классификации ЭКГ

Модуль классификации использует сохраненную модель DenseNet121_1D. На вход модели передается 10 – секундный фрагмент 12 – канальной ЭКГ после передискретизацияа до 500 Гц. Значения сигнала масштабируются из микровольт в милливольты, чтобы эксплуатационный вход соответствовал масштабу, применявшемуся при подготовке модели.

Классификатор возвращает вероятности трех классов: NORM, PATHOLOG и SR. После этого выполняется пороговая постобработка по правилам SR в PATHOLOG и NORM в PATHOLOG: если первичный argmax относится к SR или NORM, но вероятность PATHOLOG достигает рабочего порога, итоговый класс переводится в PATHOLOG. Единый порог 0.35 используется как в серверной конфигурации (fallback), так и в пользовательском интерфейсе (слайдер, сохраняется в localStorage).

6.9 Модуль анализа ритма и дополнительных признаков

Модуль анализа ритма рассчитывает R – пики, RR – интервалы, частоту сердечных сокращений и укрупненный класс ритма. Для анализа используется передискретизированный сигнал на частоте 500 Гц и окно до 10000 отсчетов (до 20 секунд).

Алгоритм выбирает наиболее информативное отведение с учетом предпочтительного порядка II, I, aVF, V1 – V6, III, aVL, aVR, выполняет поиск пиков через scipy.signal.find_peaks, фильтрует RR – интервалы в диапазоне 0.3 – 2.5 с и рассчитывает ЧСС как 60 / mean(RR). Классификация по ЧСС выполняется по простому правилу: при ЧСС ниже 60 уд/мин – брадикардия, при ЧСС от 60 до 100 уд/мин – нормальный диапазон, при ЧСС выше 100 уд/мин – тахикардия.

6.10 Модуль представления результатов

Модуль представления результатов формирует итоговую структуру, понятную пользователю. В нее входят итоговая метка, вероятность патологического класса, вероятности всех классов, сведения о пороговой постобработке, ЧСС, класс ритма.

6.11 Модуль визуализации ЭКГ – сигнала и результатов

Визуализация ЭКГ реализована с использованием Plotly. Пользователь может просматривать 12 отведений, масштабировать графики, переходить к подробной странице анализа и сопоставлять форму сигнала с результатом классификации. Для длинных записей применяется WebGL – режим отрисовки, что снижает нагрузку на браузер при отображении больших массивов точек.

На странице анализа отображаются вероятности классов, итоговый вердикт, сведения о ЧСС и ритме, показатели качества сигнала, проблемные каналы, информация о примененном пороговом правиле и экспериментальная saliency – подсветка при подробном анализе.

В завершенный объем реализации включены графики ЭКГ, численные результаты анализа, вероятности классов, сведения о ритме, признаки качества сигнала и экспериментальное отображение saliency при подробном анализе. Полноценная клинически валидированная подсистема тепловых карт не считается завершенной функцией текущей версии и относится к дальнейшему развитию.

6.12 Формирование PDF – отчета

PDF – отчет является выходным документом системы. Он фиксирует данные исходного файла, итоговый результат анализа, вероятность патологического класса, сведения о ритме и ЧСС. Пример сформированного отчета, содержащего все указанные компоненты, представлен в приложении Л (рисунок Л.5).

Система поддерживает три сценария экспорта. Одиночный отчет предназначен для анализа конкретной записи и включает имя исходного файла, идентификатор записи, итоговый вердикт, вероятность патологического класса, использованный порог, сведения о ритме и ЧСС, график ЭКГ, текстовую интерпретацию. Сводный отчет объединяет результаты нескольких файлов текущей сессии. Статистический отчет сортирует записи по вероятности патологии и может использоваться для приоритизации последующего просмотра и документирования.

PDF – отчет в текущей версии не содержит полноценные клинически валидированные тепловые карты значимости. Добавление таких карт относится к дальнейшему развитию отчетной подсистемы.

6.13 Реализация пользовательского интерфейса

Пользовательский интерфейс ориентирован на работу с очередью ЭКГ – записей. Главная страница позволяет загружать XML – файлы, просматривать их статус, фильтровать записи, запускать анализ и переходить к подробному просмотру (приложение Л, рисунок Л.1). Переход на страницу анализа вызывает POST /api/v1/analysis/run/<file_id>, поэтому подробный просмотр может заново выполнить анализ, а не только прочитать уже сохраненный результат. Страница анализа отображает результат классификации, вероятности классов, ритм, графики отведений и элементы управления порогом (приложение Л, рисунки Л.2 – Л.3).

Для работы с большим числом записей реализованы признаки просмотра и архивирования. Если запись была проанализирована и просмотрена, она может быть скрыта из активного списка и доступна через архив, внешний вид которого приведен на рисунке Л.6 приложения Л. Такой механизм снижает визуальную перегрузку при поточной работе и позволяет пользователю сосредоточиться на новых или непроверенных записях.

В интерфейс также включена карточка watcher и модальное окно настройки папки кардиографа. Пользователь может выбрать директорию экспорта, включить автоанализ, запустить повторное сканирование, приостановить наблюдение или восстановить его. Это связывает ручной и автоматический способы поступления данных в единый пользовательский сценарий.

6.14 Используемые технологии и библиотеки

Выбор технологий определялся задачами локальной обработки медицинского сигнала, нейросетевого вывод моделиа, интерактивной визуализации и формирования отчетов. Стек технологий представлен в таблице 23.

Таблица 23 – Используемые технологии

Категория	Технология	Назначение
Язык реализации	Python	Серверная логика и обработка данных
Веб – фреймворк	Flask	Маршрутизация, шаблоны, API приложения
Нейросетевой вывод модели	PyTorch	Загрузка и выполнение DenseNet121_1D
Численные вычисления	NumPy	Работа с массивами ЭКГ
Обработка сигналов	SciPy	Передискретизация, фильтрация, поиск пиков
Табличные данные	pandas	Вспомогательная обработка структурированных данных
XML – разбор	xml.etree.ElementTree / lxml	Чтение XML Poly – Spectrum.NET
Визуализация	Plotly	Интерактивные графики ЭКГ
Графики для отчетов	matplotlib	Подготовка изображений для PDF
PDF – генерация	ReportLab	Формирование отчетов
Desktop – режим	pywebview	Запуск интерфейса в нативном окне

Окончание таблицы 23

Категория	Технология	Назначение
Автоматический импорт	watchdog	Наблюдение за папкой кардиографа
Нативные диалоги	tkinter	Выбор папки экспорта (watcher)
Архитектура модели	fastai	Слои, используемые в определении DenseNet

6.15 Вывод по главе

В данной главе рассмотрены проектирование и реализация локальной программной системы поддержки принятия решений на основе анализа 12 – канальных ЭКГ – сигналов. Эксплуатационный контур системы работает с XML Poly – Spectrum.NET, извлекает 12 отведений, приводит сигнал к частоте 500 Гц, формирует вход 12 × 5000 для модели DenseNet121_1D и выполняет предварительную классификацию записи на три укрупненных класса: «норма», «патология» и «синусовые отклонения без явных патологических меток».

Дополнительно реализованы расчет R – пиков, ЧСС и класса ритма, интерактивное отображение ЭКГ, управление рабочим порогом чувствительности к патологическому классу, архивирование просмотренных записей, формирование PDF – отчетов и автоматический импорт XML – файлов из папки кардиографа. Эти компоненты образуют единый локальный контур обработки, ориентированный на работу врача с цифровыми ЭКГ – записями и последующую экспертную интерпретацию.

ЗАКЛЮЧЕНИЕ

В ходе выполнения выпускной квалификационной работы была разработана локальная программная система поддержки принятия решений для автоматизированного анализа 12-канальных ЭКГ-сигналов на основе технологий искусственного интеллекта.

На этапе теоретического анализа был выполнен обзор существующих коммерческих комплексов и исследовательских систем. Проведенный анализ позволил выявить ограничения современных решений, такие как зависимость от облачной инфраструктуры и проприетарных форматов данных, что обосновало разработку автономного программного продукта, обеспечивающего локальную обработку данных.

В рамках работы с данными была сформирована масштабная экспериментальная база, объединившая четыре крупнейших международных архива ЭКГ записей. Ключевым достижением этого этапа стала разработка методики гармонизации разнородных диагностических меток. Все сигналы были технически стандартизированы и переведены в физические величины для обеспечения корректности обучения.

В ходе экспериментального исследования было проведено сравнение глубоких сверточных архитектур ResNet18_1D и DenseNet121_1D на задаче трехклассовой классификации. Результаты показали превосходство архитектуры DenseNet121_1D, которая за счет механизма плотных соединений эффективнее переиспользует признаки и лучше справляется с распознаванием сложных состояний. Опытным путем было установлено, что использование исходного «сырого» сигнала без агрессивной фильтрации и поканальной нормализации позволяет модели сохранять важные диагностические компоненты и достигать более высокой устойчивости классификации.

Программная реализация проекта позволила объединить теоретические наработки в законченный продукт. Разработанный комплекс обеспечивает автоматизацию рабочего процесса: от анализа специализированных

медицинских форматов и автоматического мониторинга папок экспорта кардиографа до интерактивной визуализации сигналов и генерации отчетов. Локальный характер системы исключает необходимость передачи персональных данных во внешние сети, что критически важно для медицинских организаций.

Клиническая апробация системы на реальных обезличенных записях подтвердила ее работоспособность в условиях, приближенных к эксплуатационным. Проверка выявила потенциал системы как инструмента предварительного скрининга, а также позволила определить направления для дальнейшего совершенствования, связанные с адаптацией модели к специфическим возрастным группам пациентов и особенностям конкретного диагностического оборудования.

Таким образом, все задачи, поставленные в начале работы, выполнены в полном объеме. Созданная система представляет собой инструмент поддержки врачебных решений, способный повысить оперативность обработки ЭКГ – исследований и снизить риск пропуска патологических изменений в клинической практике.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1 12SL physicians guide // Numed. – URL: https://www.numed.co.uk/files/uploads/Product/2_12SL%20Physicians%20Guide%20Rev%20B.pdf (дата обращения: 20.03.2026).

2 A deep learning approach for ECG – based prediction of cardiovascular outcomes / Z. I. Attia [et al.] // PubMed. – 2019. – URL: https://pubmed.ncbi.nlm.nih.gov/30617320 (дата обращения: 20.03.2026).

3 A multi – label ECG classification approach using deep learning / J. M. [et al.] // PLOS ONE. – 2024. – URL: https://journals.plos.org/plosone/article?id=10.1371%2Fjournal.pone.0303178 (дата обращения: 20.03.2026).

4 An explainable deep learning model for ECG – based arrhythmia detection / Y. L. [et al.] // Computers in Biology and Medicine. – 2024. – URL: https://www.sciencedirect.com/science/article/pii/S0010482524013568 (дата обращения: 20.03.2026).

5 Arrhythmia classification from single – lead ECG using deep learning / P. Rajpurkar [et al.] // arXiv:2004.13701. – 2020. – URL: https://arxiv.org/pdf/2004.13701.pdf (дата обращения: 20.03.2026).

6 Arrhythmia classification using transformer networks / H. C. [et al.] // arXiv:2403.15012v2. – 2024. – URL: https://arxiv.org/html/2403.15012v2 (дата обращения: 20.03.2026).

7 Artificial intelligence for cardiovascular disease prevention and management / X. Liu [et al.] // Frontiers in Cardiovascular Medicine. – 2022. – URL: https://www.frontiersin.org/articles/10.3389/fcvm.2022.853614/full (дата обращения: 20.03.2026).

8 Artificial intelligence in cardiology : applications and challenges / D. D. Wang [et al.] // PMC. – 2021. – URL: https://pmc.ncbi.nlm.nih.gov/articles/PMC8500024 (дата обращения: 20.03.2026).

9 Automated diagnosis of cardiovascular diseases from ECG using deep learning / H. J. L. [et al.] // PMC. – 2023. – URL: https://pmc.ncbi.nlm.nih.gov/articles/PMC10356811 (дата обращения: 20.03.2026).

10 Classification of 12 – lead ECGs (PhysioNet Challenge 2020) / E. A. P. [et al.] // Computing in Cardiology. – 2020. – URL: https://physionet.org/content/challenge2020/1.0.1/papers/CinC2020 – 127.pdf (дата обращения: 20.03.2026).

11 CorIntelTech : искусственный интеллект для аннотации электрокардиограммы // Журнал телемедицины. – URL: https://jtelemed.ru/article/corinteltech – iskusstvennyj – intellekt – dlja – annotaciijelektrokardiogrammy (дата обращения: 20.03.2026).

12 Deep learning for ECG arrhythmia classification / L. Zhang [et al.] // Transactions on Network Science (EWA Direct). – URL: https://www.ewadirect.com/proceedings/tns/article/view/7917 (дата обращения: 20.03.2026).

13 Deep learning for electrocardiogram analysis : a review / E. J. Topol [et al.] // PMC. – 2020. – URL: https://pmc.ncbi.nlm.nih.gov/articles/PMC7522782 (дата обращения: 20.03.2026).

14 DXL Algorithm : white paper // Coffey Medical. – 2017. – URL: https://coffeymedical.com/wpcontent/uploads/2017/08/DXL_Algorithm_White_Paper.pdf (дата обращения: 20.03.2026).

15 ECG analysis by wavelet transform : a review / M. A. Hasan // arXiv:1005.0957. – 2010. – URL: https://arxiv.org/pdf/1005.0957.pdf (дата обращения: 20.03.2026).

16 ECG – based deep learning and clinical risk factors for mortality / S. K. K. [et al.] // arXiv:1904.01949. – 2019. – URL: https://arxiv.org/pdf/1904.01949.pdf (дата обращения: 20.03.2026).

17 ECG – Image – Kit: a dataset for classification of ECG images / M. A. R. [et al.] // Nature Scientific Data. – 2023. – URL:

https://www.nature.com/articles/s41597023 – 02153 – 8 (дата обращения: 20.03.2026).

18 External validation of a deep learning model for automatic detection of left ventricular systolic dysfunction / A. H. Ribeiro [et al.] // JAMA Internal Medicine. – 2025. – URL: https://jamanetwork.com/journals/jamainternalmedicine/fullarticle/2771093 (дата обращения: 20.03.2026).

19 Lund University ECG dataset (LUDB) // PhysioNet. – URL: https://physionet.org/content/ludb (дата обращения: 20.03.2026).

20 Machine learning for ECG analysis : a comprehensive review / S. F. [et al.] // PMC. – 2024. – URL: https://pmc.ncbi.nlm.nih.gov/articles/PMC11208545 (дата обращения: 20.03.2026).

21 Machine learning in cardiovascular medicine : current status and future directions / M. J. P. [et al.] // European Journal of Clinical Investigation. – URL: https://onlinelibrary.wiley.com/doi/10.1111/eci.70002 (дата обращения: 20.03.2026).

22 Marquette 12SL ECG analysis program : brochure // GE Healthcare. – URL: https://www.gehealthcare.com/ – /jssmedia/gehc/us/images/products/diagnosticcardiology/marquette – 12sl/brochure – marquette – 12 – sl – us.pdf?rev= – 1 (дата обращения: 20.03.2026).

23 PTB – XL: a large publicly available electrocardiography dataset / P. Wagner [et al.] // Nature Scientific Data. – 2020. – URL: https://www.nature.com/articles/s41597 – 020 – 0495 – 6 (дата обращения: 20.03.2026).

24 Self – supervised learning for ECG analysis / A. B. [et al.] // arXiv:2503.00711. – 2025. – URL: https://arxiv.org/pdf/2503.00711.pdf (дата обращения: 20.03.2026).

25 Комплексный анализ протоколов ЭКГ с использованием методов машинного обучения // Кардиоваскулярная терапия и профилактика. – URL: https://cardiovascular.elpub.ru/jour/article/view/4130 (дата обращения: 20.03.2026).

26 Разработка и валидация моделей машинного обучения, прогнозирующих госпитализации пациентов с артериальной гипертензией в течение 12 месяцев // WebiMed: публикации. – URL: https://webiomed.ai/publikacii/razrabotka – i – validatsiia – modelei – mashinnogoobucheniia – prognoziruiushchikh – gospitalizatsii – patsientov – s – arterialnoi – gipertenziei – v – techenie – 12 – mesiatsev (дата обращения: 20.03.2026).

ПРИЛОЖЕНИЕ А

Модульная архитектура локального программного комплекса

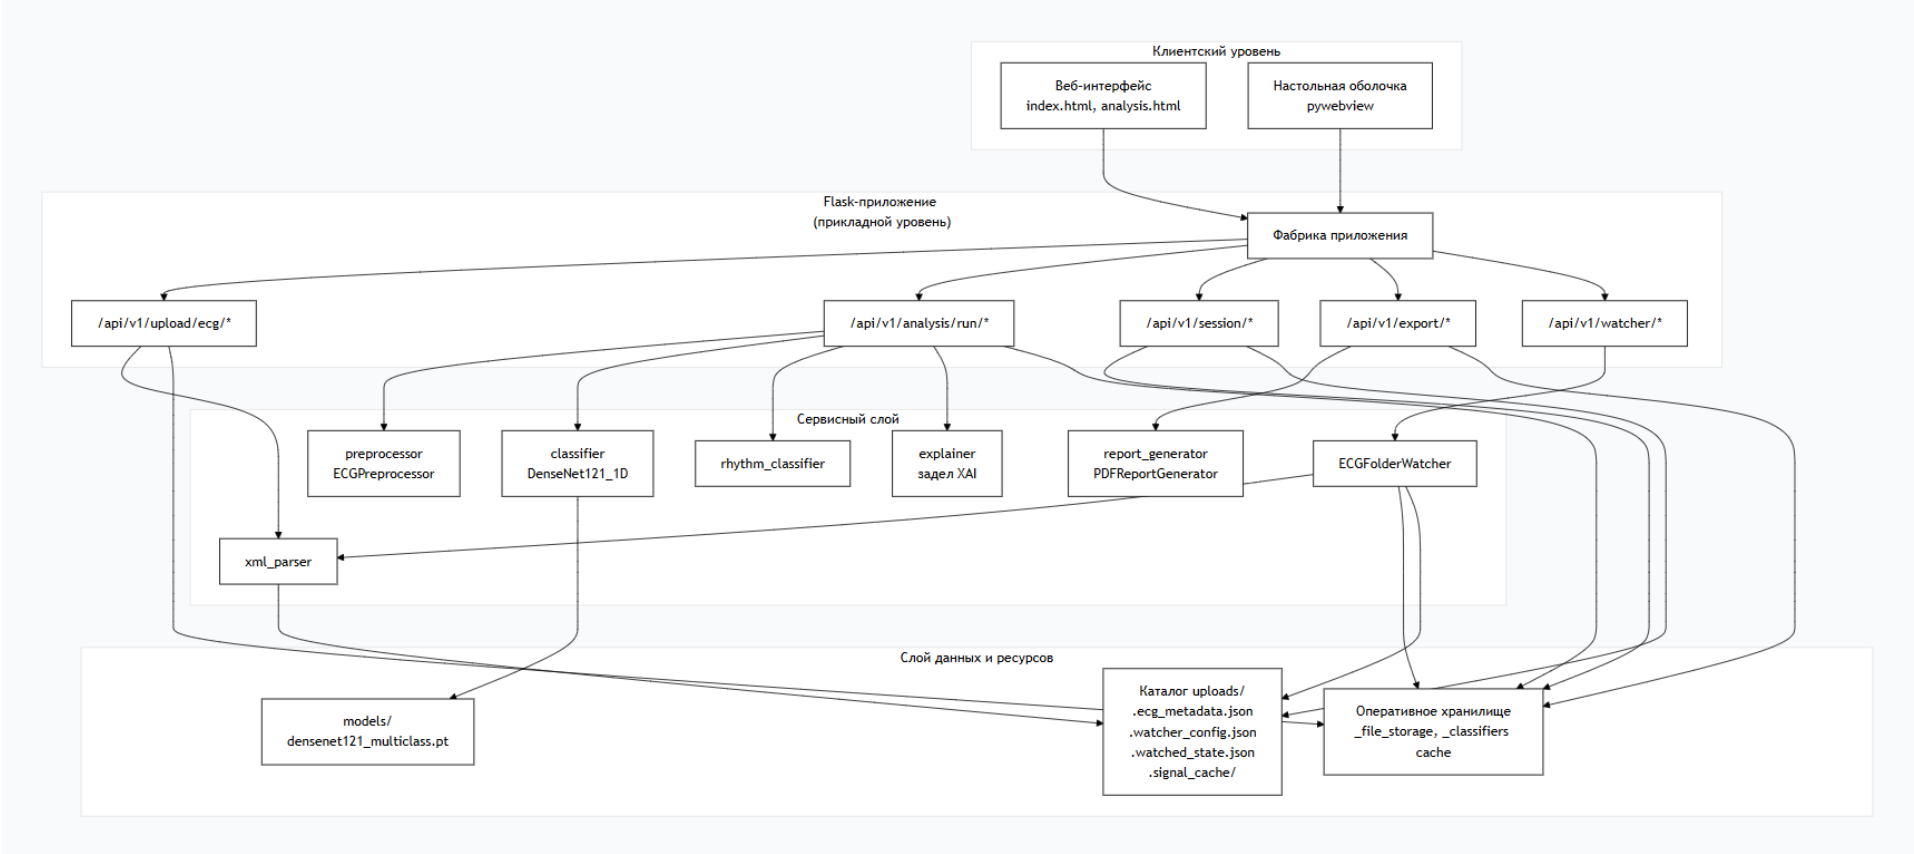
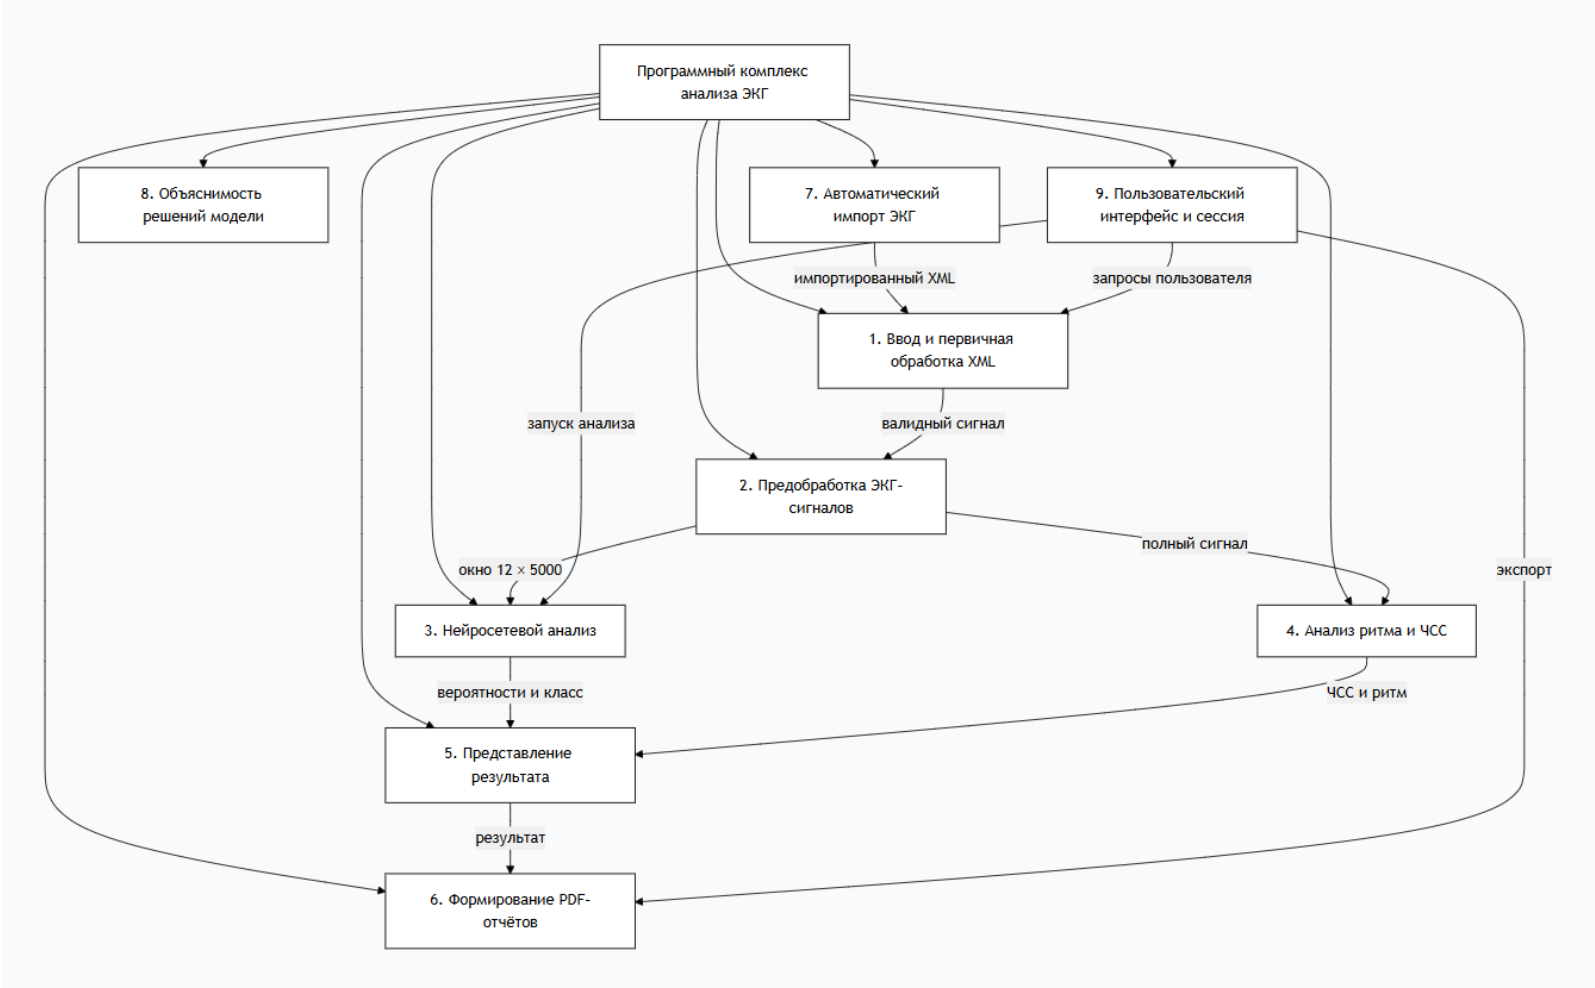


Рисунок А.1 – Модульная архитектура локального программного комплекса

ПРИЛОЖЕНИЕ Б

Состав и связи функциональных подсистем



при

Рисунок Б.1 – Схема состава и связи функциональных подсистем

ПРИЛОЖЕНИЕ В

Архитектура подсистемы автоматического импорта

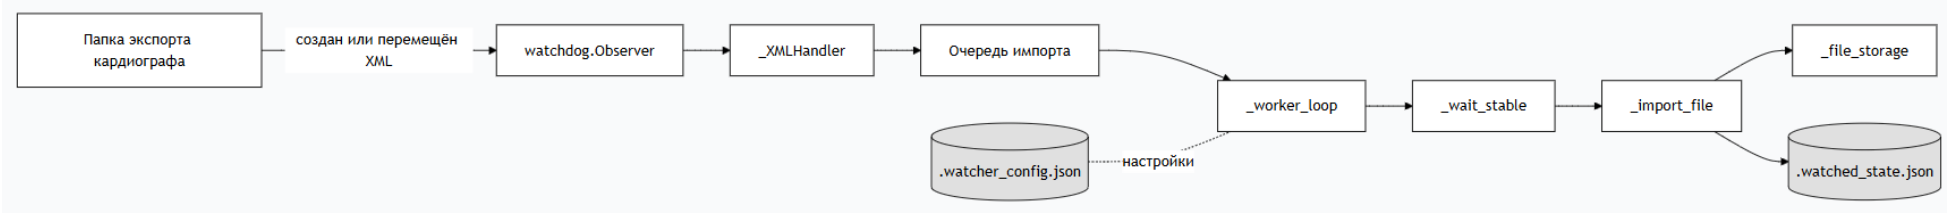


Рисунок В.1 – Подсистема автоматического импорта

ПРИЛОЖЕНИЕ Г

Основной поток обработки ЭКГ

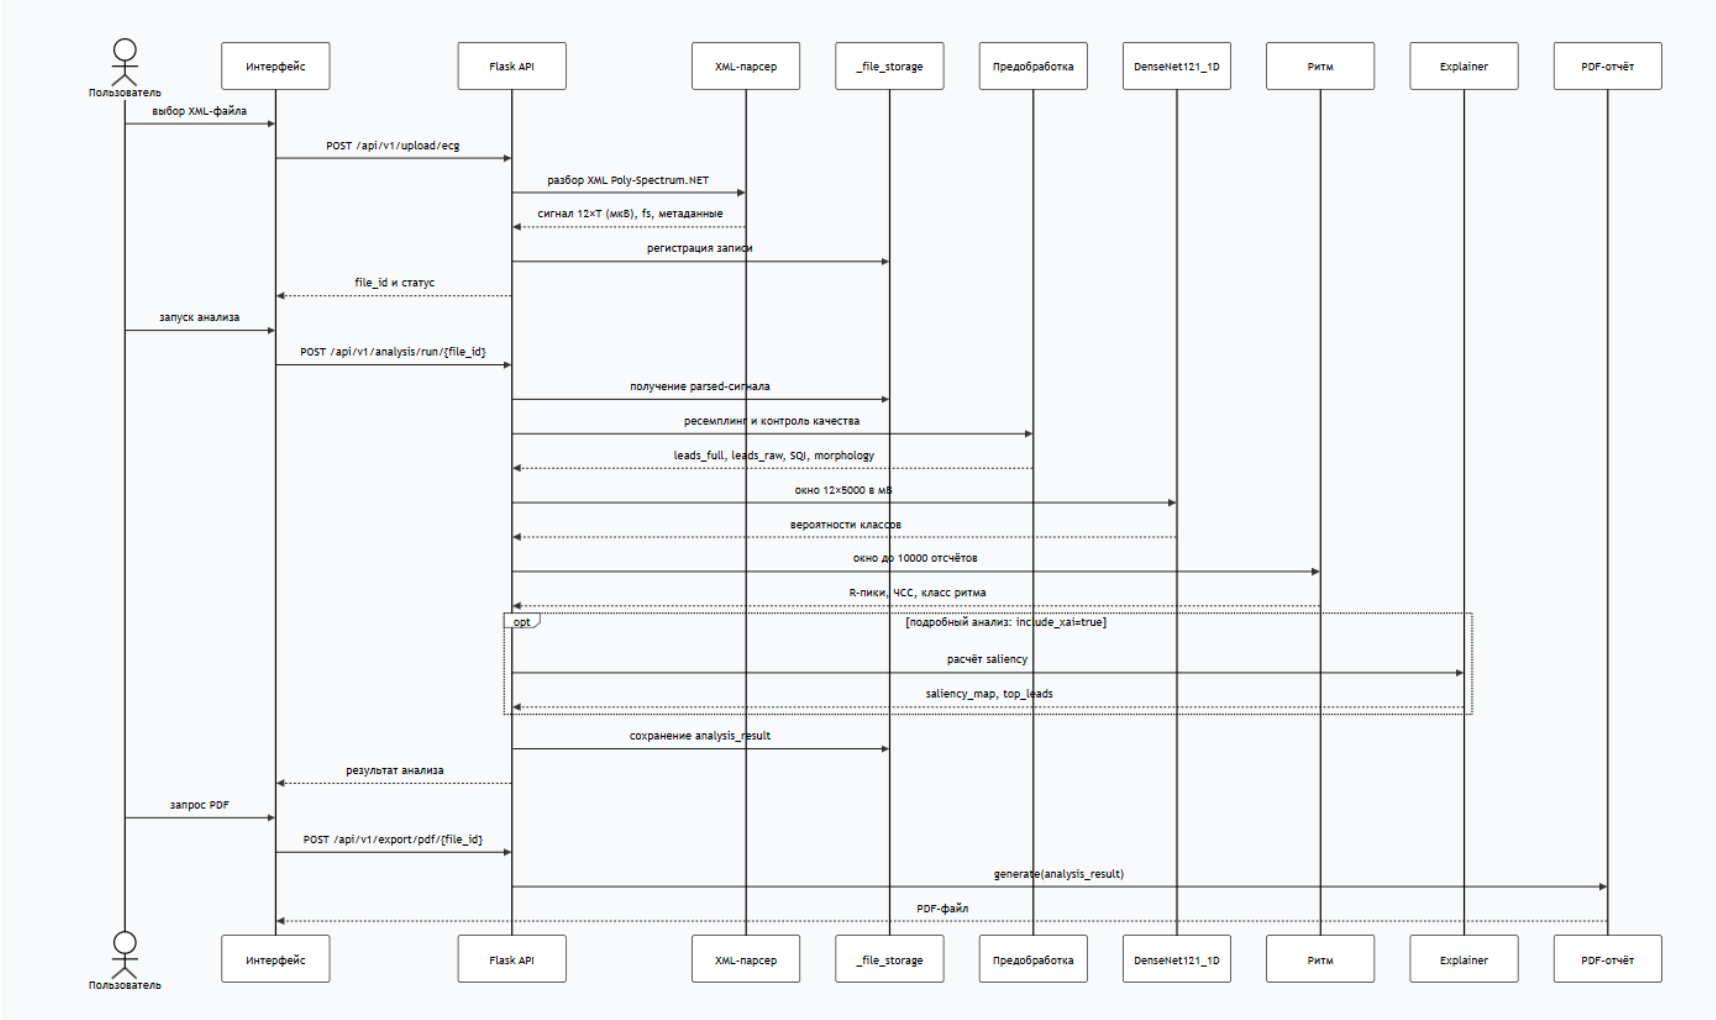


Рисунок Г.1 – Основной поток обработки ЭКГ

ПРИЛОЖЕНИЕ И

Схема потока автоматического импорта XML – файлов из папки кардиографа

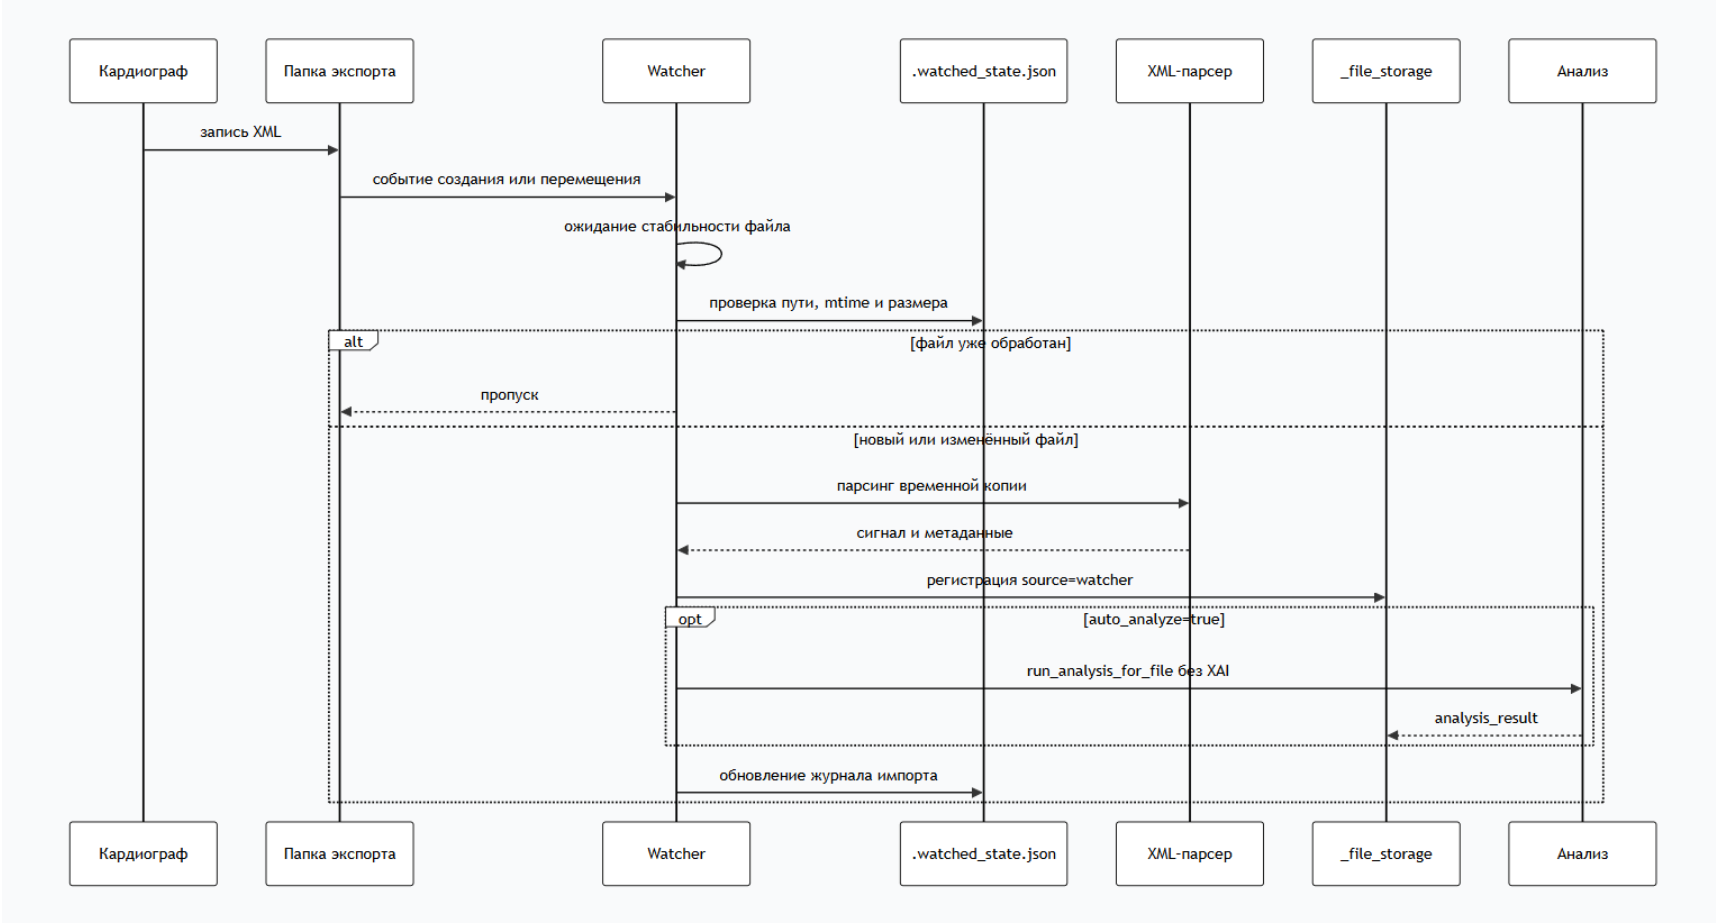


Рисунок И.1 – Поток автоматического импорта XML – файлов из папки кардиографа

ПРИЛОЖЕНИЕ К

Схема конвейера подготовки сигнала и нейросетевой классификации представлена на рисунке

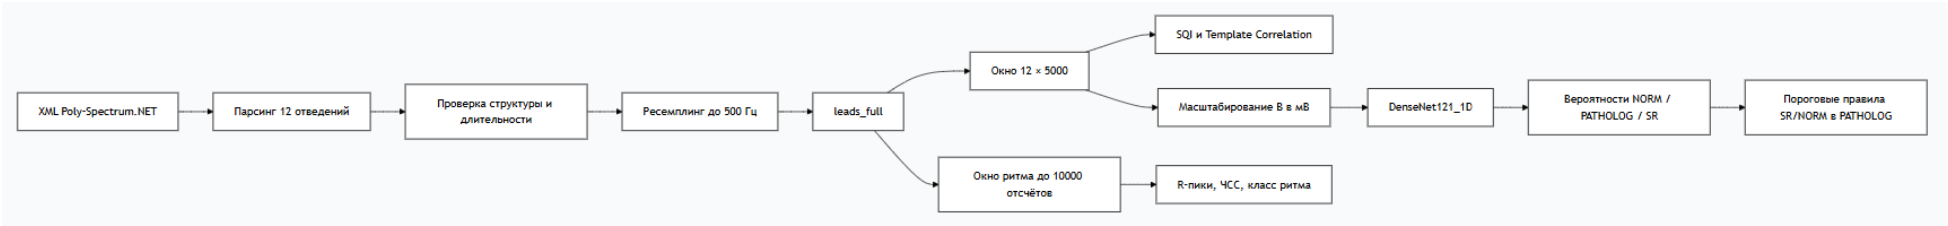


Рисунок К.1 – Схема конвейера подготовки сигнала и нейросетевой классификации представлена на рисунке

ПРИЛОЖЕНИЕ Л

Интерфейс программного комплекса

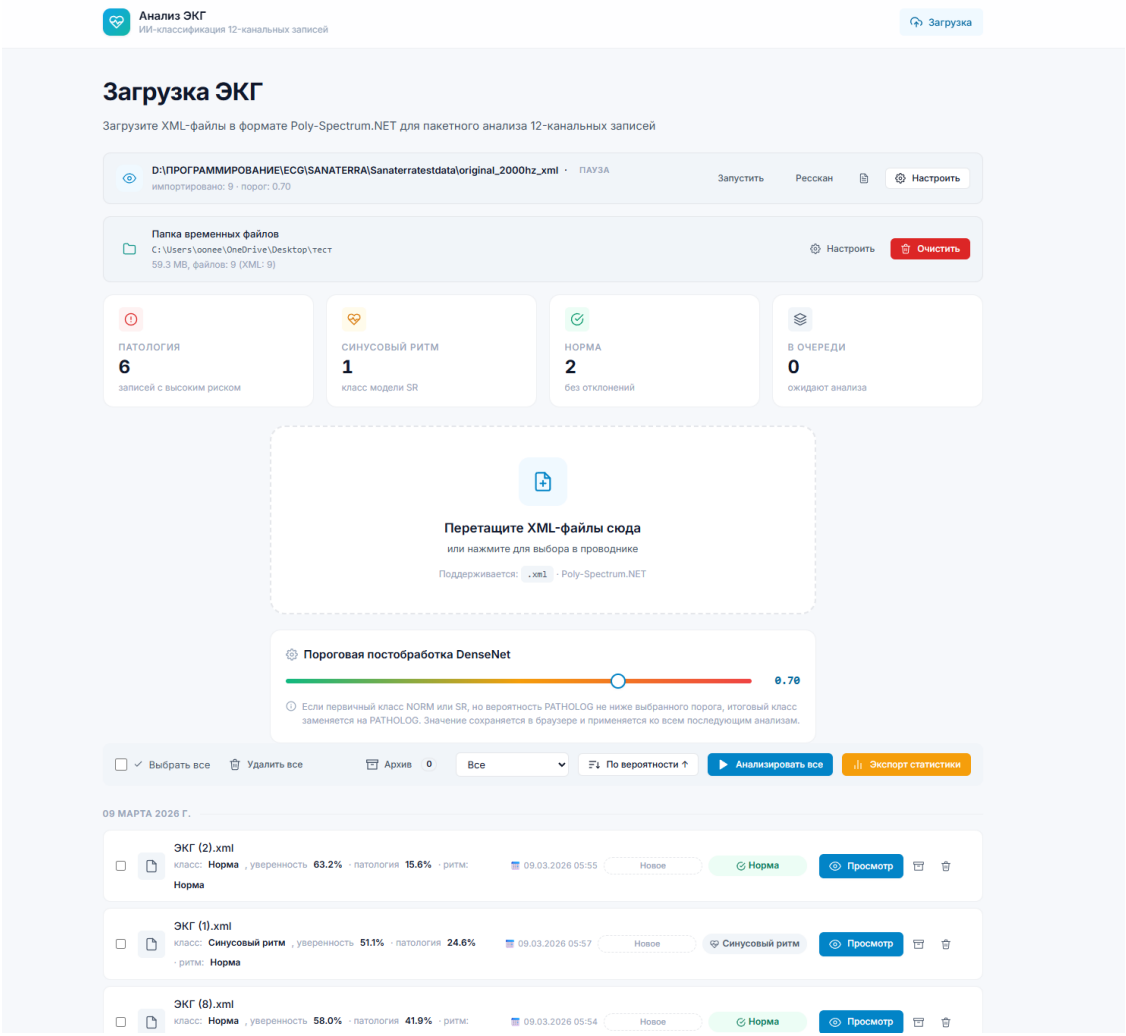


Рисунок Л.1 – Главная страница управления записями

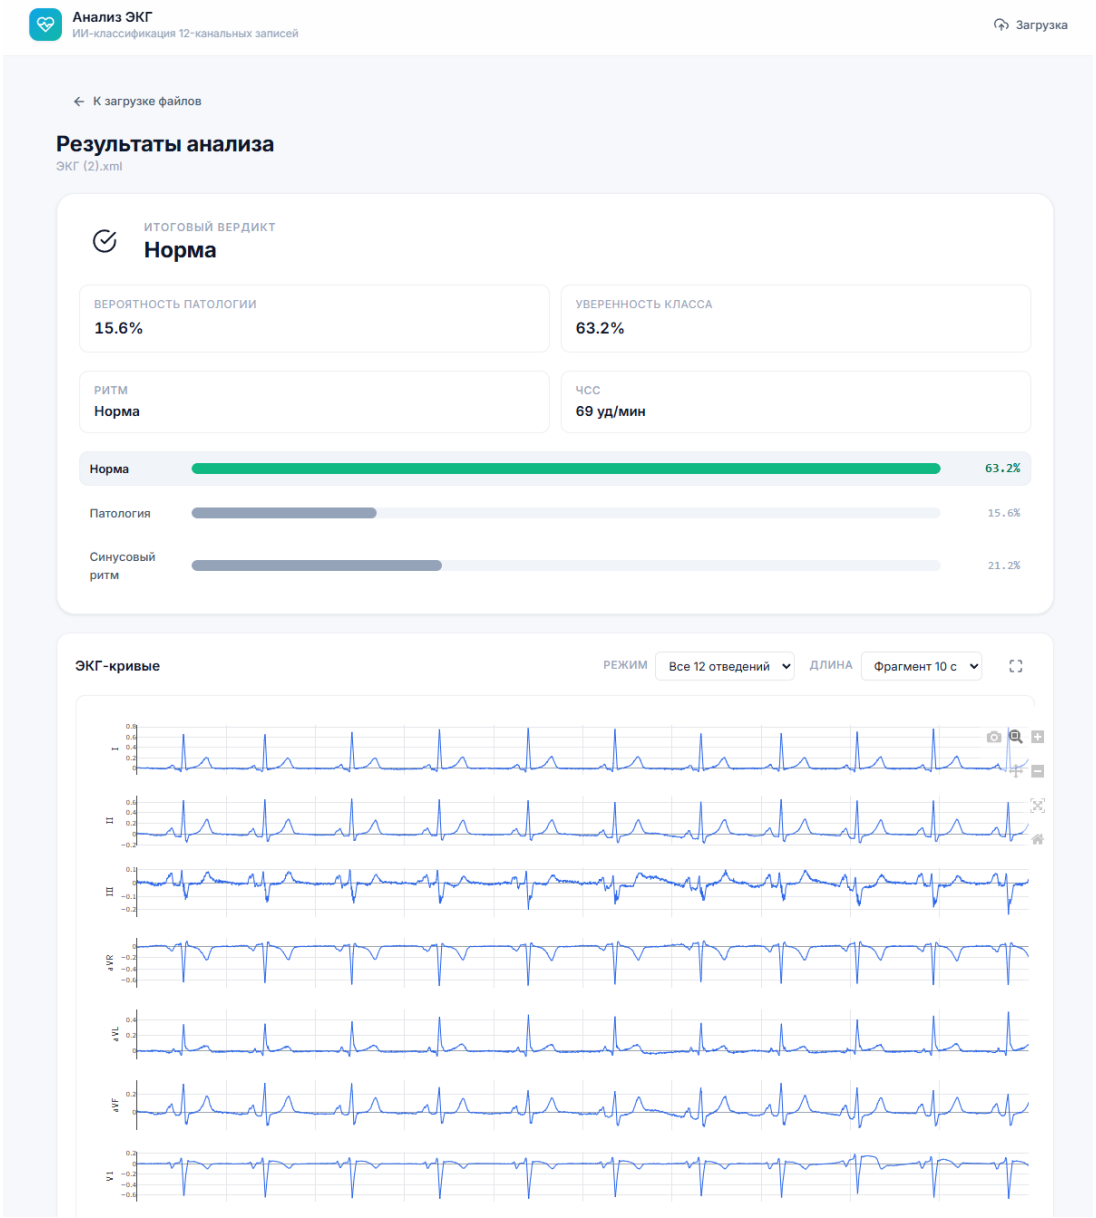


Рисунок Л.2 – Страница детального анализа: результаты классификации

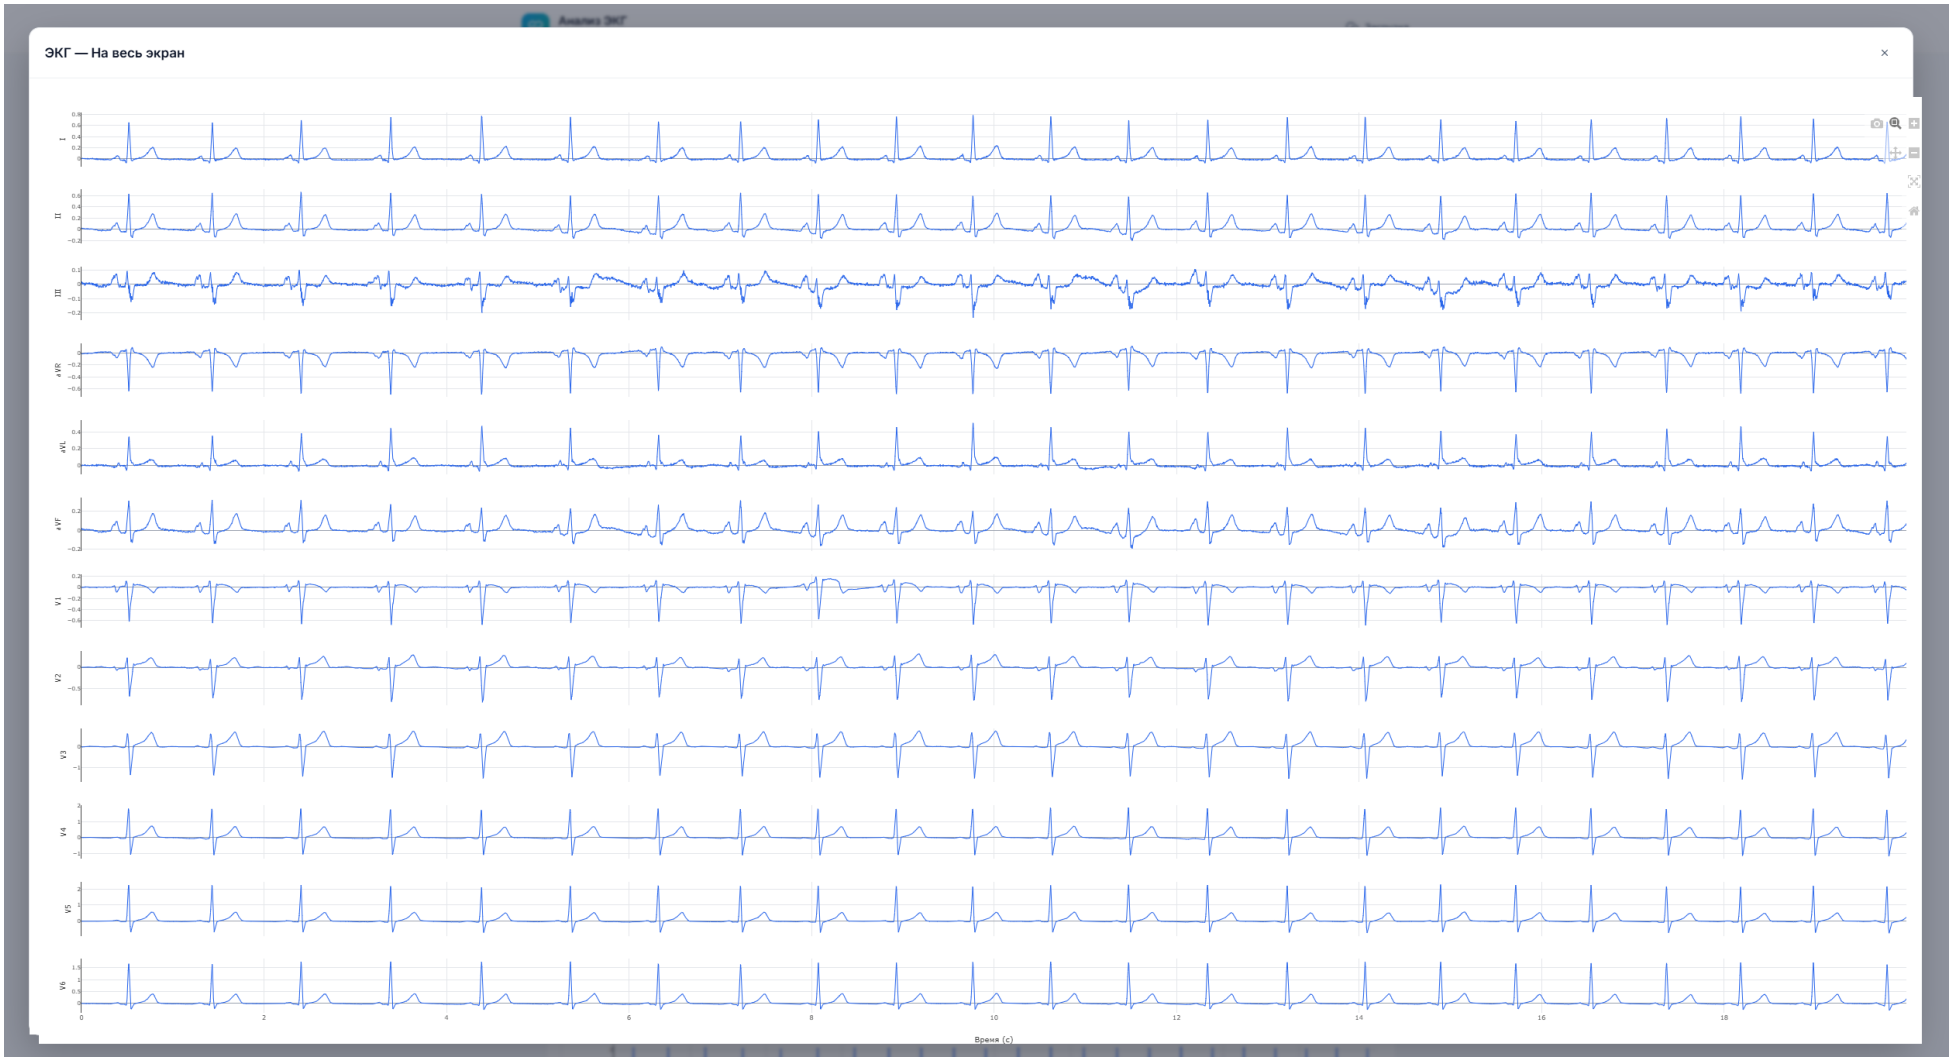


Рисунок Л.3 – Интерактивная визуализация 12 отведений

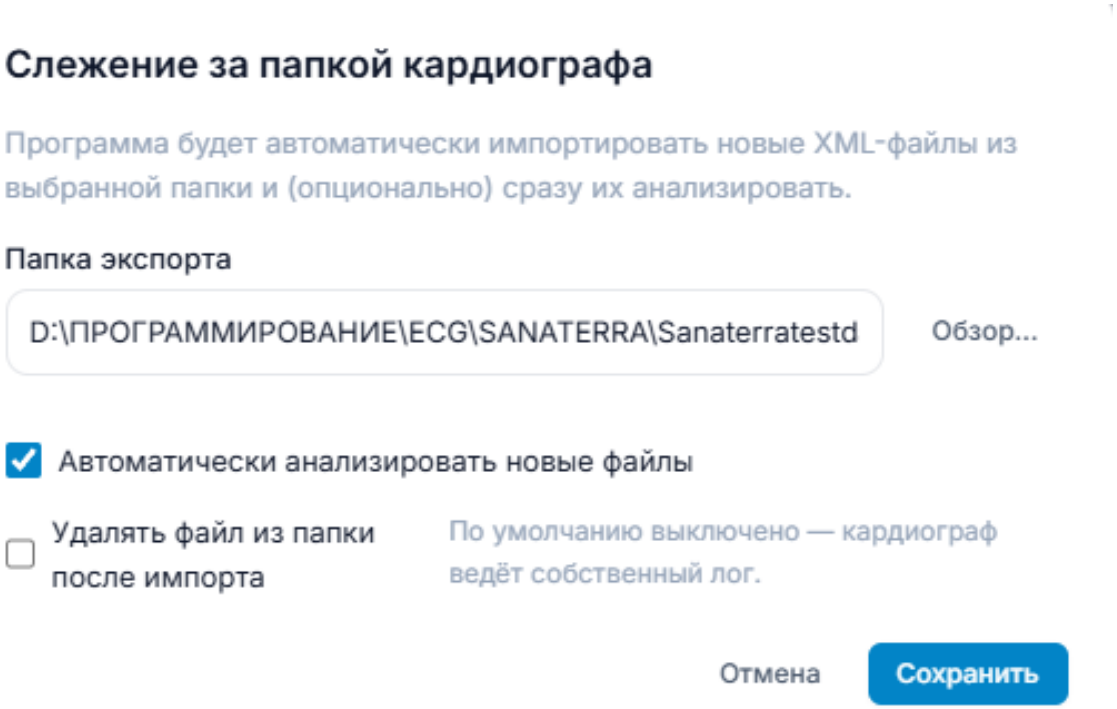


Рисунок Л.4 – Настройка подсистемы автоматического импорта



Статистика анализа ЭКГ

Дата: 17.06.2026 15:25
Всего записей: 9

Патология: 6 | Синусовый ритм: 1 | Бради/тахикардия: 0 | Норма: 2 | Средняя вероятность: 51.6%

№	Файл	Вероятность патологии (%)	Вердикт
1	ЭКГ (3).xml	76.7	Патология
2	ЭКГ (7).xml	75.4	Патология
3	ЭКГ (9).xml	73.3	Патология
4	ЭКГ (5).xml	59.9	Патология
5	ЭКГ (6).xml	49.9	Патология
6	ЭКГ (4).xml	47.2	Патология
7	ЭКГ (8).xml	41.9	Норма
8	ЭКГ (1).xml	24.6	Синусовый ритм
9	ЭКГ (2).xml	15.6	Норма

Данный анализ выполнен автоматически с использованием искусственного интеллекта и предназначен только для предварительной оценки. Окончательный диагноз должен устанавливаться квалифицированным врачом на основании полного клинического обследования.

Рисунок Л.5 – Пример сформированного PDF – отчета

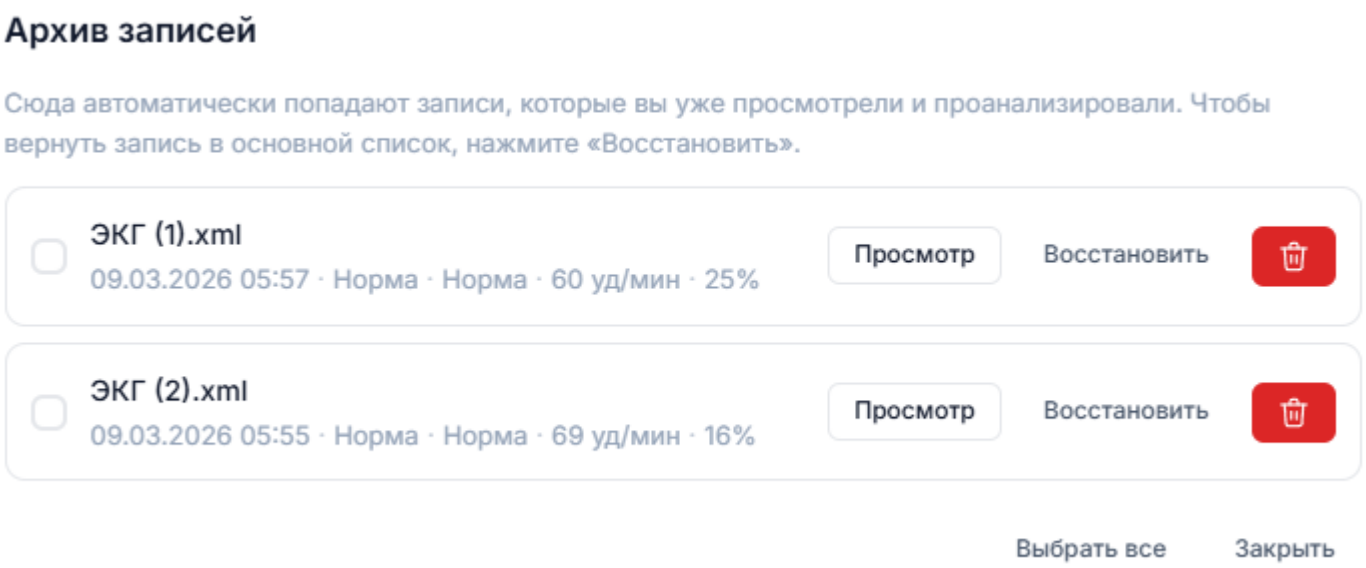


Рисунок Л.6 – Архив записей

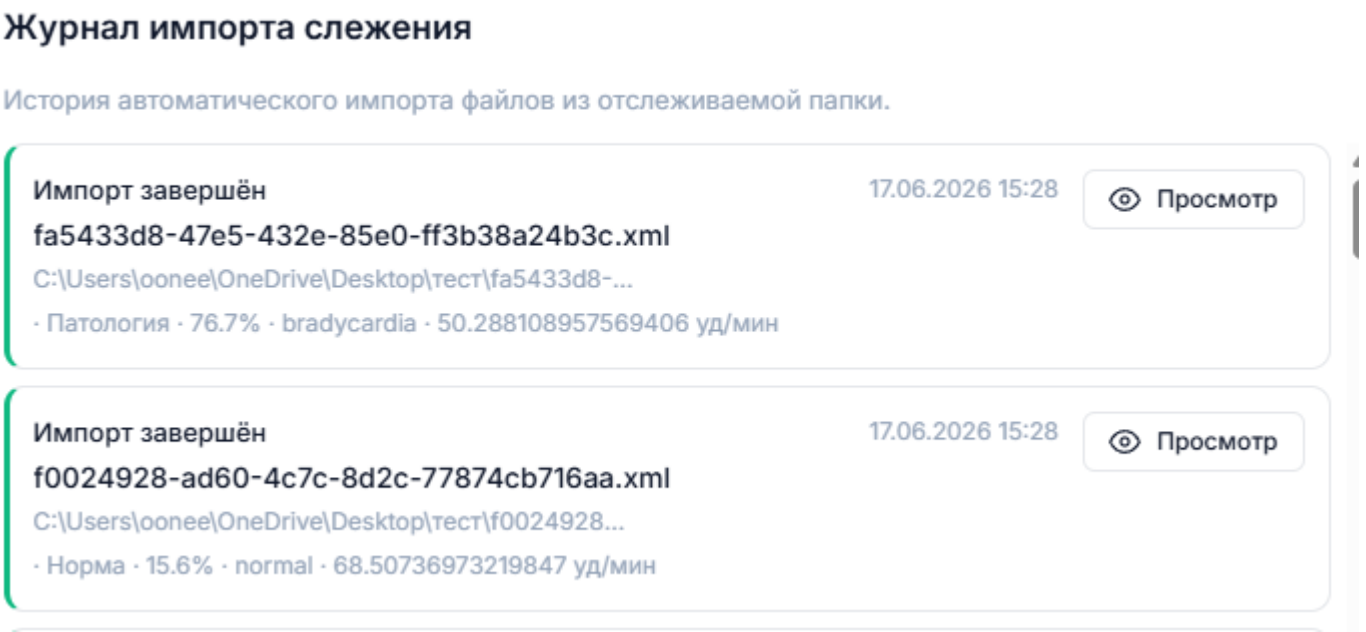


Рисунок Л.7 – Журнал истории автоанализа